

Bootstrap

Yael Rene Santiago Cruz

1. Bootstrap

Supongamos que tenemos una muestra $X_1, X_2, \dots, X_n \sim i.i.d. F$ desconocida, y nuestro objetivo es estimar la estadística $T = T(X_1, \dots, X_n)$. Sabemos que la función de distribución empírica asociada a los datos

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}\{X_i \leq x\} \xrightarrow{c.s} F$$

Por lo tanto, para estimar T , una buena idea es simular datos de $\hat{F}_n(X)$, pero ¿cómo lo hacemos?

Notamos que, dada la muestra $X_1, \dots, X_n \sim i.i.d. F$, $\hat{F}_n$ define una ley de probabilidad discreta con un número finito de átomos, la cual es

$$\hat{P}_n(x) = \frac{\#\{i : X_i = x\}}{n}$$

Entonces, para simular $X_1^*, \dots, X_n^* \sim \hat{F}_n$ es suficiente obtener n observaciones con reemplazo de X .

Algorithm 1 Algoritmo Bootstrap

- 1: Dada la muestra original $X_1, \dots, X_n$ de una distribución desconocida F
- 2: Fijar el número de réplicas bootstrap B
- 3: **for** $b = 1, \dots, B$ **do**
- 4: Obtener una muestra bootstrap:

$$X_1^*, \dots, X_n^* \sim \hat{F}_n$$

donde $\hat{F}_n$ es la distribución empírica que pone masa $1/n$ en cada X_i

- 5: Calcular el estadístico de interés:

$$T_{n,b}^* = T(X_1^*, \dots, X_n^*)$$

- 6: **end for**

- 7: Obtener la colección $T_{n,1}^*, \dots, T_{n,B}^*$

- 8: Estimar el estadístico:

$$\hat{T}_n = \frac{1}{B} \sum_{b=1}^B T_{n,b}^*$$

Con esto podemos obtener la varianza e intervalos de confianza para el estadístico T . La varianza se calcula como

$$\text{Var}_{\text{Boot}} = \frac{1}{B} \sum_{i=1}^B \left(T_{n,i}^* - \hat{T} \right)^2,$$

mientras que para los intervalos podemos usar

$$CI = \left(\hat{\theta}_{\alpha/2}^*, \hat{\theta}_{1-\alpha/2}^* \right).$$

donde $\hat{\theta}_q^*$ es el cuantil q empírico.

1.1. Bootstrap Bayesiano

En el *Bootstrap Bayesiano*, queremos obtener muestras de una distribución aleatoria sobre la función de distribución empírica. La idea consiste en generar un vector de pesos aleatorios

$$p = (p_1, \dots, p_n) \sim \text{Dirichlet}(\alpha_1, \dots, \alpha_n),$$

donde los pesos satisfacen $p_i \geq 0$ y $\sum_{i=1}^n p_i = 1$. Posteriormente, estos pesos se utilizan para construir el estimador de interés mediante una versión ponderada de la muestra observada.

El caso más común es tomar

$$\alpha_i = 1, \quad i = 1, \dots, n,$$

pues esto induce una distribución uniforme sobre el simplex y suele interpretarse como una elección no informativa.

En particular, si la muestra observada es

$$X_1, \dots, X_n,$$

la distribución aleatoria asociada al *Bootstrap Bayesiano* puede escribirse como

$$F^*(x) = \sum_{i=1}^n p_i \mathbf{1}(X_i \leq x).$$

Es decir, dado que conocemos la muestra, F^* define la siguiente medida de probabilidad:

$$P(X = X_i) = p_i, \text{ para } i = 1, \dots, n.$$

El estimador bootstrap de un parámetro θ se obtiene evaluando el funcional correspondiente sobre F^* .

Algorithm 2 Algoritmo Bootstrap Bayesiano

- 1: Dada la muestra observada $X_1, \dots, X_n$
- 2: Fijar el número de réplicas bootstrap B
- 3: **for** $b = 1, \dots, B$ **do**
- 4: Generar pesos aleatorios

$$(p_1^{(b)}, \dots, p_n^{(b)}) \sim \text{Dirichlet}(1, \dots, 1)$$

- 5: Construir la distribución empírica ponderada

$$F_b^*(x) = \sum_{i=1}^n p_i^{(b)} \mathbf{1}(X_i \leq x)$$

- 6: Calcular el estadístico de interés

$$T_{n,b}^* = T(F_b^*)$$

- 7: **end for**
- 8: Obtener la colección

$$T_{n,1}^*, \dots, T_{n,B}^*$$

- 9: Aproximar la distribución posterior del estadístico mediante las réplicas bootstrap obtenidas
-

Ejemplo

Supongamos que tenemos una muestra $X_1, \dots, X_n$ de variables i.i.d con función de distribución F y queremos estimar $\theta = E[g(X)]$. Entonces, para $b = 1, \dots, B$

$$T_{n,b}^* = \int g(x) dF_b^* = \sum_{i=1}^n p_i^{(b)} g(X_i).$$

1.2. Bootstrap en Regresión

Considere el modelo de regresión lineal múltiple $y_i = \mathbf{x}_i^T \boldsymbol{\beta} + \epsilon_i$ para $i = 1, \dots, n$, donde ϵ_i son i.i.d. con media cero y varianza constante. Una formas de aplicar el bootstrap es remuestreando los residuales: ajuste el modelo para obtener valores ajustados $\hat{y}_i$ y residuales $\hat{\epsilon}_i$; muestree $\{\hat{\epsilon}_1^*, \dots, \hat{\epsilon}_n^*\}$ con reemplazo de $\{\hat{\epsilon}_1, \dots, \hat{\epsilon}_n\}$; cree pseudo-respuestas $y_i^* = \hat{y}_i + \hat{\epsilon}_i^*$; ajuste la regresión $\mathbf{y}^*$ sobre $\mathbf{x}$ para obtener $\hat{\boldsymbol{\beta}}^*$; repita. Esto funciona para predictores fijos (diseños experimentales). Para estudios observacionales donde (x_i, y_i) son i.i.d., use el remuestreo pareado: muestree pares $\mathbf{Z}_i^* = (x_i^*, y_i^*)$ con reemplazo de los pares observados $\{(x_1, y_1), \dots, (x_n, y_n)\}$, luego estime $\hat{\boldsymbol{\beta}}^*$. El remuestreo pareado es menos sensible a violaciones de los supuestos del modelo (ej., varianza no constante) que el remuestreo de residuales.

1.3. Métodos de Ensamble con Bootstrap

Supongamos que tenemos un conjunto de datos

$$D = \{(X_1, Y_1), \dots, (X_n, Y_n)\}$$

y queremos entrenar un modelo de machine learning para aproximar la relación entre X y Y . Un problema común en aprendizaje estadístico es que muchos modelos tienen alta varianza, es decir, pequeños cambios en los datos producen modelos muy diferentes.

La idea principal de los métodos de ensamble es combinar múltiples modelos para obtener un predictor más estable y con mejor capacidad de generalización. Uno de los métodos más importantes es el *Bootstrap Aggregating* o *Bagging*.

El método consiste en generar múltiples conjuntos de entrenamiento usando Bootstrap. Para cada conjunto Bootstrap entrenamos un modelo

$$f^{(b)}(x), \quad b = 1, \dots, B$$

de manera independiente.

En problemas de regresión, la predicción final se obtiene promediando las predicciones de todos los modelos,

$$\hat{f}(x) = \frac{1}{B} \sum_{b=1}^B f^{(b)}(x)$$

mientras que en clasificación normalmente se utiliza votación mayoritaria,

$$\hat{y}(x) = \text{Moda} \left(f^{(1)}(x), \dots, f^{(B)}(x) \right).$$

La ventaja principal de Bagging es que reduce la varianza del estimador sin incrementar demasiado el sesgo. Este método es especialmente útil para modelos inestables como árboles de decisión. De hecho, Random Forest puede verse como una extensión de Bagging donde además se introduce aleatoriedad en la selección de variables durante la construcción de cada árbol.

1.3.1. Ensamble con Bootstrap Bayesiano

En lugar de remuestrear observaciones, cada modelo del ensamble se entrena usando pesos distintos sobre los datos originales. Así, cada observación contribuye de manera diferente en cada modelo del ensamble.

Si denotamos por

$$f^{(b)}(x)$$

el modelo entrenado usando el vector de pesos $p^{(b)}$, entonces la predicción final nuevamente puede obtenerse promediando

$$\hat{f}(x) = \frac{1}{B} \sum_{b=1}^B f^{(b)}(x).$$

En el caso donde queremos ajustar un modelo de tal manera que se minimice una función de pérdida, al aplicar Bootstrap Bayesiano el problema es equivalente al siguiente:

$$\theta^{(b)} = \arg \min_{\theta} - \sum_{i=1}^n p_i^{(b)} \log (q(y_i; x_i, \theta)).$$

Es decir, la nueva función de pérdida queda dada por

$$\mathcal{L}^{(b)}(\theta) = - \sum_{i=1}^n p_i^{(b)} \log (q(y_i; x_i, \theta)),$$

en donde $q(y_i; x_i, \theta)$ es la verosimilitud de los datos.

A diferencia del Bootstrap clásico, aquí todas las observaciones participan en el entrenamiento, pero cada una tiene distinta importancia dependiendo de los pesos generados.