

1. Desbalance de clases y ajuste de logits

En muchos problemas de clasificación, algunas clases son mucho más frecuentes que otras. En este caso, entrenar mediante máxima verosimilitud con la pérdida de entropía cruzada estándar puede producir clasificadores que favorecen a las clases mayoritarias, ya que el error total está dominado por ellas. Una alternativa consiste en minimizar la *balanced error rate* (BER), definida como el promedio de los errores de clasificación dentro de cada clase,

$$BER(f) = \frac{1}{C} \sum_{y=1}^C P \left(y \notin \arg \max_{y'} f_{y'}(x) \mid y \right).$$

El clasificador que minimiza esta cantidad satisface

$$\arg \max_y f_y^*(x) = \arg \max_y p_{\text{bal}}(y|x) = \arg \max_y p(x|y),$$

donde $p_{\text{bal}}(y) = 1/C$ corresponde a asumir clases balanceadas. Por tanto, minimizar el BER equivale a utilizar las probabilidades condicionales $p(x|y)$ en lugar de las probabilidades posteriores $p(y|x)$.

Supóngase que un modelo produce logits

$$f_y(x) = w_y^T \phi(x),$$

de manera que

$$p(y|x) = \frac{\exp(f_y(x))}{\sum_{j=1}^C \exp(f_j(x))}.$$

Si $\pi_y = p(y)$ denota la proporción empírica de la clase y , entonces, usando la fórmula de Bayes,

$$p(x|y) = \frac{p(y|x)p(x)}{\pi_y},$$

y por consiguiente

$$\arg \max_y p(x|y) = \arg \max_y \frac{\exp(f_y(x))}{\pi_y} = \arg \max_y (f_y(x) - \log \pi_y).$$

En el libro proponen introducir un parámetro $\tau > 0$ y utilizar la regla de decisión

$$\hat{f}(x) = \arg \max_y (f_y(x) - \tau \log \pi_y),$$

la cual se conoce como *logit adjustment*. Esta corrección penaliza a las clases más frecuentes y favorece a las clases minoritarias.

El ajuste puede aplicarse únicamente durante la predicción (*post-hoc logit adjustment*) o incorporarse directamente en el entrenamiento. En este último caso se definen los logits ajustados

$$g_y(x) = f_y(x) + \tau \log \pi_y,$$

y se utiliza la pérdida de entropía cruzada

$$\ell(y, f(x)) = -\log \left(\frac{\exp(f_y(x) + \tau \log \pi_y)}{\sum_{j=1}^C \exp(f_j(x) + \tau \log \pi_j)} \right).$$

Por tanto, durante la propagación hacia adelante se calculan los logits $g_y(x)$, se aplica la función softmax y posteriormente se evalúa la pérdida de entropía cruzada.

Desde un punto de vista bayesiano, esto equivale a modificar la verosimilitud del modelo. Si θ denota los parámetros y $D = \{(x_i, y_i)\}_{i=1}^N$ el conjunto de datos, entonces

$$y_i \mid x_i, \theta \sim \text{Categorical}(\text{softmax}(f(x_i; \theta) + \tau \log \pi)),$$

donde

$$\pi_y = \frac{N_y}{N}$$

es la proporción de observaciones pertenecientes a la clase y . En consecuencia, la posterior viene dada por

$$p(\theta \mid D) \propto p(\theta) \prod_{i=1}^N p(y_i \mid x_i, \theta),$$

de modo que la única diferencia con la regresión logística bayesiana estándar es la aparición del término constante $\tau \log \pi_y$ dentro de los logits.