

Estadística Bayesiana y MCMC

Yael Rene Santiago Cruz

Introducción

Supongamos que $X \sim \text{Exp}(\lambda)$ y que, condicionado a $X = x$, se tiene

$$Y \mid X = x \sim \text{Poisson}(x).$$

Un cuestionamiento natural es: ¿cómo se distribuyen Y y $X \mid Y = y$?

Usando probabilidad condicional, sabemos que

$$f_{X|Y}(x \mid y) = \frac{f_{X,Y}(x, y)}{f_Y(y)} = \frac{P(Y = y \mid X = x) f_X(x)}{f_Y(y)}.$$

Como $f_Y(y)$ no depende de x , podemos escribir

$$f_{X|Y}(x \mid y) \propto P(Y = y \mid X = x) f_X(x).$$

Sustituyendo las distribuciones:

$$f_{X|Y}(x \mid y) \propto \frac{e^{-x} x^y}{y!} \cdot \lambda e^{-\lambda x} = \frac{\lambda}{y!} x^y e^{-(1+\lambda)x}.$$

Por lo tanto,

$$f_{X|Y}(x \mid y) \propto x^y e^{-(1+\lambda)x},$$

que corresponde al kernel de una distribución Gamma. Así,

$$X \mid Y = y \sim \text{Gamma}(y + 1, 1 + \lambda).$$

Ahora, usando probabilidad total:

$$P_Y(y) = \int_0^\infty P(Y = y \mid X = x) f_X(x) dx.$$

Sustituyendo:

$$\begin{aligned}
P_Y(y) &= \int_0^\infty \frac{e^{-x} x^y}{y!} \lambda e^{-\lambda x} dx \\
&= \frac{\lambda}{y!} \int_0^\infty x^y e^{-(1+\lambda)x} dx \\
&= \frac{\lambda}{y!} \cdot \frac{y!}{(1+\lambda)^{y+1}} \\
&= \frac{\lambda}{1+\lambda} \left(\frac{1}{1+\lambda} \right)^y \\
&= \frac{\lambda}{1+\lambda} \left(1 - \frac{\lambda}{1+\lambda} \right)^y.
\end{aligned}$$

Por lo tanto,

$$Y \sim \text{Geom} \left(\frac{\lambda}{1+\lambda} \right).$$

Estadística Bayesiana

En estadística bayesiana, suponemos que contamos con una muestra aleatoria $\{X_i\}_{i=1}^n$ y un parámetro θ , tales que

$$X_i \mid \theta \stackrel{\text{i.i.d.}}{\sim} p(X \mid \theta), \quad \theta \sim p(\theta),$$

donde $p(\theta)$ se denomina distribución *a priori*.

El objetivo es encontrar la distribución posterior

$$p(\theta \mid X_1, \dots, X_n),$$

la cual, por la regla de Bayes, satisface

$$p(\theta \mid X_1, \dots, X_n) = \frac{L(X_1, \dots, X_n \mid \theta) p(\theta)}{p(X_1, \dots, X_n)} \propto L(X_1, \dots, X_n \mid \theta) p(\theta).$$

Como las observaciones son independientes:

$$L(X_1, \dots, X_n \mid \theta) = \prod_{i=1}^n p(X_i \mid \theta).$$

Por lo tanto,

$$p(\theta \mid X_1, \dots, X_n) \propto \left(\prod_{i=1}^n p(X_i \mid \theta) \right) p(\theta).$$

Ejemplo: modelo normal-normal

Supongamos que

$$\theta \sim \mathcal{N}(\mu_0, \sigma_0^2), \quad \text{y} \quad X_i | \theta \sim \mathcal{N}(\theta, \sigma^2),$$

con σ^2 conocida.

Entonces,

$$p(\theta | X_1, \dots, X_n) \propto \prod_{i=1}^n \exp \left\{ -\frac{(X_i - \theta)^2}{2\sigma^2} \right\} \exp \left\{ -\frac{(\theta - \mu_0)^2}{2\sigma_0^2} \right\}.$$

Agrupando términos:

$$p(\theta | X_1, \dots, X_n) \propto \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (X_i - \theta)^2 - \frac{(\theta - \mu_0)^2}{2\sigma_0^2} \right\}.$$

Completando el cuadrado, se obtiene que la posterior es normal:

$$\theta | X_1, \dots, X_n \sim \mathcal{N}(\mu_n, \sigma_n^2),$$

donde

$$\mu_n = \frac{n\sigma_0^2 \bar{X}_n + \sigma^2 \mu_0}{n\sigma_0^2 + \sigma^2}, \quad \sigma_n^2 = \frac{\sigma^2 \sigma_0^2}{n\sigma_0^2 + \sigma^2}.$$

Observamos que

$$\lim_{n \rightarrow \infty} \mu_n = \bar{X}_n, \quad \lim_{n \rightarrow \infty} \sigma_n^2 = 0.$$

Esto implica que

$$p(\theta | X_1, \dots, X_n) \xrightarrow{d} \delta_{\bar{X}_n},$$

donde $\delta_{\bar{X}_n}$ es la delta de Dirac centrada en $\bar{X}_n$.

En este ejemplo se obtuvo una forma analítica para la distribución posterior. Sin embargo, en muchos casos esto no es posible, por lo que es necesario recurrir a métodos numéricos como los algoritmos MCMC.

Elección de distribuciones a priori

En estadística bayesiana, la elección de la distribución a priori $p(\theta)$ es un paso fundamental, ya que refleja la información previa disponible sobre el parámetro. Existen diferentes enfoques para definirla, entre los más importantes se encuentran las priors no informativas, las priors conjugadas y la prior de Jeffreys.

Priors no informativas

Las priors no informativas (o débiles) buscan introducir la menor cantidad posible de información previa, permitiendo que los datos dominen la inferencia.

Prior uniforme impropia

$$p(\theta) \propto 1, \quad \theta \in \mathbb{R}.$$

No favorece ningún valor, pero no es invariante ante cambios de parametrización.

Prior uniforme en escala logarítmica

 Para parámetros positivos:

$$p(\theta) \propto \frac{1}{\theta}, \quad \theta > 0.$$

Equivale a ser uniforme en $\log \theta$, por lo que es invariante a cambios de escala.

Ejemplo: Si $X|\theta \sim \text{Exp}(\theta)$, es común usar $p(\theta) \propto 1/\theta$.

Prior no informativa para varianza

 En el modelo normal:

$$X_i \sim \mathcal{N}(\mu, \sigma^2),$$

una elección clásica es:

$$p(\mu, \sigma^2) \propto \frac{1}{\sigma^2}, \quad \text{o equivalentemente} \quad p(\sigma) \propto \frac{1}{\sigma}.$$

Esta prior refleja ignorancia sobre la escala.

Límite de priors conjugadas Algunas priors no informativas aparecen como límites de priors conjugadas.

Ejemplo: Si $\theta \sim \text{Beta}(\alpha, \beta)$ y $\alpha, \beta \rightarrow 0$, se obtiene formalmente

$$p(\theta) \propto \theta^{-1}(1-\theta)^{-1}.$$

Priors débilmente informativas En la práctica, se usan priors con gran varianza para estabilizar la inferencia:

$$\theta \sim \mathcal{N}(0, \tau^2), \quad \text{con } \tau^2 \text{ grande.}$$

Ejemplo:

$$\theta \sim \mathcal{N}(0, 10^2).$$

Priors conjugadas

Una prior conjugada es aquella que, al combinarse con la verosimilitud, produce una posterior en la misma familia de distribuciones.

Ejemplo: Si

$$X_i | \theta \sim \mathcal{N}(\theta, \sigma^2), \quad \theta \sim \mathcal{N}(\mu_0, \sigma_0^2),$$

entonces la posterior también es normal:

$$\theta \mid X_1, \dots, X_n \sim \mathcal{N}(\mu_n, \sigma_n^2),$$

como se mostró anteriormente.

Otro ejemplo clásico es:

$$Y \mid \theta \sim \text{Binomial}(n, \theta), \quad \theta \sim \text{Beta}(\alpha, \beta),$$

lo cual implica

$$\theta \mid Y \sim \text{Beta}(\alpha + Y, \beta + n - Y).$$

Prior de Jeffreys

La prior de Jeffreys es una prior objetiva definida a partir de la información de Fisher:

$$p(\theta) \propto \sqrt{I(\theta)},$$

donde $I(\theta)$ es la información de Fisher:

$$I(\theta) = \mathbb{E} \left[\left(\frac{\partial}{\partial \theta} \log p(X \mid \theta) \right)^2 \right].$$

Esta prior es invariante ante reparametrizaciones, lo que la hace especialmente atractiva.

Ejemplo: Si $X \sim \text{Bernoulli}(\theta)$, entonces

$$I(\theta) = \frac{1}{\theta(1-\theta)},$$

por lo que la prior de Jeffreys es

$$p(\theta) \propto \frac{1}{\sqrt{\theta(1-\theta)}},$$

que corresponde a una distribución Beta:

$$\theta \sim \text{Beta}\left(\frac{1}{2}, \frac{1}{2}\right).$$

Teorema fundamental de decisión bayesiana

En el marco de la teoría de decisión, el objetivo no es únicamente estimar un parámetro, sino tomar decisiones óptimas bajo incertidumbre. Para ello, se introduce una función de pérdida

$$L(\theta, a),$$

que mide el costo de tomar la acción a cuando el verdadero valor del parámetro es θ .

Riesgo y riesgo bayesiano

Dado un estimador (o regla de decisión) $\delta(X)$, se define el riesgo como

$$R(\theta, \delta) = \mathbb{E}[L(\theta, \delta(X)) \mid \theta].$$

En el enfoque bayesiano, se considera además una prior $p(\theta)$ y se define el riesgo bayesiano:

$$r(\delta) = \mathbb{E}[L(\theta, \delta(X))] = \int R(\theta, \delta) p(\theta) d\theta.$$

Teorema fundamental

El teorema fundamental de la decisión bayesiana establece que el estimador bayesiano $\delta^*(X)$ minimiza el riesgo bayesiano si y solo si, para cada valor observado $X = x$, minimiza el riesgo posterior:

$$\delta^*(x) = \arg \min_a \mathbb{E}[L(\theta, a) \mid X = x].$$

Es decir, el problema global de optimización se reduce a minimizar una esperanza condicional con respecto a la distribución posterior:

$$p(\theta \mid X = x).$$

Pérdida cuadrática

Si

$$L(\theta, a) = (\theta - a)^2,$$

entonces, definiendo $f(a) = \mathbb{E}[(\theta - a)^2 \mid X = x]$, tenemos que

$$f'(a) = -2\mathbb{E}[\theta - a \mid X = x] \Rightarrow f'(a) = 0 \Leftrightarrow f'(a) = \mathbb{E}[\theta \mid X = x]$$

entonces el estimador bayesiano es la media posterior:

$$\delta^*(x) = \mathbb{E}[\theta \mid X = x].$$

Pérdida absoluta

Si

$$L(\theta, a) = |\theta - a|,$$

podemos definir $f(a) = \mathbb{E}[|\theta - a| \mid X = x]$ y por lo tanto

$$\begin{aligned}
f(a) &= \int_{-\infty}^{\infty} |\theta - a| p(\theta | x) d\theta \\
&= \int_{-\infty}^a |\theta - a| p(\theta | x) d\theta + \int_a^{\infty} |\theta - a| p(\theta | x) d\theta \\
&= - \int_{-\infty}^a (\theta - a) p(\theta | x) d\theta + \int_a^{\infty} (\theta - a) p(\theta | x) d\theta \\
&= - \int_{-\infty}^a \theta p(\theta | x) d\theta + \int_a^{\infty} \theta p(\theta | x) d\theta + a(F(a | x) - S(a | x)) \\
&= - \int_{-\infty}^a \theta p(\theta | x) d\theta + \int_a^{\infty} \theta p(\theta | x) d\theta + a(2F(a | x) - 1),
\end{aligned}$$

y utilizando el teorema fundamental del calculo obtenemos que

$$\begin{aligned}
f'(a) &= -2ap(a | x) + 2ap(a | \theta) + 2F(a | x) - 1 \\
&= 2F(a | x) - 1
\end{aligned}$$

$\Rightarrow f'(a) = 0 \Leftrightarrow F(a | x) = \frac{1}{2}$, entonces el estimador bayesiano es la mediana posterior:

$$\delta^*(x) = \text{mediana}(\theta | X = x).$$

Pérdida 0-1

Si

$$L(\theta, a) = \begin{cases} 0, & \text{si } a = \theta, \\ 1, & \text{si } a \neq \theta, \end{cases}$$

entonces el estimador bayesiano es la moda posterior (MAP):

$$\delta^*(x) = \arg \max_{\theta} p(\theta | X = x).$$

Intervalos en estadística bayesiana

En el enfoque bayesiano, la incertidumbre sobre los parámetros se describe mediante su distribución posterior. A partir de esta, es posible construir intervalos que cuantifican la incertidumbre de manera probabilística.

Intervalos de credibilidad

Un intervalo de credibilidad para un parámetro θ es un intervalo $[a, b]$ tal que:

$$\mathbb{P}(\theta \in [a, b] | x) = 1 - \alpha.$$

A diferencia de los intervalos de confianza clásicos, este resultado se interpreta directamente como una probabilidad sobre el parámetro dado los datos observados.

Tipos de intervalos

Existen varias formas de construir intervalos de credibilidad:

- **Intervalo central:** Se define a partir de cuantiles de la distribución posterior:

$$[q_{\alpha/2}, q_{1-\alpha/2}].$$

- **Intervalo de máxima densidad (HPD):** Es el intervalo más corto que contiene una probabilidad $1 - \alpha$, es decir, aquel donde la densidad posterior es mayor.

Intervalos predictivos

Además de los parámetros, es posible construir intervalos para observaciones futuras. Si x^* es una nueva observación, independiente de una muestra $x_1, \dots, x_n$ condicionada al parámetro θ , es decir, $p(x^* | x_1, \dots, x_n, \theta) = p(x^* | \theta)$. Entonces su distribución predictiva está dada por:

$$p(x^* | x_1, \dots, x_n) = \int p(x^* | \theta) p(\theta | x_1, \dots, x_n) d\theta.$$

Un intervalo predictivo es un intervalo que contiene x^* con probabilidad $1 - \alpha$ bajo esta distribución.

Los intervalos bayesianos proporcionan una interpretación más directa que los intervalos de confianza clásicos, ya que permiten hacer afirmaciones probabilísticas sobre los parámetros y predicciones, incorporando de manera natural la incertidumbre del modelo.

Modelos Lineales Generalizados Bayesianos

Familia exponencial

Una distribución pertenece a la familia exponencial si puede escribirse como:

$$p(y | \theta) = h(y) \exp \{ \langle \eta(\theta), T(y) \rangle - A(\theta) \},$$

donde:

- $\eta(\theta) \in \mathbb{R}^d$ es el parámetro natural,
- $T(y) \in \mathbb{R}^d$ es la estadística suficiente,
- $\langle \cdot, \cdot \rangle$ denota el producto punto,
- $A(\theta)$ es la función log-partición,
- $h(y)$ es una función base.

Ejemplo: distribución normal

Sea

$$Y \sim \mathcal{N}(\mu, \sigma^2).$$

Su densidad puede escribirse como:

$$p(y \mid \mu, \sigma^2) = \exp \left\{ \frac{\mu}{\sigma^2} y - \frac{1}{2\sigma^2} y^2 - \left(\frac{\mu^2}{2\sigma^2} + \frac{1}{2} \log(2\pi\sigma^2) \right) \right\}.$$

Por lo tanto:

$$T(y) = (y, y^2), \quad \eta_1 = \frac{\mu}{\sigma^2}, \quad \eta_2 = -\frac{1}{2\sigma^2}.$$

Ejemplo: distribución Bernoulli

Sea

$$Y \sim \text{Bernoulli}(p).$$

Su función de masa es:

$$p(y \mid p) = p^y (1-p)^{1-y}.$$

Esto puede reescribirse como:

$$p(y \mid p) = \exp \left\{ y \log \left(\frac{p}{1-p} \right) + \log(1-p) \right\}.$$

Por lo tanto:

$$T(y) = y, \quad \eta = \log \left(\frac{p}{1-p} \right), \quad A(\theta) = -\log(1-p).$$

La Tabla 1 muestra diferentes distribuciones pertenecientes a la familia exponencial.

Distribución	$T(y)$	$\eta(\theta)$	$A(\theta)$	$h(y)$
Normal	(y, y^2)	$\left(\frac{\mu}{\sigma^2}, -\frac{1}{2\sigma^2} \right)$	$\frac{\mu^2}{2\sigma^2} + \frac{1}{2} \log(2\pi\sigma^2)$	1
Bernoulli	y	$\log \left(\frac{p}{1-p} \right)$	$-\log(1-p)$	1
Poisson	y	$\log(\lambda)$	λ	$\frac{1}{y!}$
Gamma	y	$-\beta$	$-\alpha \log \beta$	$y^{\alpha-1}$

Tabla 1: Componentes de la familia exponencial para distribuciones comunes

Modelos lineales generalizados (GLM)

Un modelo lineal generalizado consta de tres componentes:

- **Componente aleatoria:** Y_i sigue una distribución de la familia exponencial.

- **Componente sistemática:**

$$\eta_i = X_i^\top \beta.$$

- **Función liga:**

$$g(\mu_i) = \eta_i, \quad \mu_i = \mathbb{E}[Y_i \mid X_i].$$

En el enfoque bayesiano:

$$\beta \sim p(\beta).$$

La posterior es:

$$p(\beta \mid y) \propto \left(\prod_{i=1}^n p(y_i \mid X_i, \beta) \right) p(\beta).$$

En general, no tiene forma cerrada y se requieren métodos como MCMC. La Tabla 2 muestra los componentes de diferentes GLM.

Modelo	Distribución	μ	$g(\mu)$	Soporte
Regresión lineal	$\mathcal{N}(\mu, \sigma^2)$	μ	μ	$\mathbb{R}$
Logística	Bernoulli(p)	p	$\log\left(\frac{p}{1-p}\right)$	$\{0, 1\}$
Poisson	Poisson(λ)	λ	$\log(\lambda)$	$\mathbb{N}$
Gamma	Gamma(α, β)	$\frac{\alpha}{\beta}$	$\frac{1}{\mu}$	$\mathbb{R}^+$

Tabla 2: Modelos lineales generalizados: distribución, media, función liga y soporte

Una distribución que no pertenece a la familia exponencial es la distribución Laplace, cuya función de densidad está dada por

$$p(y \mid \mu, b) = \frac{1}{2b} \exp\left\{-\frac{|y - \mu|}{b}\right\}.$$

A pesar de esto, es posible construir un modelo de regresión lineal basado en esta distribución. En particular, consideremos

$$Y_i \mid X_i, \beta, b \sim \text{Laplace}(X_i^\top \beta, b).$$

En este caso, se cumple que

$$\mathbb{E}[Y_i \mid X_i, \beta, b] = X_i^\top \beta,$$

por lo que se puede definir la función g como la identidad:

$$g(\mu_i) = \mu_i.$$

Este modelo corresponde a la regresión por mínimos absolutos, la cual es más robusta a valores atípicos en comparación con la regresión lineal clásica basada en errores normales.

Métodos de Cadenas de Márkov Monte Carlo (MCMC)

Motivación

Sea f_k el kernel de una función de densidad de probabilidad f en $\mathbb{R}^d$, es decir, f_k es una función positiva tal que

$$0 < \int_{\mathbb{R}^d} f_k(x) dx < \infty.$$

Esta función induce una medida de probabilidad dada por:

$$\mathbb{P}(X \in A) = \frac{\int_A f_k(x) dx}{\int_{\mathbb{R}^d} f_k(x) dx}, \quad A \in \mathcal{B}(\mathbb{R}^d).$$

Nuestro objetivo es estimar cantidades de la forma:

$$\mathbb{E}_f[h(X)] = \frac{\int_{\mathbb{R}^d} h(x) f_k(x) dx}{\int_{\mathbb{R}^d} f_k(x) dx},$$

para funciones $h : \mathbb{R}^d \rightarrow \mathbb{R}$.

Cuando f_k es complicada, puede ser difícil generar muestras independientes con esta distribución.

Idea de MCMC

Los métodos MCMC consisten en construir una cadena de Márkov $\{X_n\}_{n \geq 0}$ con valores en $\mathbb{R}^d$ que sea fácil de simular y cuya distribución estacionaria sea f .

Es decir, buscamos un kernel de transición $P(x, dy)$ tal que:

$$\int_{\mathbb{R}^d} P(x, A) f(x) dx = \int_A f(x) dx, \quad A \in \mathcal{B}(\mathbb{R}^d).$$

Si generamos una trayectoria larga de la cadena:

$$X_0, X_1, \dots, X_n,$$

con n grande, entonces:

$$\mathcal{L}(X_n) \approx f.$$

En la práctica, no se reinicia la cadena, sino que se utiliza un estimador del tipo:

$$\frac{1}{m-b} \sum_{i=b+1}^m h(X_i),$$

donde b es el periodo de quemado o *burn-in*.

Si b es suficientemente grande, se espera que:

$$\mathcal{L}(X_b) \approx f.$$

Aunque las muestras no son independientes, este estimador es consistente.

Medida invariante

Decimos que una medida π es invariante para un kernel de transición P si:

$$\pi(B) = \int P(x, B) \pi(dx), \quad B \in \mathcal{B}(X).$$

Si además π es una medida de probabilidad, se denomina distribución invariante.

Balance detallado

Sea $P(x, dy) = p(x, y) dy$ un kernel de transición. Decimos que satisface balance detallado si existe una función π tal que:

$$\pi(x) p(x, y) = \pi(y) p(y, x).$$

Teorema

Si un kernel de transición satisface la condición de balance detallado con respecto a una densidad π , entonces π es una distribución invariante de la cadena de Márkov.

Algoritmo de Metropolis-Hastings

Sea f_k el kernel de una densidad objetivo y $Q(x, dy)$ un kernel de transición de propuesta.

Dado el estado actual X_{n-1} :

1. Generar $Y_n \sim Q(X_{n-1}, \cdot)$ y $U \sim \text{Uniforme}(0, 1)$.

2. Aceptar Y_n con probabilidad

$$\alpha(X_{n-1}, Y_n) = \min \left\{ 1, \frac{f_k(Y_n) Q(Y_n, X_{n-1})}{f_k(X_{n-1}) Q(X_{n-1}, Y_n)} \right\}.$$

3. Definir

$$X_n = \begin{cases} Y_n, & \text{si } U \leq \alpha(X_{n-1}, Y_n), \\ X_{n-1}, & \text{en otro caso.} \end{cases}$$

En la práctica, puede ser numéricamente más estable trabajar en escala logarítmica al calcular la probabilidad de aceptación. En lugar de comparar directamente con α , se puede utilizar el siguiente criterio equivalente:

$$\log(U) \leq \min \{0, \log f_k(Y_n) + \log q(Y_n, X_{n-1}) - \log f_k(X_{n-1}) - \log q(X_{n-1}, Y_n)\}.$$

El uso de logaritmos evita problemas de desbordamiento numérico y mejora la estabilidad computacional, especialmente cuando se trabajan con densidades muy pequeñas.

Elección del kernel

La elección del kernel de propuesta $q(x, y)$ es fundamental para el desempeño del algoritmo de Metropolis-Hastings, ya que afecta directamente la tasa de aceptación y la eficiencia de la exploración del espacio de estados.

Metropolis-Hastings simétrico

Si el kernel de propuesta es simétrico, es decir,

$$q(x, y) = q(y, x),$$

entonces la probabilidad de aceptación se simplifica a:

$$\alpha(x, y) = \min \left\{ 1, \frac{f_k(y)}{f_k(x)} \right\}.$$

Este caso corresponde al algoritmo de Metropolis clásico.

Metropolis-Hastings con caminata aleatoria

Un caso particular importante es cuando el kernel depende únicamente de la diferencia $y - x$:

$$q(x, y) = q(y - x).$$

Ejemplos comunes incluyen:

$$Q(x, \cdot) = \mathcal{N}(x, \sigma^2) \quad \text{y} \quad Q(x, \cdot) = \text{Uniforme}(x - 1, x + 1).$$

Algoritmo de Langevin

El algoritmo de Langevin incorpora información del gradiente de la densidad objetivo para guiar la propuesta. Para $\delta > 0$ pequeño, se define:

$$Y_{n+1} \sim \mathcal{N} \left(X_n + \frac{\delta}{2} \nabla \log f(X_n), \delta I \right).$$

Este método permite una exploración más eficiente del espacio de parámetros, especialmente en dimensiones altas, al aprovechar la geometría local de la distribución objetivo.

Estimación del precio de una opción call

El objetivo es estimar el precio de una opción call, el cual puede escribirse como:

$$C = e^{-rt} \mathbb{E} [\max(S_T - K, 0)].$$

Bajo el modelo de Black-Scholes, el precio del activo en el tiempo T se expresa como:

$$S_T = S_0 \exp \left((r - \frac{1}{2}\sigma^2)T + \sigma\sqrt{T} Z \right),$$

donde $Z \sim \mathcal{N}(0, 1)$.

Por lo tanto, el precio puede escribirse como:

$$C = e^{-rt} \int \text{payoff}(z) \phi(z) dz,$$

donde $\phi(z)$ es la densidad de la normal estándar.

Para reducir la varianza del estimador, se introduce la distribución de mínima varianza:

$$\pi(z) = \frac{\text{payoff}(z) \phi(z)}{c},$$

donde c es la constante de normalización dada por:

$$c = \int \text{payoff}(z) \phi(z) dz.$$

En el caso de la opción call, esta constante puede calcularse explícitamente como:

$$c = \sqrt{2\pi} \left[S_0 e^{rT} \Phi(\theta - \sigma\sqrt{T}) - K \Phi(\theta) \right],$$

donde Φ es la función de distribución de la normal estándar y

$$\theta = \frac{\log(K/S_0) - (r - \frac{1}{2}\sigma^2)T}{\sigma\sqrt{T}}.$$

Esta distribución concentra masa en las regiones donde el payoff es significativo.

Sin embargo, no es posible muestrear directamente de π , por lo que se utiliza el algoritmo de Metropolis-Hastings.

Construcción de la cadena

Se construye una cadena de Márkov $\{Z_n\}$ cuya distribución estacionaria es $\pi(z)$.

Utilicemos un kernel de propuesta de tipo caminata aleatoria:

$$Y = X_n + \epsilon, \quad \epsilon \sim \mathcal{N}(0, \sigma^2).$$

La probabilidad de aceptación está dada por:

$$\alpha(x, y) = \min \left\{ 1, \frac{\pi(y)}{\pi(x)} \right\}.$$

Dado que

$$\pi(z) \propto \text{payoff}(z) \phi(z),$$

se obtiene:

$$\alpha(x, y) = \min \left\{ 1, \frac{\text{payoff}(y) \phi(y)}{\text{payoff}(x) \phi(x)} \right\}.$$

En la práctica, se trabaja en escala logarítmica:

$$\log \alpha = \log \text{payoff}(y) + \log \phi(y) - \log \text{payoff}(x) - \log \phi(x).$$

Una vez generadas las muestras $\{Z_i\}_{i=1}^m$ de la cadena (después del periodo de burn-in), se estima el precio mediante:

$$\hat{C} = e^{-rt} \frac{1}{m} \sum_{i=1}^m \frac{\text{payoff}(Z_i) \phi(Z_i)}{g(Z_i)},$$

donde g es la distribución de mínima varianza normalizada.

Regresión Lineal Bayesiana

Sea $y \in \mathbb{R}^n$ y $X \in \mathbb{R}^{n \times d}$. Se considera el modelo:

$$y \mid X, \beta, \sigma^2 \sim \mathcal{N}(X\beta, \sigma^2 I_n)$$

$$\beta \sim \mathcal{N}(0, \tau^2 I_d)$$

$$\sigma^2 \sim \text{Inverse-Gamma}(a, b) = \frac{b^a}{\Gamma(a)} (\sigma^2)^{-(a+1)} \exp \left(-\frac{b}{\sigma^2} \right), \quad \sigma^2 > 0.$$

Entonces, el logaritmo de la posterior es

$$\log(p(\beta, \sigma^2 \mid y, X)) \propto \log(p(y \mid X, \beta, \sigma^2)) + \log(p(\beta)) + \log(p(\sigma^2)),$$

en donde

$$\log p(y \mid X, \beta, \sigma^2) = -\frac{n}{2} \log \sigma^2 - \frac{1}{2\sigma^2} \|y - X\beta\|^2,$$

$$\log p(\beta) = -\frac{1}{2\tau^2} \|\beta\|^2$$

y

$$\log p(\sigma^2) = -(a+1) \log \sigma^2 - \frac{b}{\sigma^2}$$

Como se propone un kernel de transición normal, es necesario realizar una transformación sobre el parámetro σ^2 , ya que la distribución normal tiene soporte en todo $\mathbb{R}$, mientras que $\sigma^2 > 0$.

Para ello, definimos el cambio de variable:

$$\eta = \log(\sigma^2),$$

de modo que $\eta \in \mathbb{R}$.

Aplicando la fórmula de cambio de variable, la densidad inducida sobre η satisface:

$$p(\eta) = p(\sigma^2) \left| \frac{d\sigma^2}{d\eta} \right| = p(\sigma^2) e^\eta,$$

y por lo tanto,

$$\log p(\eta) = \log p(\sigma^2) + \eta.$$

En consecuencia, la log-posterior en términos de (β, η) está dada por:

$$\log p(\beta, \eta \mid y) = -\left(\frac{n}{2} + a\right) \eta - \frac{1}{2e^\eta} \|y - X\beta\|^2 - \frac{b}{e^\eta} - \frac{1}{2\tau^2} \|\beta\|^2.$$

Algoritmo Metropolis-Hastings

Bajo las consideraciones anteriores, el algoritmo de Metropolis-Hastings para muestrear de la distribución posterior $p(\beta, \eta \mid y)$ queda de la siguiente manera:

1. Inicializar $\beta^{(0)}$ y $\eta^{(0)}$.
2. Para $t = 1, \dots, T$:

a) Generar propuestas mediante un paseo aleatorio Gaussiano:

$$\beta' = \beta^{(t-1)} + \epsilon_\beta, \quad \epsilon_\beta \sim \mathcal{N}(0, s^2 I)$$

$$\eta' = \eta^{(t-1)} + \epsilon_\eta, \quad \epsilon_\eta \sim \mathcal{N}(0, s^2)$$

b) Calcular la razón de aceptación:

$$\alpha = \min \left(1, \frac{p(\beta', \eta' | y)}{p(\beta^{(t-1)}, \eta^{(t-1)} | y)} \right)$$

o equivalentemente en escala logarítmica:

$$\log \alpha = \log p(\beta', \eta' | y) - \log p(\beta^{(t-1)}, \eta^{(t-1)} | y)$$

c) Generar $u \sim \mathcal{U}(0, 1)$ y aceptar la propuesta si:

$$\log u \leq \log \alpha.$$

d) Actualizar:

$$(\beta^{(t)}, \eta^{(t)}) = \begin{cases} (\beta', \eta'), & \text{si se acepta,} \\ (\beta^{(t-1)}, \eta^{(t-1)}), & \text{en otro caso.} \end{cases}$$

Predicción, error e intervalos de credibilidad

Una vez obtenidas muestras $\{(\beta^{(s)}, \sigma^{2(s)})\}_{s=1}^S$ de la distribución posterior, es posible realizar inferencia predictiva mediante simulación Monte Carlo.

Para cada muestra posterior, la distribución predictiva está dada por:

$$y^{(s)} \sim \mathcal{N}(X\beta^{(s)}, \sigma^{2(s)}I),$$

lo que permite generar realizaciones de la variable respuesta incorporando tanto la incertidumbre en los parámetros como el ruido inherente del modelo.

La media predictiva puede aproximarse mediante:

$$\mathbb{E}[y | X] \approx \frac{1}{S} \sum_{s=1}^S X\beta^{(s)},$$

la cual corresponde a un estimador de Monte Carlo de la esperanza posterior.

Por otro lado, para evaluar el desempeño predictivo del modelo, se puede considerar el error cuadrático medio (MSE) asociado a cada muestra:

$$\text{MSE}^{(s)} = \frac{1}{n} \sum_{i=1}^n \left(y_i^{(s)} - y_i \right)^2,$$

lo que induce una distribución posterior del error que refleja la incertidumbre en la calidad de las predicciones.

Finalmente, es posible construir intervalos de credibilidad para cualquier cantidad de interés Z (por ejemplo, predicciones o el MSE) a partir de los cuantiles empíricos de las muestras:

$$[q_{\alpha/2}(Z), q_{1-\alpha/2}(Z)].$$

Estos intervalos permiten cuantificar la incertidumbre asociada a las predicciones y a las métricas de desempeño del modelo en un marco completamente bayesiano.

Regresión Logística Bayesiana

Sea $y \in \{0, 1\}^n$ y $X \in \mathbb{R}^{n \times d}$. Se considera el modelo:

$$y_i \mid X, \beta \sim \text{Bernoulli}(p_i), \quad \text{con } p_i = \sigma(x_i^T \beta),$$

donde $\sigma(t) = \frac{1}{1+e^{-t}}$ es la función sigmoide.

Como prior para los parámetros se asume:

$$\beta \sim \mathcal{N}(0, \tau^2 I_d).$$

Entonces, el logaritmo de la posterior es

$$\log(p(\beta \mid y, X)) \propto \log(p(y \mid X, \beta)) + \log(p(\beta)),$$

en donde

$$\log p(y \mid X, \beta) = \sum_{i=1}^n [y_i \log \sigma(x_i^T \beta) + (1 - y_i) \log(1 - \sigma(x_i^T \beta))],$$

y

$$\log p(\beta) = -\frac{1}{2\tau^2} \|\beta\|^2.$$

Algoritmo Metropolis-Hastings

Bajo las consideraciones anteriores, el algoritmo de Metropolis-Hastings para muestrear de la distribución posterior $p(\beta \mid y, X)$ queda de la siguiente manera:

1. Inicializar $\beta^{(0)}$.
2. Para $t = 1, \dots, T$:

a) Generar propuestas mediante un paseo aleatorio Gaussiano:

$$\beta' = \beta^{(t-1)} + \epsilon, \quad \epsilon \sim \mathcal{N}(0, s^2 I_d).$$

b) Calcular la razón de aceptación:

$$\alpha = \min \left(1, \frac{p(\beta' | y)}{p(\beta^{(t-1)} | y)} \right),$$

o equivalentemente en escala logarítmica:

$$\log \alpha = \log p(\beta' | y) - \log p(\beta^{(t-1)} | y).$$

c) Generar $u \sim \mathcal{U}(0, 1)$ y aceptar la propuesta si:

$$\log u \leq \log \alpha.$$

d) Actualizar:

$$\beta^{(t)} = \begin{cases} \beta', & \text{si se acepta,} \\ \beta^{(t-1)}, & \text{en otro caso.} \end{cases}$$

Métricas de Evaluación

Dado un nuevo conjunto de datos (X, y) , se pueden evaluar distintas métricas a partir de muestras de la posterior.

Probabilidades predictivas Para cada muestra $\beta^{(s)}$, se calculan las probabilidades:

$$p^{(s)} = \sigma(X\beta^{(s)}).$$

Accuracy Dado un umbral $t \in (0, 1)$ (típicamente $t = 0.5$), se define la predicción:

$$\hat{y}_i^{(s)} = \mathbb{I} \left(p_i^{(s)} \geq t \right).$$

El accuracy para la muestra s es:

$$\text{Accuracy}^{(s)} = \frac{1}{n} \sum_{i=1}^n \mathbb{I} \left(y_i = \hat{y}_i^{(s)} \right).$$

Esto induce una distribución posterior del accuracy.

AUC (Área bajo la curva ROC) Para cada muestra $\beta^{(s)}$, se consideran las probabilidades $p^{(s)}$ como scores. El AUC mide la capacidad de discriminación del modelo:

$$\text{AUC}^{(s)} = \mathbb{P} \left(p_i^{(s)} > p_j^{(s)} \mid y_i = 1, y_j = 0 \right).$$

En la práctica, se calcula usando la curva ROC, obteniendo así una distribución posterior del AUC.

Deviance La deviance (log-loss) para cada muestra se define como:

$$D^{(s)} = -\frac{1}{n} \sum_{i=1}^n \left[y_i \log p_i^{(s)} + (1 - y_i) \log(1 - p_i^{(s)}) \right].$$

Esta cantidad mide el ajuste del modelo, donde valores más pequeños indican mejor ajuste.

Inferencia posterior A partir de las muestras $\{\beta^{(s)}\}$, se pueden estimar:

- Media posterior de las métricas (accuracy, AUC, deviance),
- Intervalos de credibilidad,
- Densidades posteriores.

Regresión Poisson Bayesiana

Sea $y \in \mathbb{N}^n$ y $X \in \mathbb{R}^{n \times d}$. Se considera el modelo:

$$y_i \mid X, \beta \sim \text{Poisson}(\lambda_i), \quad \text{con } \lambda_i = \exp(x_i^T \beta).$$

Equivalentemente,

$$y \mid X, \beta \sim \text{Poisson}(\exp(X\beta)).$$

Como prior para los parámetros se asume:

$$\beta \sim \mathcal{N}(0, \tau^2 I_d).$$

Entonces, el logaritmo de la posterior es

$$\log(p(\beta \mid y, X)) \propto \log(p(y \mid X, \beta)) + \log(p(\beta)),$$

en donde

$$\log p(y \mid X, \beta) = \sum_{i=1}^n [y_i(x_i^T \beta) - \exp(x_i^T \beta) - \log(y_i!)] ,$$

y

$$\log p(\beta) = -\frac{1}{2\tau^2} \|\beta\|^2.$$

Por lo tanto, la log-posterior queda dada por

$$\log p(\beta \mid y, X) = \sum_{i=1}^n [y_i(x_i^T \beta) - \exp(x_i^T \beta)] - \frac{1}{2\tau^2} \|\beta\|^2,$$

ignorando términos constantes.

Media predictiva Para cada muestra $\beta^{(s)}$, se tiene:

$$\lambda^{(s)} = \exp(X\beta^{(s)}),$$

que corresponde a la media de la distribución Poisson.

Deviance La deviance para el modelo Poisson se define como:

$$D^{(s)} = \frac{1}{n} \sum_{i=1}^n \left[y_i \log \left(\frac{y_i}{\lambda_i^{(s)}} \right) - (y_i - \lambda_i^{(s)}) \right],$$

donde por continuidad se toma $y_i \log(y_i/\lambda_i^{(s)}) = 0$ cuando $y_i = 0$.

Esta cantidad mide el ajuste del modelo, donde valores más pequeños indican mejor ajuste.

Inferencia posterior A partir de las muestras $\{\beta^{(s)}\}$, se pueden estimar:

- Media posterior de la deviance,
- Intervalos de credibilidad,
- Densidad posterior.

Regresión Gamma Bayesiana

Sea $y \in \mathbb{R}_+^n$ y $X \in \mathbb{R}^{n \times d}$. Se considera el modelo:

$$y_i \mid X, \beta, \alpha \sim \text{Gamma}(\alpha, \text{rate} = \alpha/\mu_i), \quad \text{con } \mu_i = \exp(x_i^T \beta).$$

De esta forma, se tiene que $\mathbb{E}[y_i \mid X, \beta] = \mu_i$.

Como priors para los parámetros se asume:

$$\beta \sim \mathcal{N}(0, \tau^2 I_d), \quad \alpha \sim \text{Gamma}(a, b).$$

Entonces, el logaritmo de la posterior es

$$\log(p(\beta, \alpha \mid y, X)) \propto \log(p(y \mid X, \beta, \alpha)) + \log(p(\beta)) + \log(p(\alpha)).$$

En donde

$$\log p(y \mid X, \beta, \alpha) = \sum_{i=1}^n \left[\alpha \log \left(\frac{\alpha}{\mu_i} \right) - \log \Gamma(\alpha) + (\alpha - 1) \log y_i - \frac{\alpha}{\mu_i} y_i \right],$$

$$\log p(\beta) = -\frac{1}{2\tau^2} \|\beta\|^2, \quad \log p(\alpha) = (a - 1) \log \alpha - b\alpha.$$

Transformación de parámetro

Como $\alpha > 0$, se introduce el cambio de variable:

$$\eta = \log(\alpha), \quad \text{de modo que } \eta \in \mathbb{R}.$$

Aplicando cambio de variable:

$$\log p(\eta) = \log p(\alpha) + \eta.$$

Por lo tanto, la log-posterior en términos de (β, η) es:

$$\log p(\beta, \eta \mid y, X) = \log p(y \mid X, \beta, \alpha) - \frac{1}{2\tau^2} \|\beta\|^2 + (a - 1)\eta - be^\eta + \eta.$$

Algoritmo Metropolis-Hastings

Bajo las consideraciones anteriores, el algoritmo de Metropolis-Hastings para muestrear de la distribución posterior $p(\beta, \eta \mid y, X)$ queda de la siguiente manera:

1. Inicializar $\beta^{(0)}$ y $\eta^{(0)}$.

2. Para $t = 1, \dots, T$:

a) Generar propuestas mediante un paseo aleatorio Gaussiano:

$$\beta' = \beta^{(t-1)} + \epsilon_\beta, \quad \epsilon_\beta \sim \mathcal{N}(0, s^2 I_d),$$

$$\eta' = \eta^{(t-1)} + \epsilon_\eta, \quad \epsilon_\eta \sim \mathcal{N}(0, s^2).$$

b) Calcular la razón de aceptación:

$$\alpha = \min \left(1, \frac{p(\beta', \eta' \mid y)}{p(\beta^{(t-1)}, \eta^{(t-1)} \mid y)} \right),$$

o equivalentemente en escala logarítmica:

$$\log \alpha = \log p(\beta', \eta' \mid y) - \log p(\beta^{(t-1)}, \eta^{(t-1)} \mid y).$$

c) Generar $u \sim \mathcal{U}(0, 1)$ y aceptar la propuesta si:

$$\log u \leq \log \alpha.$$

d) Actualizar:

$$(\beta^{(t)}, \eta^{(t)}) = \begin{cases} (\beta', \eta'), & \text{si se acepta,} \\ (\beta^{(t-1)}, \eta^{(t-1)}), & \text{en otro caso.} \end{cases}$$

Media predictiva Para cada muestra $(\beta^{(s)}, \alpha^{(s)})$, se tiene:

$$\mu^{(s)} = \exp(X\beta^{(s)}).$$

Deviance La deviance para el modelo Gamma se define como:

$$D^{(s)} = \frac{1}{n} \sum_{i=1}^n \left[\frac{y_i - \mu_i^{(s)}}{\mu_i^{(s)}} - \log \left(\frac{y_i}{\mu_i^{(s)}} \right) \right].$$

Esta cantidad mide el ajuste del modelo, donde valores más pequeños indican mejor ajuste.

Inferencia posterior A partir de las muestras $\{(\beta^{(s)}, \alpha^{(s)})\}$, se pueden estimar:

- Media posterior de β y α ,
- Intervalos de credibilidad,
- Densidades posteriores,
- Media posterior de la deviance.

Red Neuronal Bayesiana con una Capa Oculta

Sea $y \in \{0, 1\}^n$ y $X \in \mathbb{R}^{n \times d}$. Se considera un modelo de red neuronal con una capa oculta de dimensión h , dado por:

$$a_i = \tanh(W_1^T x_i + b_1), \quad z_i = W_2^T a_i + b_2,$$

y

$$y_i \mid X, \theta \sim \text{Bernoulli}(\sigma(z_i)),$$

donde $\sigma(t) = \frac{1}{1+e^{-t}}$ es la función logística y $\theta = (W_1, b_1, W_2, b_2)$ denota el conjunto de parámetros.

Equivalentemente, en forma matricial:

$$a = \tanh(XW_1 + \mathbf{1}b_1^T), \quad z = aW_2 + b_2.$$

Priori

Se asumen priors independientes gaussianos para todos los parámetros:

$$W_1 \sim \mathcal{N}(0, \tau^2 I), \quad b_1 \sim \mathcal{N}(0, \tau^2 I),$$

$$W_2 \sim \mathcal{N}(0, \tau^2 I), \quad b_2 \sim \mathcal{N}(0, \tau^2 I).$$

Log-posterior

Entonces, el logaritmo de la posterior es:

$$\log p(\theta \mid y, X) \propto \log p(y \mid X, \theta) + \log p(\theta),$$

en donde

$$\log p(y \mid X, \theta) = \sum_{i=1}^n [y_i \log \sigma(z_i) + (1 - y_i) \log(1 - \sigma(z_i))],$$

y

$$\log p(\theta) = -\frac{1}{2\tau^2} (\|W_1\|^2 + \|b_1\|^2 + \|W_2\|^2 + \|b_2\|^2).$$

Por lo tanto, la log-posterior queda dada por:

$$\log p(\theta \mid y, X) = \sum_{i=1}^n [y_i \log \sigma(z_i) + (1 - y_i) \log(1 - \sigma(z_i))] - \frac{1}{2\tau^2} (\|W_1\|^2 + \|b_1\|^2 + \|W_2\|^2 + \|b_2\|^2).$$

Algoritmo Metropolis-Hastings

Bajo las consideraciones anteriores, el algoritmo de Metropolis-Hastings para muestrear de la distribución posterior $p(\theta \mid y, X)$ queda de la siguiente manera:

1. Inicializar $(W_1^{(0)}, b_1^{(0)}, W_2^{(0)}, b_2^{(0)})$.
2. Para $t = 1, \dots, T$:

a) Generar propuestas mediante un paseo aleatorio Gaussiano:

$$\begin{aligned} W_1' &= W_1^{(t-1)} + \epsilon_{W_1}, & \epsilon_{W_1} &\sim \mathcal{N}(0, s^2 I), \\ W_2' &= W_2^{(t-1)} + \epsilon_{W_2}, & \epsilon_{W_2} &\sim \mathcal{N}(0, s^2 I), \\ b_1' &= b_1^{(t-1)} + \epsilon_{b_1}, & \epsilon_{b_1} &\sim \mathcal{N}(0, s^2 I), \\ b_2' &= b_2^{(t-1)} + \epsilon_{b_2}, & \epsilon_{b_2} &\sim \mathcal{N}(0, s^2 I). \end{aligned}$$

b) Calcular la razón de aceptación:

$$\alpha = \min \left(1, \frac{p(\theta' \mid y)}{p(\theta^{(t-1)} \mid y)} \right),$$

o equivalentemente en escala logarítmica:

$$\log \alpha = \log p(\theta' \mid y) - \log p(\theta^{(t-1)} \mid y).$$

c) Generar $u \sim \mathcal{U}(0, 1)$ y aceptar la propuesta si:

$$\log u \leq \log \alpha.$$

d) Actualizar:

$$\theta^{(t)} = \begin{cases} \theta', & \text{si se acepta,} \\ \theta^{(t-1)}, & \text{en otro caso.} \end{cases}$$

Red Neuronal Bayesiana con MALA

Sea $y \in \{0, 1\}^n$ y $X \in \mathbb{R}^{n \times d}$. Se considera un modelo de red neuronal con una capa oculta de dimensión h , dado por:

$$a_i = \phi(W_1^T x_i + b_1), \quad z_i = W_2^T a_i + b_2,$$

y

$$y_i \mid X, \theta \sim \text{Bernoulli}(\sigma(z_i)),$$

donde $\phi(\cdot)$ es una función de activación, $\sigma(t) = \frac{1}{1+e^{-t}}$ es la función logística, y $\theta = (W_1, b_1, W_2, b_2)$.

Priori

Se asumen priors gaussianos independientes:

$$\theta \sim \mathcal{N}(0, \tau^2 I),$$

es decir,

$$\log p(\theta) = -\frac{1}{2\tau^2} \|\theta\|^2.$$

Log-posterior

El logaritmo de la posterior es:

$$\log p(\theta \mid y, X) \propto \log p(y \mid X, \theta) + \log p(\theta),$$

donde

$$\log p(y \mid X, \theta) = \sum_{i=1}^n [y_i \log \sigma(z_i) + (1 - y_i) \log(1 - \sigma(z_i))].$$

Origen de MALA

El algoritmo MALA se deriva de la ecuación de Langevin sobreamortiguada, dada por la ecuación diferencial estocástica:

$$d\theta_t = \frac{1}{2} \nabla \log p(\theta_t \mid y) dt + dW_t,$$

donde W_t es un movimiento browniano estándar.

Esta dinámica tiene como distribución invariante a $p(\theta \mid y)$.

Aplicando el esquema de discretización de Euler–Maruyama con paso ϵ , se obtiene:

$$\theta_{t+1} = \theta_t + \frac{\epsilon}{2} \nabla \log p(\theta_t \mid y) + \sqrt{\epsilon} Z_t,$$

donde $Z_t \sim \mathcal{N}(0, I)$.

Esta discretización induce una cadena de Markov cuya distribución estacionaria no es exactamente la posterior, por lo que se introduce un paso de corrección tipo Metropolis-Hastings.

Algoritmo MALA

El algoritmo Metropolis-Adjusted Langevin Algorithm (MALA) queda:

1. Inicializar $\theta^{(0)}$.
2. Para $t = 1, \dots, T$:

a) Calcular el gradiente:

$$\nabla \log p(\theta^{(t-1)} \mid y).$$

b) Generar propuesta:

$$\theta' = \theta^{(t-1)} + \frac{\epsilon}{2} \nabla \log p(\theta^{(t-1)} \mid y) + \sqrt{\epsilon} Z,$$

donde $Z \sim \mathcal{N}(0, I)$.

c) Definir la densidad de transición:

$$q(\theta' \mid \theta) = \mathcal{N}\left(\theta + \frac{\epsilon}{2} \nabla \log p(\theta), \epsilon I\right).$$

d) Calcular la razón de aceptación:

$$\alpha = \min\left(1, \frac{p(\theta' \mid y) q(\theta^{(t-1)} \mid \theta')}{p(\theta^{(t-1)} \mid y) q(\theta' \mid \theta^{(t-1)})}\right),$$

o equivalentemente:

$$\log \alpha = \log p(\theta' \mid y) - \log p(\theta^{(t-1)} \mid y) + \log q(\theta^{(t-1)} \mid \theta') - \log q(\theta' \mid \theta^{(t-1)}).$$

e) Generar $u \sim \mathcal{U}(0, 1)$ y aceptar si:

$$\log u \leq \log \alpha.$$

f) Actualizar:

$$\theta^{(t)} = \begin{cases} \theta', & \text{si se acepta,} \\ \theta^{(t-1)}, & \text{en otro caso.} \end{cases}$$

Gibbs Sampling

El algoritmo de Gibbs Sampling es un método de Monte Carlo vía cadenas de Markov (MCMC) que permite muestrear de una distribución conjunta cuando se conocen las distribuciones condicionales completas.

Dado un vector aleatorio $x = (x_1, \dots, x_d)$, el método consiste en actualizar cada componente según:

$$x_i \sim p(x_i \mid x_{-i}),$$

donde x_{-i} denota el resto de las variables.

Algoritmos de Gibbs Sampling

Gibbs Secuencial

En el esquema secuencial, se actualizan todas las coordenadas en un orden fijo en cada iteración.

1. Inicializar $x^{(0)}$.
2. Para $t = 1, \dots, T$:

a) Para $i = 1, \dots, d$:

$$x_i^{(t)} \sim p(x_i \mid x_1^{(t)}, \dots, x_{i-1}^{(t)}, x_{i+1}^{(t-1)}, \dots, x_d^{(t-1)}).$$

Gibbs Random Scan

En el esquema random scan, en cada iteración se selecciona una coordenada al azar.

1. Inicializar $x^{(0)}$.
2. Para $t = 1, \dots, T$:
 - a) Elegir $i_t \sim \text{Uniform}\{1, \dots, d\}$.
 - b) Actualizar:

$$x_{i_t}^{(t)} \sim p(x_{i_t} \mid x_{-i_t}^{(t-1)}),$$

manteniendo las demás coordenadas fijas.

Aplicación: Restauración de Imágenes

Considera la matriz aleatoria $(\theta_{i,j})_{i,j}$ para $i \in \{1, \dots, n\}$ y $j \in \{1, \dots, m\}$ con valores en $\{-1, 1\}$. Observamos una versión ruidosa:

$$X_{i,j} = \theta_{i,j} + \varepsilon_{i,j},$$

donde $\varepsilon_{i,j}$ son variables iid con media cero.

El objetivo es obtener muestras de la distribución posterior:

$$p(\theta \mid X).$$

Modelo a priori

Se considera un modelo de campo de Markov (MRF) con parámetro $\lambda > 0$:

$$P(\theta_{i,j} \mid \theta_{-(i,j)}) \propto \exp(\lambda \theta_{i,j} \Sigma_{i,j}),$$

donde

$$\Sigma_{i,j} = \theta_{i-1,j} + \theta_{i+1,j} + \theta_{i,j-1} + \theta_{i,j+1},$$

es la suma de los vecinos de $\theta_{i,j}$.

Se adopta la convención:

$$\theta_{0,j} = \theta_{i,0} = \theta_{n+1,j} = \theta_{i,m+1} = 0.$$

Suponiendo ruido gaussiano:

$$\varepsilon_{i,j} \sim \mathcal{N}(0, \sigma^2),$$

se tiene:

$$p(X \mid \theta) \propto \exp\left(-\frac{1}{2\sigma^2} \sum_{i,j} (X_{i,j} - \theta_{i,j})^2\right).$$

Por la regla de Bayes:

$$p(\theta \mid X) \propto p(X \mid \theta) p(\theta).$$

Condicionales completas

Para cada pixel (i, j) :

$$p(\theta_{i,j} \mid \theta_{-(i,j)}, X) \propto \exp \left(\theta_{i,j} \left[\lambda \Sigma_{i,j} + \frac{X_{i,j}}{\sigma^2} \right] \right).$$

Por lo tanto,

$$\mathbb{P}(\theta_{i,j} = 1 \mid \cdot) = g \left(2 \left[\lambda \Sigma_{i,j} + \frac{X_{i,j}}{\sigma^2} \right] \right),$$

$$\text{donde } g(x) = \frac{1}{1 + e^{-x}}$$

Algoritmo de Gibbs

1. Inicializar $\theta^{(0)}$.
2. Para $t = 1, \dots, T$:

a) Para cada pixel (i, j) :

- Calcular:

$$\Sigma_{i,j}^{(t)} = \theta_{i-1,j}^{(t)} + \theta_{i+1,j}^{(t)} + \theta_{i,j-1}^{(t)} + \theta_{i,j+1}^{(t)}.$$

- Calcular:

$$p_{i,j} = g \left(2 \left[\lambda \Sigma_{i,j}^{(t)} + \frac{X_{i,j}}{\sigma^2} \right] \right).$$

- Actualizar:

$$\theta_{i,j}^{(t)} = \begin{cases} 1, & \text{con probabilidad } p_{i,j}, \\ -1, & \text{en otro caso.} \end{cases}$$

Aplicación: Regresión Lineal Bayesiana

Sea $y \in \mathbb{R}^n$ y $X \in \mathbb{R}^{n \times d}$. El modelo es:

$$y \mid X, \beta, \sigma^2 \sim \mathcal{N}(X\beta, \sigma^2 I_n)$$

$$\beta \sim \mathcal{N}(0, \tau^2 I_d)$$

$$\sigma^2 \sim \text{Inv-Gamma}(a, b)$$

La distribución posterior condicional de β es:

$$\beta \mid \sigma^2, y \sim \mathcal{N}(\mu_n, \Sigma_n)$$

donde:

$$\Sigma_n = \left(\frac{1}{\sigma^2} X^\top X + \frac{1}{\tau^2} I_d \right)^{-1}$$

$$\mu_n = \Sigma_n \left(\frac{1}{\sigma^2} X^\top y \right)$$

La distribución posterior condicional de σ^2 es:

$$\sigma^2 \mid \beta, y \sim \text{Inv-Gamma}(a_n, b_n)$$

donde:

$$a_n = a + \frac{n}{2}$$

$$b_n = b + \frac{1}{2} \|y - X\beta\|^2$$

Algoritmo de Gibbs

Dado un estado inicial $(\beta^{(0)}, \sigma^{2(0)})$, se itera para $t = 1, \dots, T$:

1. Muestrear:

$$\beta^{(t)} \sim \mathcal{N}(\mu_n^{(t-1)}, \Sigma_n^{(t-1)})$$

donde:

$$\Sigma_n^{(t-1)} = \left(\frac{1}{\sigma^{2(t-1)}} X^\top X + \frac{1}{\tau^2} I_d \right)^{-1}$$

$$\mu_n^{(t-1)} = \Sigma_n^{(t-1)} \left(\frac{1}{\sigma^{2(t-1)}} X^\top y \right)$$

2. Muestrear:

$$\sigma^{2(t)} \sim \text{Inv-Gamma} \left(a + \frac{n}{2}, b + \frac{1}{2} \|y - X\beta^{(t)}\|^2 \right)$$

Monte Carlo Hamiltoniano (HMC)

El Monte Carlo Hamiltoniano es un método avanzado de MCMC inspirado en el movimiento de una partícula, y que mejora el muestreo en alta dimensión.

Supongamos que podemos caracterizar el movimiento de una partícula en términos de su posición $\theta \in \mathbb{R}^d$ y de su momento $v \in \mathbb{R}^d$. El conjunto de posibles valores para (θ, v) es llamado *espacio fase*. Además, definimos la energía total o *Hamiltoniano* como

$$H(\theta, v) = E(\theta) + K(v),$$

donde

$$E(\theta) = -\log p(\theta),$$

con $p(\theta)$ el kernel de una función de densidad (*energía potencial*), y

$$K(v) = \frac{1}{2}v^\top \Sigma^{-1}v,$$

donde Σ es una matriz definida positiva (*energía cinética*). Con esto definido, nuestra distribución objetivo tiene la forma

$$p(\theta, v) \propto \exp[-H(\theta, v)] = \exp\left(-E(\theta) - \frac{1}{2}v^\top \Sigma^{-1}v\right),$$

tal que

$$p(\theta) = \int p(\theta, v) dv \propto \int e^{-E(\theta)} e^{-\frac{1}{2}v^\top \Sigma^{-1}v} dv \propto e^{-E(\theta)}.$$

El movimiento de la partícula se puede modelar mediante las *ecuaciones de Hamilton*:

$$\frac{d\theta}{dt} = \frac{\partial H}{\partial v} = \frac{\partial K}{\partial v}, \quad \frac{dv}{dt} = -\frac{\partial H}{\partial \theta} = -\frac{\partial E}{\partial \theta}.$$

Como no podemos resolver estas ecuaciones analíticamente, usamos el *integrador leapfrog*:

$$\begin{aligned} v_{t+\frac{1}{2}} &= v_t - \frac{\eta}{2} \nabla E(\theta_t), \\ \theta_{t+1} &= \theta_t + \eta \nabla_v K(v_{t+\frac{1}{2}}), \\ v_{t+1} &= v_{t+\frac{1}{2}} - \frac{\eta}{2} \nabla E(\theta_{t+1}). \end{aligned}$$

El algoritmo de HMC es el siguiente:

Algorithm 1 Algoritmo HMC

```
1: Definir un valor inicial  $\theta_0$ 
2: for  $t = 1, \dots, T$  do
3:   Generar  $v_{t-1} \sim \mathcal{N}(0, \Sigma)$ 
4:   Inicializar  $(\theta'_0, v'_0) = (\theta_{t-1}, v_{t-1})$ 
5:    $v'_{1/2} = v'_0 - \frac{\eta}{2} \nabla E(\theta'_0)$ 
6:   for  $\ell = 1, \dots, L-1$  do
7:      $\theta'_\ell = \theta'_{\ell-1} + \eta \Sigma^{-1} v'_{\ell-1/2}$ 
8:      $v'_{\ell+1/2} = v'_{\ell-1/2} - \eta \nabla E(\theta'_\ell)$ 
9:   end for
10:   $\theta'_L = \theta'_{L-1} + \eta \Sigma^{-1} v'_{L-1/2}$ 
11:   $v'_L = v'_{L-1/2} - \frac{\eta}{2} \nabla E(\theta'_L)$ 
12:  Propuesta:  $(\theta^*, v^*) = (\theta'_L, v'_L)$ 
13:  Calcular
      
$$\alpha = \min \left( 1, \exp \left( -H(\theta^*, v^*) + H(\theta_{t-1}, v_{t-1}) \right) \right)$$

14:  Aceptar  $\theta_t = \theta^*$  con probabilidad  $\alpha$ , en otro caso  $\theta_t = \theta_{t-1}$ 
15: end for
```

Se necesita muestrear un nuevo momento en cada iteración para garantizar ergodicidad, es decir, para asegurar que el muestreador explore todo el espacio, debemos elegir un momento aleatorio al inicio de cada iteración.

Elección de Hiperparámetros

Para la elección de hiperparámetros en HMC, necesitamos especificar: el número de pasos leapfrog L , el tamaño de paso η y la covarianza Σ .

Para la elección de L , queremos que sea lo suficientemente grande como para que el algoritmo explore el conjunto de energía constante, pero sin que la trayectoria “regrese sobre sí misma”, lo cual desperdicia cómputo al producir muestras altamente correlacionadas. Afortunadamente, existe un algoritmo llamado *No-U-Turn Sampler* (NUTS) que puede elegir L de forma adaptativa.

Para la elección de η se recomienda la siguiente heurística:

- Fijar $\Sigma = I$ y $L = 1$
- Ajustar η hasta que la tasa de aceptación esté entre 40 % y 80 %

Una forma de estimar Σ fija es:

1. Ejecutar HMC con $\Sigma = I$ durante un periodo de calentamiento hasta que la cadena alcance el régimen estacionario.

2. Correr iteraciones adicionales para estimar la matriz de covarianza empírica:

$$\Sigma = \mathbb{E}[(\theta - \bar{\theta})(\theta - \bar{\theta})^\top]$$

Inferencia Variacional

Consideremos un modelo con variable desconocida (latente) z y una variable conocida x . Supongamos que la prior es $p(z)$ y la verosimilitud es $p(x | z)$, de tal forma que la densidad conjunta es $p(x, z) = p(x | z)p(z)$ y la posterior es $p(z | x) = p(x, z)/p(x)$. Además, supongamos que la constante de normalización $p(x) = \int p(x, z)dz$ es incalculable, y por lo tanto también la posterior. El objetivo sera encontrar un densidad $q(z)$ que aproxime la posterior, tal que minimice la siguiente función de pérdida:

$$q = \arg \min_{q \in \mathcal{Q}} D_{KL}(q(z) \parallel p_\theta(z | x)),$$

en donde

$$D_{KL}(q(z) \parallel p_\theta(z | x)) = \mathbb{E}_{q(z)} \left[\log \left(\frac{q(z)}{p_\theta(z | x)} \right) \right]$$

es la *Divergencia de Kullback-Leiber* y $\mathcal{Q} = \{q_\theta(z) : \theta \in \Theta\}$ es una familia paramétrica de funciones de densidad, θ es conocida como los *parámetros variacionales*.

En este caso, el problema se puede reescribir como:

$$\theta^* = \arg \min_{\theta} D_{KL}(q_\theta(z) \parallel p(z | x))$$

y desarrollando la divergencia:

$$\begin{aligned} \theta^* &= \arg \min_{\theta} D_{KL}(q_\theta(z) \parallel p_\theta(z | x)) \\ &= \arg \min_{\theta} \mathbb{E}_{q_\theta(z)} \left[\log \frac{q_\theta(z)}{p_\theta(z | x)} \right] \\ &= \arg \min_{\theta} \mathbb{E}_{q_\theta(z)} [\log q_\theta(z) - \log p_\theta(z | x)] \\ &= \arg \min_{\theta} \mathbb{E}_{q_\theta(z)} \left[\log q_\theta(z) - \log \left(\frac{p_\theta(x | z)p_\theta(z)}{p_\theta(x)} \right) \right] \\ &= \arg \min_{\theta} \mathbb{E}_{q_\theta(z)} [\log q_\theta(z) - \log p_\theta(x | z) - \log p_\theta(z) + \log p_\theta(x)] \\ &= \arg \min_{\theta} \{ \mathbb{E}_{q_\theta(z)} [\log q_\theta(z) - \log p_\theta(x | z) - \log p_\theta(z)] + \log p_\theta(x) \} \\ &= \arg \min_{\theta} \mathbb{E}_{q_\theta(z)} [\log q_\theta(z) - \log p_\theta(x | z) - \log p_\theta(z)] \\ &= \arg \min_{\theta} \mathbb{E}_{q_\theta(z)} [-\log p_\theta(x, z) + \log q_\theta(z)] \\ &= \arg \min_{\theta} \mathcal{L}(\theta | x) \end{aligned}$$

Si definimos la energía como

$$E_{\theta}(z) = -\log p_{\theta}(x, z),$$

entonces la función de pérdida se puede reescribir como:

$$\mathcal{L}(\theta \mid x) = \mathbb{E}_{q_{\theta}(z)}[E_{\theta}(z)] - H(q_{\theta}),$$

donde $H(q_{\theta})$ es la entropía de la distribución variacional. Es decir, la pérdida se interpreta como:

$$\text{energía esperada} - \text{entropía}.$$

En física, esta cantidad se conoce como la *energía libre variacional* (VFE). Además, esta es una cota superior de la energía libre:

$$-\log p_{\theta}(x),$$

ya que se cumple:

$$D_{KL}(q_{\theta}(z) \parallel p_{\theta}(z \mid x)) = \mathcal{L}(\theta \mid x) + \log p_{\theta}(x) \geq 0.$$

Por lo tanto,

$$\mathcal{L}(\theta \mid x) \geq -\log p_{\theta}(x).$$

Así, la inferencia variacional es equivalente a minimizar la energía libre variacional. En el caso ideal, cuando se alcanza el mínimo

$$-\log p_{\theta}(x),$$

la divergencia KL es cero, lo que implica que la aproximación $q_{\theta}(z)$ coincide exactamente con la posterior verdadera.

El negativo de la energía libre variacional (VFE) se conoce como la *evidence lower bound* (ELBO):

$$\mathcal{E}(\theta \mid x) = \mathbb{E}_{q_{\theta}(z)}[\log p_{\theta}(x, z) - \log q_{\theta}(z)].$$

El nombre proviene de que satisface la siguiente cota:

$$\mathcal{E}(\theta \mid x) \leq \log p_{\theta}(x),$$

donde $\log p_{\theta}(x)$ se conoce como la *evidencia*. Por lo tanto, maximizar la ELBO es equivalente a minimizar la divergencia KL, ya que $\log p_{\theta}(x)$ es constante respecto a θ .

La ELBO también se puede escribir como:

$$\mathcal{E}(\theta \mid x) = \mathbb{E}_{q_\theta(z)} [\log p_\theta(x, z)] + H(q_\theta),$$

lo que permite interpretarla como:

$$\text{ELBO} = \text{log-verosimilitud conjunta esperada} + \text{entropía}.$$

Equivalentemente, puede reescribirse como:

$$\mathcal{E}(\theta \mid x) = \mathbb{E}_{q_\theta(z)} [\log p_\theta(x \mid z) + \log p_\theta(z) - \log q_\theta(z)],$$

y por lo tanto:

$$\mathcal{E}(\theta \mid x) = \mathbb{E}_{q_\theta(z)} [\log p_\theta(x \mid z)] - D_{KL}(q_\theta(z) \parallel p_\theta(z)).$$

Esto se puede interpretar como:

$$\text{ELBO} = \text{log-verosimilitud esperada} - \text{regularización KL}.$$

El término KL actúa como un regularizador que evita que la distribución variacional se aleje demasiado de la prior.

ELBO Estocástica para Aproximaciones Gaussianas Mean-Field

Supongamos que

$$\mathcal{Q} = \left\{ q(z) = \prod_{i=1}^d \mathcal{N}(z; \mu_i, \sigma_i^2) : \mu_i \in \mathbb{R}, \sigma_i > 0 \text{ y } z \in \mathbb{R}^n \right\}$$

y que la prior es $\mathcal{N}(z; 0, \tau^2 I_d)$, en este caso

$$\begin{aligned}
D_{KL}(q(z) \parallel p(z)) &= \mathbb{E}_{q(z)} \left[\log \left(\frac{q(z)}{p(z)} \right) \right] \\
&= \mathbb{E}_{q(z)} \left[\log \left(\frac{\prod_{i=1}^d \mathcal{N}(z_i; \mu_i, \sigma_i^2)}{\prod_{i=1}^d \mathcal{N}(z_i; 0, \tau^2)} \right) \right] \\
&= \sum_{i=1}^d \mathbb{E}_{q(z)} [\log (\mathcal{N}(z_i; \mu_i, \sigma_i^2)) - \log (\mathcal{N}(z_i; 0, \tau^2))] \\
&= \sum_{i=1}^d \mathbb{E}_{q(z)} [\log (\mathcal{N}(z_i; \mu_i, \sigma_i^2) - \mathcal{N}(z_i; 0, \tau^2))] \\
&= \sum_{i=1}^d \mathbb{E}_{q(z)} \left[\log \left(\frac{\tau}{\sigma_i} \right) - \frac{(z_i - \mu_i)^2}{2\sigma_i^2} + \frac{z_i^2}{2\tau^2} \right] \\
&= \sum_{i=1}^d \mathbb{E}_{q(z)} \left[\log \left(\frac{\tau}{\sigma_i} \right) - \frac{(z_i - \mu_i)^2}{2\sigma_i^2} + \frac{z_i^2}{2\tau^2} \right] \\
&= \sum_{i=1}^d \log \left(\frac{\tau}{\sigma_i} \right) - \frac{1}{2} + \frac{\mu_i^2 + \sigma_i^2}{2\tau^2} \\
&\quad .
\end{aligned}$$

Por otro lado, sea el dataset $D = \{(x_n, y_n)\}_{n=1}^N$, entonces:

$$p(D|z) = \prod_{n=1}^N p(y_n|x_n, z)$$

y por tanto:

$$\log p(D|z) = \sum_{n=1}^N \log p(y_n|x_n, z).$$

La esperanza bajo $q(z)$ es:

$$\begin{aligned}
\mathbb{E}_{q(z)}[\log p(D|z)] &= \sum_{n=1}^N \mathbb{E}_{q(z)}[\log p(y_n|x_n, z)] \\
&\approx \frac{1}{S} \sum_{s=1}^S \sum_{n=1}^N \log p(y_n|x_n, z^{(s)})
\end{aligned}$$

donde:

$$z^{(s)} = \mu + \sigma \odot \epsilon^{(s)}, \quad \epsilon^{(s)} \sim \mathcal{N}(0, I)$$

Cuando se utiliza un tamaño de minibatch B , se necesita multiplicar el estimador de la log-verosimilitud por $\frac{N}{B}$ para que este sea insesgado. Además, podemos multiplicar la divergencia de Kullback–Leibler por un término β para controlar la regularización. Por lo tanto, la función de pérdida quedaría como:

$$\mathcal{L} = \underbrace{-\frac{1}{S} \sum_{s=1}^S \frac{N}{B} \sum_{n \in \mathcal{B}} \log p(y_n \mid x_n, z^{(s)})}_{\text{data term}} + \underbrace{\beta D_{KL}(q(z) \parallel p(z))}_{\text{regularization}}$$

Dividiendo toda la expresión por N , obtenemos una forma equivalente (normalizada por el tamaño del dataset):

$$\frac{1}{N} \mathcal{L} = \underbrace{-\frac{1}{S} \sum_{s=1}^S \frac{1}{B} \sum_{n \in \mathcal{B}} \log p(y_n \mid x_n, z^{(s)})}_{\text{data term (normalized)}} + \underbrace{\beta \frac{1}{N} D_{KL}(q(z) \parallel p(z))}_{\text{regularization (scaled)}}$$

Ambas expresiones son equivalentes, ya que difieren únicamente en una constante de escala positiva $\frac{1}{N}$, la cual no cambia el óptimo del problema:

$$\arg \min \mathcal{L} = \arg \min \left(\frac{1}{N} \mathcal{L} \right).$$

En la practica podemos regularizar a la $D_{KL}(q(z) \parallel p(z))$ mediante el parámetro β , eliminando la división entre N y quedarnos con la siguiente función de perdida:

$$\mathcal{L} = \underbrace{-\frac{1}{S} \sum_{s=1}^S \frac{1}{B} \sum_{n \in \mathcal{B}} \log p(y_n \mid x_n, z^{(s)})}_{\text{data term}} + \underbrace{\beta D_{KL}(q(z) \parallel p(z))}_{\text{regularization}}$$

Modelos Bayesianos para Series de Tiempo

Modelo ETS AAdN (tendencia lineal amortiguada)

El modelo ETS AAdN (tendencia lineal amortiguada no estacional) describe una serie de tiempo mediante dos componentes latentes: el nivel l_t y la tendencia local b_t . Se asume que

la observación futura y_{t+1} sigue una distribución normal con media $\hat{y}_{t+1}$ y varianza σ^2 , donde la predicción a un paso se define como

$$\hat{y}_{t+1} = l_t + \phi b_t.$$

El nivel evoluciona como un promedio ponderado entre la nueva observación y la predicción previa,

$$l_{t+1} = \alpha y_{t+1} + (1 - \alpha)(l_t + \phi b_t),$$

mientras que la tendencia se actualiza en función del cambio en el nivel,

$$b_{t+1} = \beta(l_{t+1} - l_t) + (1 - \beta)\phi b_t.$$

Los parámetros $\alpha, \beta \in (0, 1)$ controlan el grado de suavizamiento del nivel y la tendencia, respectivamente, mientras que $\phi \in (0, 1)$ es un factor de amortiguamiento que reduce la influencia de la tendencia a lo largo del tiempo (si $\phi = 1$, se obtiene el modelo sin amortiguamiento AAN).

Los valores iniciales l_1 y b_1 se tratan como parámetros a estimar. Este modelo es apropiado cuando tanto el nivel como la tendencia cambian gradualmente en el tiempo.

Modelo autorregresivo con estacionalidad (SAR)

El modelo autorregresivo con estacionalidad (SAR) describe una serie de tiempo incorporando dependencias tanto de corto plazo como patrones periódicos. Se asume que la observación y_t puede expresarse como una combinación lineal de valores pasados recientes y valores pasados separados por un periodo estacional s , junto con un término de error.

En su forma básica, el modelo se escribe como

$$y_t = \phi_1 y_{t-1} + \cdots + \phi_p y_{t-p} + \Phi_1 y_{t-s} + \cdots + \Phi_P y_{t-Ps} + \varepsilon_t,$$

donde $\varepsilon_t \sim \mathcal{N}(0, \sigma^2)$.

Los coeficientes ϕ_i capturan la dependencia autorregresiva de corto plazo, mientras que los coeficientes Φ_j modelan la dependencia estacional con periodo s . El parámetro σ^2 representa la varianza del ruido.

Este modelo permite capturar series donde existe correlación temporal tanto entre observaciones consecutivas como entre observaciones separadas por ciclos estacionales (por ejemplo, meses o trimestres). Es especialmente útil cuando los patrones estacionales son persistentes en el tiempo.

Los parámetros del modelo, incluyendo los coeficientes autorregresivos y la varianza del error, se estiman a partir de los datos.