

Aprendizaje Supervisado

Yael Rene Santiago Cruz

Índice

1. Aprendizaje Supervisado	1
2. Aprendizaje Supervisado Bayesiano	4
2.1. Métricas de Evaluación	4

1. Aprendizaje Supervisado

En el *Aprendizaje Supervisado* suponemos que tenemos un conjunto de datos de entrenamiento

$$D_{train} = \{(x_1, y_1), \dots, (x_n, y_n) : x_i \in X, y_i \in Y, \forall i = 1, \dots, n\},$$

tal que $D_{train} \sim P(X, Y)$. El conjunto $F_T = \{x_1, \dots, x_n\}$ se denomina *características*, mientras que el conjunto $L_T = \{y_1, \dots, y_n\}$ es conocido como *etiquetas*. Además, suponemos que existe una función $h : X \rightarrow Y$ que relaciona a los conjuntos de características y etiquetas. En la vida real h no es conocida, incluso podría no existir, por lo tanto nuestro objetivo será estimarla mediante otra función $g : X \times \Theta \rightarrow Y$, donde Θ es llamado el *espacio de parámetros*.

La forma de estimar h es mediante la minimización de la *función de riesgo*

$$R(\theta) = \mathbb{E}_{P_{true}(X, Y)}[\ell(y, \hat{y})]$$

con $\hat{y} = g(x, \theta)$ y ℓ una función de pérdida.

Suponiendo que D_{train} es una muestra i.i.d. con ley $P(X, Y)$, podemos utilizar Monte Carlo para estimar a la función de riesgo como

$$\hat{R}(\theta) = \frac{1}{n} \sum_{i=1}^n \ell(y_i, \hat{y}_i).$$

Ahora el problema es: ¿cuál función de pérdida se debe utilizar? Para responder esta pregunta, agregamos hipótesis adicionales. Consideremos el conjunto de entrenamiento D_{train} tal que $\{y_i \mid X_i, \theta\}_{i=1}^n$ son v.a. independientes con ley $q(y_i; x_i, \theta)$. Entonces podemos estimar θ por máxima verosimilitud, es decir

$$\begin{aligned}\hat{\theta} &= \arg \max_{\theta} L(\theta) \\ &= \arg \max_{\theta} \prod_{i=1}^n q(y_i; x_i, \theta) \\ &= \arg \min_{\theta} -\frac{1}{n} \sum_{i=1}^n \log(q(y_i; x_i, \theta)).\end{aligned}$$

Entonces nuestra función de pérdida es

$$\ell(\theta) = -\log(q(y_i; x_i, \theta)).$$

Ejemplo 1 (Datos Normales)

Supongamos que $\{y_i \mid X_i, \theta\}_{i=1}^n$ es una muestra independiente con ley $N(\hat{y}_i, \sigma^2)$ en donde $\theta = (W, \sigma)$, $W \in \mathbb{R}^d$, $\sigma \in \mathbb{R}^+$, y $\hat{y}_i = g(x_i, W)$. Por lo tanto

$$\begin{aligned}\ell(\theta) &= -\log \left(\frac{1}{\sqrt{2\pi}\sigma} \exp \left\{ -\frac{(y_i - \hat{y}_i)^2}{2\sigma^2} \right\} \right) \\ &= \log(\sqrt{2\pi}) + \log(\sigma) + \frac{(y_i - \hat{y}_i)^2}{2\sigma^2}.\end{aligned}$$

Eliminado términos constantes obtenemos lo siguiente:

$$\ell(\theta) = \log(\sigma) + \frac{(y_i - \hat{y}_i)^2}{2\sigma^2}.$$

En estadística nos interesa estimar σ , pero notemos que con nuestras hipótesis para encontrar el estimador de h , no dependemos de σ , por lo tanto podemos tomar este parámetro como constante y quedarnos con

$$\ell(W) = (y_i - \hat{y}_i)^2$$

la cual es conocida como *Error Cuadrático Medio (MSE)*.

Ejemplo 2 (Datos Bernoulli)

Supongamos que $\{y_i \mid X_i, \theta\}_{i=1}^n$ es una muestra independiente con ley $Ber(\hat{y}_i)$, en donde $\theta \in \mathbb{R}^d$, y $\hat{y}_i = g(x_i, \theta)$. De manera similar al ejemplo anterior obtenemos que

$$\ell(\theta) = -\log(\hat{y}_i^{y_i} (1 - \hat{y}_i)^{1-y_i}) = -y_i \log(\hat{y}_i) - (1 - y_i) \log(1 - \hat{y}_i).$$

Esta función es conocida como *Entropía Cruzada Binaria*.

Ejemplo 3 (Datos Poisson)

Sea $\{y_i \mid X_i, \theta\}_{i=1}^n$ una muestra independiente con ley $Poi(\hat{y}_i)$ con $\theta \in \mathbb{R}^d$ y $\hat{y}_i = g(x_i, \theta)$. De manera análoga a los ejemplos anteriores se tiene

$$\ell(\theta) = -\log \left(e^{-\hat{y}_i} \frac{\hat{y}_i^{y_i}}{y_i!} \right) = \hat{y}_i - y_i \log(\hat{y}_i) + \log(y_i!),$$

y como y_i no depende de θ para todo $i = 1, \dots, n$,

$$\ell(\theta) = \hat{y}_i - y_i \log(\hat{y}_i).$$

Ejemplo 4 (Datos Gamma)

Sea $\{y_i \mid X_i, \theta\}_{i=1}^n$ una muestra independiente con ley $Gamma(\alpha, \alpha/\hat{y}_i)$, en donde $\theta = (W, \alpha)$, $W \in \mathbb{R}^d$, $\alpha \in \mathbb{R}^+$ y $\hat{y}_i = g(x_i, W)$. Por lo tanto

$$\ell(\theta) = \log(\Gamma(\alpha)) - \alpha \log(\alpha) + \alpha \log(\hat{y}_i) - (\alpha - 1) \log(y_i) + \alpha \frac{y_i}{\hat{y}_i}.$$

Pero si consideramos a α como una constante la función de pérdida para datos Gamma es

$$\ell(W) = \log(\hat{y}_i) + \frac{y_i}{\hat{y}_i}.$$

Ejemplo 5 (Datos Laplace)

Sea $\{y_i \mid X_i, \theta\}_{i=1}^n$ una muestra independiente con ley $Lap(\hat{y}_i, b)$, en donde $\theta = (W, b)$, $W \in \mathbb{R}^d$, $b \in \mathbb{R}^+$ y $\hat{y}_i = g(x_i, W)$. Calculando nuevamente el negativo del logaritmo de la verosimilitud obtenemos que

$$\ell(\theta) = -\log \left(\exp \left(-\frac{1}{2b} |y_i - \hat{y}_i| \right) \right) = \frac{1}{2b} |y_i - \hat{y}_i|,$$

y considerando a b como constante

$$\ell(W) = |y_i - \hat{y}_i|$$

que es denominada Error Absoluto Medio (MAE).

2. Aprendizaje Supervisado Bayesiano

Usando la teoría bayesiana podemos agregar un supuesto adicional, θ es aleatorio con una densidad prior $p(\theta)$. En esta ocasión nos interesa conocer la densidad posterior $p(\theta|D_{train})$, para obtener muestras de ella. Como no siempre es fácil encontrar la densidad posterior usamos MCMC o inferencia variacional.

Ejemplo (Datos Normales)

Supongamos que tenemos una muestra $\{y_i \mid X_i, \theta\}_{i=1}^n$ independiente con ley $N(\hat{y}_i, \sigma^2)$, en donde

$$\theta = (W, \sigma), \quad W \in \mathbb{R}^d, \quad \sigma \in \mathbb{R}^+, \quad \text{y } y_i = g(x_i, W).$$

Para la prior de σ podemos tomar una densidad asociada a una v.a. positiva como:

- $\sigma \sim \text{InvGamma}(a, b)$, a, b fijos.
- $\sigma \sim \text{LogNormal}(\mu, \tau^2)$, μ, τ^2 fijos.
- $\sigma \sim \text{HalfNormal}(\mu)$, μ fijo.

Mientras que para W podemos usar:

- $W \sim N(0, \tau^2 I_d)$ con τ fija.
- $W \sim \prod_{i=1}^d \text{Lap}(0, b)$ con b fijo.
- $W|\tau \sim N(0, \tau^2 I_d)$ y $\tau \sim \text{InvGamma}(a, b)$ con a, b fijos.

2.1. Métricas de Evaluación

En los modelos bayesianos las métricas para evaluarlos son variables aleatorias y podemos calcular su densidad. Sea $M = M(\theta, D_{test})$ una métrica; por ejemplo Accuracy, MSE o AUC Score, en donde D_{test} es el conjunto de prueba. Entonces

$$P(M|D_{train}) = \int P(M, \theta|D_{train}) d\theta = \int P(M|\theta, D_{train})P(\theta|D_{train}) d\theta.$$

Asumiendo que dado θ , D_{test} es independiente de D_{train} , entonces

$$P(M|\theta, D_{train}) = P(M|\theta)$$

y por tanto

$$P(M|D_{train}) = \int P(M|\theta)P(\theta|D_{train}) d\theta.$$

En la práctica usamos Monte Carlo para estimar esa densidad. Si simulamos

$$\theta^{(s)} \sim P(\theta|D_{train}),$$

el par

$$(\theta^{(s)}, D_{test})$$

es una realización conjunta de la distribución que nos interesa y por tanto

$$M(\theta^{(s)}, D_{test}) = M^{(s)}$$

también es una realización de la métrica M .