

# 1. Regresión probit

## 1.1. Interpretación con variable latente

Podemos interpretar el modelo probit (y logístico) de la siguiente manera. Primero, asociemos cada ítem  $x_i$  con dos utilidades latentes,  $u_{0i}$  y  $u_{1i}$ , correspondientes a las elecciones posibles  $y_i = 0$  e  $y_i = 1$ . Luego asumimos que la elección observada es la acción que tiene mayor utilidad. Más precisamente, el modelo es el siguiente:

$$u_{0i} \sim w_0^T x_i + \delta_{0i} \quad (1)$$

$$u_{1i} \sim w_1^T x_i + \delta_{1i} \quad (2)$$

$$y_i = \mathbb{I}(u_{1i} > u_{0i}) \quad (3)$$

donde  $\delta$  son términos de error, que representan todos los otros factores que podrían ser relevantes en la toma de decisiones que hemos decidido no modelar. Esto se llama modelo de utilidad aleatoria o RUM.

Dado que solo la diferencia de utilidades importa, definamos  $z_i = u_{1i} - u_{0i} = w^T x_i + \varepsilon_i$ , donde  $\varepsilon_i = \delta_{1i} - \delta_{0i}$ . Si los  $\delta$  tienen distribución Gaussiana, entonces  $\varepsilon_i$  también la tiene. Así podemos escribir

$$z_i \sim w^T x_i + \varepsilon_i \quad (4)$$

$$\varepsilon_i \sim \mathcal{N}(0, 1) \quad (5)$$

$$y_i = 1 = \mathbb{I}(z_i \geq 0) \quad (6)$$

Llamamos a esto el modelo RUM de diferencias o dRUM.

Cuando marginalizamos  $z_i$ , recuperamos el modelo probit:

$$p(y_i = 1 | x_i, w) = \int \mathbb{I}(z_i \geq 0) \mathcal{N}(z_i | w^T x_i, 1) dz_i \quad (7)$$

$$= p(w^T x_i + \varepsilon \geq 0) = p(\varepsilon \geq -w^T x_i) \quad (8)$$

$$= 1 - \Phi(-w^T x_i) = \Phi(w^T x_i) \quad (9)$$

usando la simetría de la Gaussiana. Esta interpretación de variable latente proporciona una forma alternativa de ajustar el modelo.

Curiosamente, si usamos una distribución de Gumbel para los  $\delta$ , inducimos una distribución logística para  $\varepsilon_i$ , y el modelo se reduce a regresión logística.

## 1.2. Estimación EM para regresión probit

Recordemos que la interpretación de variable latente de la regresión probit tiene la forma  $p(y_i = 1|z_i) = \mathbb{I}(z_i > 0)$ , donde  $z_i \sim \mathcal{N}(w^T x_i, 1)$  es latente. Mostramos ahora cómo ajustar este modelo usando EM. (Aunque es posible ajustar modelos de regresión probit usando métodos basados en gradiente, este enfoque basado en EM tiene la ventaja de que se generaliza a muchos otros tipos de modelos.)

La verosimilitud logarítmica de los datos completos tiene la siguiente forma, asumiendo una prior  $\mathcal{N}(0, V_0)$  sobre  $w$ :

$$\ell(z, w|V_0) = \log p(y|z) + \log \mathcal{N}(z|Xw, I) + \log \mathcal{N}(w|0, V_0) \quad (10)$$

$$= \sum_i \log p(y_i|z_i) - \frac{1}{2}(z - Xw)^T(z - Xw) - \frac{1}{2}w^T V_0^{-1}w + \text{constante} \quad (11)$$

La posterior en el paso E es una Gaussiana truncada:

$$p(z_i|y_i, x_i, w) = \begin{cases} \mathcal{N}(z_i|w^T x_i, 1)\mathbb{I}(z_i > 0) & \text{si } y_i = 1 \\ \mathcal{N}(z_i|w^T x_i, 1)\mathbb{I}(z_i < 0) & \text{si } y_i = 0 \end{cases} \quad (12)$$

En la ecuación anterior, vemos que  $w$  solo depende linealmente de  $z$ , así que solo necesitamos calcular  $\mathbb{E}[z_i|y_i, x_i, w]$ . La media posterior está dada por

$$\mathbb{E}[z_i|w, x_i] = \begin{cases} \mu_i + \frac{\phi(\mu_i)}{1 - \Phi(-\mu_i)} = \mu_i + \frac{\phi(\mu_i)}{\Phi(\mu_i)} & \text{si } y_i = 1 \\ \mu_i - \frac{\phi(\mu_i)}{\Phi(-\mu_i)} = \mu_i - \frac{\phi(\mu_i)}{1 - \Phi(\mu_i)} & \text{si } y_i = 0 \end{cases} \quad (13)$$

donde  $\mu_i = w^T x_i$  y  $\phi$  es la función de densidad de la normal estándar.

En el paso M, estimamos  $w$  usando regresión ridge, donde  $\mu = \mathbb{E}[z]$  es el resultado que intentamos predecir. Específicamente, tenemos

$$\hat{w} = (V_0^{-1} + X^T X)^{-1} X^T \mu \quad (14)$$

El algoritmo EM es simple, pero puede ser mucho más lento que los métodos de gradiente directo. Esto se debe a que la entropía posterior en el paso E es bastante alta, ya que solo observamos que  $z$  es positivo o negativo, pero no tenemos información de la verosimilitud sobre su magnitud. Usar un regularizador más fuerte puede ayudar a acelerar la convergencia porque restringe el rango de valores plausibles de  $z$ . Además, se pueden usar varios trucos de aceleración, como la aumentación de datos, pero no los discutimos aquí.

### 1.3. Muestreador de Gibbs con variables latentes

Recordemos la interpretación de variable latente de la regresión probit. Es sencillo convertir esta representación en un muestreador de Gibbs de variables auxiliares, ya que:

- La distribución posterior  $p(w|\mathcal{D})$  es Gaussiana.
- La distribución  $p(z_i|x_i, y_i, w)$  es Gaussiana truncada.

Ambas distribuciones son fáciles de muestrear. El muestreador de Gibbs procede iterativamente de la siguiente manera:

#### 1.3.1. Paso 1: Muestrear las variables latentes $z_i$

Para cada observación  $i$ , muestreemos  $z_i$  de su distribución condicional completa:

$$z_i \sim \begin{cases} \mathcal{N}(w^T x_i, 1) \text{ truncada en } (0, \infty) & \text{si } y_i = 1 \\ \mathcal{N}(w^T x_i, 1) \text{ truncada en } (-\infty, 0) & \text{si } y_i = 0 \end{cases} \quad (15)$$

#### 1.3.2. Muestreo desde una Gaussiana truncada

Para muestrear desde una distribución  $\mathcal{N}(\mu, \sigma^2)$  truncada al intervalo  $[a, b]$ , podemos usar el siguiente método (Robert 1995):

1. Muestrear  $u \sim \mathcal{U}(\Phi(\frac{a-\mu}{\sigma}), \Phi(\frac{b-\mu}{\sigma}))$
2. Calcular  $z = \mu + \sigma \Phi^{-1}(u)$

donde  $\Phi$  es la CDF de la normal estándar y  $\Phi^{-1}$  es su inversa. Este método funciona porque la CDF de una Gaussiana truncada es uniforme en el intervalo  $[0, 1]$ .

En nuestro caso particular:

- Si  $y_i = 1$ , tenemos  $a = 0, b = \infty$ , por lo que  $u \sim \mathcal{U}(\Phi(-\mu_i), 1)$  donde  $\mu_i = w^T x_i$ .
- Si  $y_i = 0$ , tenemos  $a = -\infty, b = 0$ , por lo que  $u \sim \mathcal{U}(0, \Phi(-\mu_i))$ .

#### 1.3.3. Paso 2: Muestrear los pesos $w$

Dado  $\mathbf{z} = (z_1, \dots, z_N)$ , tenemos un modelo de regresión lineal con ruido unitario. Usando una prior conjugada Gaussiana  $w \sim \mathcal{N}(0, V_0)$ , la posterior es:

$$w|\mathbf{z}, X \sim \mathcal{N}(\bar{w}, \bar{V}) \quad (16)$$

donde

$$\bar{V} = (V_0^{-1} + X^T X)^{-1} \quad (17)$$

$$\bar{w} = \bar{V} X^T \mathbf{z} \quad (18)$$

### 1.3.4. Algoritmo completo de Gibbs

El algoritmo de Gibbs para regresión probit es:

1. Inicializar  $w^{(0)}$  (por ejemplo, con estimación de máxima verosimilitud o ceros)
2. Para  $t = 1, 2, \dots, T$ :
  - a) Para cada  $i = 1, \dots, N$ :
    - Calcular  $\mu_i = (w^{(t-1)})^T x_i$
    - Si  $y_i = 1$ , muestrear  $u_i \sim \mathcal{U}(\Phi(-\mu_i), 1)$
    - Si  $y_i = 0$ , muestrear  $u_i \sim \mathcal{U}(0, \Phi(-\mu_i))$
    - Calcular  $z_i^{(t)} = \mu_i + \Phi^{-1}(u_i)$
  - b) Muestrear  $w^{(t)} \sim \mathcal{N}(\bar{w}, \bar{V})$  con  $\bar{V} = (V_0^{-1} + X^T X)^{-1}$  y  $\bar{w} = \bar{V} X^T \mathbf{z}^{(t)}$
3. Descartar las primeras  $B$  iteraciones como calentamiento (burn-in)

La ventaja de este enfoque es que evita tener que calcular costosas integrales o aproximaciones, y en su lugar utiliza muestreo directo de distribuciones conocidas. El algoritmo es particularmente útil cuando se desea obtener una estimación completa de la incertidumbre sobre los parámetros, a diferencia de EM que solo proporciona una estimación puntual.