

Notas de Simulación Estocástica

Yael Rene Santiago Cruz

2 de septiembre de 2026

Índice

1. Introducción	4
2. Simulación de Variables Aleatorias	4
2.1. Generador Lineal Congruencial (GLC)	4
2.2. Método de la Función Inversa	5
2.3. Método de aceptación y rechazo	7
2.4. Otros métodos para simular variables aleatorias	10
2.4.1. Algoritmo de Box-Muller	10
2.4.2. Distribución Gamma	11
2.4.3. Distribución Poisson (con λ pequeña)	11
2.4.4. Distribuciones extras	12
2.4.5. Mezcla de distribuciones	13
2.5. Simulación de vectores aleatorios	13
2.5.1. Método de aceptación y rechazo multivariado	13
2.5.2. Vector aleatorio con componentes independientes	14
2.5.3. Vector aleatorio normal multivariado	14
2.5.4. Simular vectores aleatorios usando densidades condicionales	14
2.5.5. Distribución Dirichlet	15
3. Simulación de Procesos Estocásticos	17
3.1. Proceso Poisson	17

3.1.1.	Definición del proceso de Poisson desde la perspectiva de los procesos de Lévy	18
3.1.2.	Caracterización del proceso de Poisson mediante tiempos de llegada condicionados	19
3.2.	Proceso de Poisson no homogéneo	21
3.3.	Proceso de Poisson compuesto	22
3.4.	Proceso de riesgo (modelo clásico de Cramér–Lundberg)	24
3.5.	Movimiento browniano	25
4.	Método Monte Carlo	27
4.1.	Integración numérica mediante Monte Carlo	28
4.2.	Estimación de la función de distribución	30
4.3.	Estimación de la función de densidad	32
4.4.	Estimación de la función cuantil	33
4.5.	Aproximación Monte Carlo de la esperanza del proceso Poisson compuesto	34
4.6.	Proceso de Cramér–Lundberg y probabilidad de ruina	36
4.6.1.	Probabilidad de ruina	38
4.7.	Valor en Riesgo (VaR) y Valor en Riesgo Condicional (CVaR)	39
4.7.1.	Caso particular: distribución exponencial	41
4.7.2.	Estimación empírica mediante Monte Carlo	41
5.	Métodos de reducción de varianza	42
5.1.	Variables antitéticas	42
5.2.	Variables de control	45
5.3.	Monte Carlo condicionado	47
5.4.	Muestreo estratificado	48
5.5.	Muestreo por importancia	51
5.5.1.	Valoración de una opción Call mediante Monte Carlo e Importance Sampling	55
5.5.2.	Muestreo por importancia normalizado	57
6.	Monte Carlo vía cadenas de Markov	59
6.1.	Cadenas de Markov con espacio de estados continuo	59

6.1.1.	Funciones de transición en n pasos	61
6.1.2.	Irreducibilidad, periodicidad y recurrencia	61
6.1.3.	Distribuciones estacionarias, distribuciones límite y reversibilidad	63
6.2.	Algoritmo de Metropolis-Hastings	64
6.2.1.	Regresión lineal bayesiana con Metropolis-Hastings	68
6.3.	Muestreo de Gibbs	70
6.3.1.	Esquema secuencial (Gibbs Secuencial)	70
6.3.2.	Esquema aleatorio (Gibbs Random Scan)	71
6.3.3.	Restauración de imágenes mediante Gibbs sampling	71
6.3.4.	Regresión lineal bayesiana con Gibbs sampling	73
6.4.	Monte Carlo Hamiltoniano (HMC)	75
7.	Optimización estocástica	77
7.1.	Algoritmo EM	78
7.1.1.	Monte Carlo EM	81
7.2.	Descenso de Gradiente Estocástico (SGD)	83
7.3.	Búsqueda Aleatoria	86
7.4.	Recocido Simulado	87
7.5.	Algoritmos Evolutivos	89
8.	Inferencia Variacional	90
8.1.	Divergencia de Kullback-Leibler y entropía	91
8.2.	Inferencia Variacional como optimización	92

1. Introducción

La simulación estocástica se encarga de estudiar los algoritmos numéricos para generar muestras de una variable aleatoria X con función de distribución $F(x)$, con el objetivo de visualizar los diferentes escenarios que se pueden obtener al modelar un experimento aleatorio y así poder calcular integrales o esperanzas. Por ejemplo, la ley débil de los grandes números nos dice que si $X_1, \dots, X_n$ son una sucesión de variables aleatorias independientes e idénticamente distribuidas tales que $\mathbb{E}[X_i] = \mu$ y $\text{Var}(X_i) = \sigma^2$, entonces

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{p} \mu.$$

Por lo tanto, si μ fuese difícil de calcular, podríamos simular un número de muestra grande de una variable aleatoria $X \sim F$ para aproximar la $\mathbb{E}[X]$. Es más, si h es una función medible tal que $\mathbb{E}[(h(X))^2] < \infty$, entonces

$$\mathbb{E}[h(X)] \approx \frac{1}{n} \sum_{i=1}^n h(X_i)$$

para n grande. Por ejemplo, si $h(x) = \mathbb{1}\{x \in A\}$ para $A \in \mathcal{B}(\mathbb{R})$, la esperanza se convierte en una probabilidad, es decir,

$$\mathbb{E}[h(X)] = \mathbb{E}[\mathbb{1}\{X \in A\}] = \mathbb{P}[X \in A] = \int_A dF(x).$$

Una vez que podamos simular muestras de diferentes variables aleatorias, también se pueden simular procesos estocásticos como el movimiento browniano, el proceso de Poisson, cadenas de Markov, etc.

2. Simulación de Variables Aleatorias

La forma de simular números aleatorios en una computadora es mediante algoritmos deterministas, esto los hace en realidad pseudoaleatorios, pero que siguen funcionando para modelar fenómenos, ya que se pueden utilizar pruebas de bondad de ajuste para verificar que los números generados efectivamente pertenecen a una muestra de una variable aleatoria. En este capítulo se estudiarán los métodos para generar números pseudoaleatorios en el intervalo $(0,1)$, los cuales serán suficientes para generar muestras de diferentes variables aleatorias.

2.1. Generador Lineal Congruencial (GLC)

Un generador lineal congruencial (GLC) es un método para generar una secuencia de números pseudoaleatorios calculados mediante una ecuación lineal. Se define por la relación de recurrencia:

$$X_{n+1} = (aX_n + c) \pmod{m}.$$

En donde:

- $a \in \mathbb{N}$ es el multiplicador.
- $c \in \mathbb{N}$ es el incremento.
- $m \in \mathbb{N}$, $m \geq 2$, es el módulo.
- $X_0 \in \mathbb{N}$ es la semilla (valor inicial).

Es evidente que cada número generado por esta sucesión es tal que $0 \leq X_n < m$, por tanto, si definimos a la sucesión normalizada $U_n = X_n/m$, obtenemos valores en el intervalo $[0,1)$, que se utilizan como una aproximación computacional a una sucesión de variables aleatorias uniformes.

El período máximo del GLC es igual al módulo m , pero esto solo se logra si:

1. c y m son primos relativos.
2. a es divisible por todos los factores primos de m .
3. Si m es divisible por 4, entonces $a - 1$ también debe serlo.

En 1988, Park y Miller sugirieron los parámetros particulares $m = 2^{31} - 1$ y $a = 7^5$, con $c = 0$.

2.2. Método de la Función Inversa

Este es un método que nos ayuda a generar muestras de una variable aleatoria usando la inversa generalizada de una función de distribución. Sea X una variable aleatoria con función de distribución F , entonces se define la función inversa generalizada asociada a esta como:

$$F^{-1}(u) = \inf\{x : F(x) \geq u\}$$

para $u \in (0, 1]$.

En el caso cuando $F(x)$ es estrictamente creciente, su función inversa existe y coincide con la inversa generalizada.

El método de la función inversa se sustenta por el siguiente resultado: sea X una variable aleatoria con función de distribución $F(x)$ y $F^{-1}(u)$ su inversa generalizada respectiva. Entonces, si $U \sim \text{Unif}(0, 1)$,

$$F^{-1}(U) \stackrel{d}{=} X.$$

Para demostrar este resultado primero se prueba que

$$(F^{-1}(U) \leq x) = (U \leq F(x)),$$

y por lo tanto

$$\mathbb{P}[F^{-1}(U) \leq x] = \mathbb{P}[U \leq F(x)] = F(x).$$

Ejemplo 2.1. Sea $X \sim \text{Exp}(\lambda)$, entonces para $x > 0$,

$$F(x) = 1 - e^{-\lambda x}$$

y por lo tanto

$$F^{-1}(u) = \frac{\log(1-u)}{-\lambda}.$$

Y como $1 - U \sim U(0, 1)$ se cumple que

$$F^{-1}(U) \stackrel{d}{=} \frac{\log(U)}{-\lambda}.$$

Ejemplo 2.2. Sea X con función de distribución

$$F(x) = \frac{1}{1 + e^{-x}} \quad \forall x \in \mathbb{R}.$$

Entonces

$$F^{-1}(u) = \log\left(\frac{u}{1-u}\right).$$

Ejemplo 2.3. Sea $X_1, X_2, \dots, X_n$ una muestra de la variable aleatoria $X \sim F(x)$ continua y sean

$$X_{(1)} = \min\{X_1, \dots, X_n\} \quad y \quad X_{(n)} = \max\{X_1, \dots, X_n\}.$$

Entonces

$$\begin{aligned} F_{X_{(n)}}(x) &= \mathbb{P}[X_{(n)} \leq x] \\ &= \mathbb{P}[X_1 \leq x, \dots, X_n \leq x] \\ &= \prod_{i=1}^n \mathbb{P}[X_i \leq x] \\ &= F(x)^n. \end{aligned}$$

Por lo tanto,

$$F_{X(n)}^{-1}(u) = F^{-1}(u^{1/n}), \quad 0 < u < 1.$$

De manera análoga se puede demostrar que

$$F_{X(1)}^{-1}(u) = F^{-1}(1 - (1 - u)^{1/n}) \stackrel{d}{=} F^{-1}(1 - u^{1/n}).$$

Ejemplo 2.4. Sea X una variable aleatoria que toma valores en el conjunto $\{x_1, \dots, x_n\}$, tal que $\mathbb{P}(X = x_i) = p_i$ y $\sum_{i=1}^n p_i = 1$. Entonces

$$F^{-1}(u) = \begin{cases} x_1, & \text{si } 0 < u < p_1, \\ x_2, & \text{si } p_1 \leq u < p_1 + p_2, \\ \vdots & \\ x_n, & \text{si } p_1 + p_2 + \dots + p_{n-1} \leq u < 1. \end{cases}$$

Cuando $n = 2$, $x_1 = 0$ y $x_2 = 1$, obtenemos el caso de la distribución Bernoulli. Este método también se puede usar cuando la variable aleatoria toma valores en un conjunto numerable $\{X_1, X_2, \dots\}$, por ejemplo, las variables aleatorias pertenecientes a la clase $(a, b, 0)$. Una variable aleatoria discreta X pertenece a la clase $(a, b, 0)$ si

$$p_k = \left(a + \frac{b}{k}\right) p_{k-1},$$

donde $a, b \in \mathbb{R}$ y $p_k = \mathbb{P}[X = k]$ para $k = 0, 1, 2, \dots$

Esta clase de distribuciones solo posee tres miembros: la binomial, la Poisson y la binomial negativa.

2.3. Método de aceptación y rechazo

Sea X una variable aleatoria continua con función de densidad de probabilidad $f(x)$, de la cual deseamos generar simulaciones. El método de aceptación y rechazo consiste en elegir una variable aleatoria auxiliar Y , de la cual sabemos simular, y un criterio de aceptación, de tal manera que Y condicionada a este tenga la distribución de interés asociada a X .

En particular, consideramos Y con función de densidad g y una constante $M > 1$ tales que

$$f(x) \leq M g(x) \quad \forall x \in \mathbb{R}.$$

Sea $U \sim \text{Unif}(0, 1)$, independiente de Y , entonces

$$Y \mid \left(U \leq \frac{f(Y)}{M g(Y)} \right) \sim f(x).$$

Este resultado se justifica por el siguiente cálculo:

$$\begin{aligned}
\mathbb{P}\left[Y \leq x \mid U \leq \frac{f(Y)}{Mg(Y)}\right] &= \frac{\mathbb{P}\left[Y \leq x, U \leq \frac{f(Y)}{Mg(Y)}\right]}{\mathbb{P}\left[U \leq \frac{f(Y)}{Mg(Y)}\right]} \\
&= \frac{\int_{-\infty}^x \int_0^{f(y)/(Mg(y))} g(y) \, du \, dy}{\int_{-\infty}^{\infty} \int_0^{f(y)/(Mg(y))} g(y) \, du \, dy} \\
&= \frac{\int_{-\infty}^x g(y) \frac{1}{M} \frac{f(y)}{g(y)} \, dy}{\int_{-\infty}^{\infty} g(y) \frac{1}{M} \frac{f(y)}{g(y)} \, dy} \\
&= \frac{\int_{-\infty}^x \frac{1}{M} f(y) \, dy}{\int_{-\infty}^{\infty} \frac{1}{M} f(y) \, dy} \\
&= \int_{-\infty}^x f(y) \, dy \\
&= \mathbb{P}[X \leq x].
\end{aligned}$$

Por lo tanto, para simular de X se debe realizar el siguiente algoritmo:

1. Simular de $Y \sim g$ y $U \sim Unif(0, 1)$.
2. Aceptar $X = Y$ si

$$U \leq \frac{f(Y)}{Mg(Y)}.$$

En caso contrario, regresar a 1.

Notamos que

$$\mathbb{P}[\text{Aceptar}] = \mathbb{P}\left[U \leq \frac{f(Y)}{Mg(Y)}\right] = \frac{1}{M},$$

es decir, si M es grande vamos a aceptar muy pocas veces y eso hace que el algoritmo sea deficiente.

Ejemplo 2.5. Sea $X \sim \text{Gamma}(\alpha, 1)$ con $\alpha > 1$ y $Y \sim \text{Exp}(\lambda)$ con $\lambda < 1$.

Para usar aceptación y rechazo queremos encontrar M tal que

$$f_X(x) \leq Mg_Y(x)$$

para toda $x > 0$, o equivalentemente, maximizar el cociente

$$h(x) = \frac{f_X(x)}{g_Y(x)}.$$

Pero

$$h(x) = \frac{\lambda^{-1}}{\Gamma(\alpha)} x^{\alpha-1} e^{-(1-\lambda)x}$$

y como

$$h'(x) = \frac{\lambda^{-1}}{\Gamma(\alpha)} e^{-(1-\lambda)x} x^{\alpha-2} [\alpha - 1 - x(1-\lambda)],$$

se tiene que

$$h'(x) > 0 \iff x < \frac{\alpha - 1}{1 - \lambda}$$

y

$$h'(x) < 0 \iff x > \frac{\alpha - 1}{1 - \lambda}.$$

Por lo tanto, $h(x)$ alcanza el máximo en

$$x^* = \frac{\alpha - 1}{1 - \lambda}.$$

Además, si queremos optimizar la tasa de aceptación basta con minimizar

$$M(\lambda) = \frac{\lambda^{-1}}{\Gamma(\alpha)} \left(\frac{\alpha - 1}{1 - \lambda} \right)^{\alpha-1} e^{-(\alpha-1)}$$

o lo que es igual, minimizar

$$M(\lambda) = -\log(\lambda) + (1 - \alpha) \log(1 - \lambda).$$

Se puede demostrar que el valor óptimo es

$$\lambda^* = \frac{1}{\alpha}.$$

Ejemplo 2.6. *Sea $X \sim \text{Beta}(\alpha, \beta)$ con $\alpha, \beta \geq 1$. En este caso la función de densidad de X está acotada en el intervalo $[0, 1]$ y se cumple que*

$$f_X(x) = \frac{x^{\alpha-1}(1-x)^{\beta-1}}{B(\alpha, \beta)} \leq \frac{(\alpha-1)^{\alpha-1}(\beta-1)^{\beta-1}}{B(\alpha, \beta)(\alpha+\beta-2)^{\alpha+\beta-2}} = M$$

para toda $x \in (0, 1)$.

Entonces, si Y es una variable aleatoria uniforme en el intervalo $(0, 1)$, podremos utilizarla como variable auxiliar en el algoritmo de aceptación y rechazo.

2.4. Otros métodos para simular variables aleatorias

En esta sección se explicarán otros métodos para generar muestras de las variables aleatorias más usadas, como la Normal, Gamma y Poisson.

2.4.1. Algoritmo de Box-Muller

Sean U_1 y U_2 independientes e idénticamente distribuidas uniformemente en $(0, 1)$. El método de la transformada inversa $X = -2 \log(U_1)$ tiene distribución $\text{Exp}(1/2)$. Entonces,

$$Y_1 = \sqrt{X} \cos(2\pi U_2) \quad \text{y} \quad Y_2 = \sqrt{X} \sin(2\pi U_2)$$

son variables aleatorias independientes con distribución $N(0, 1)$. Para demostrar esta afirmación utilizamos el teorema de cambio de variable. Notemos que

$$Y_1^2 + Y_2^2 = X$$

y

$$U_2 = \frac{\arctan(Y_2/Y_1)}{2\pi}.$$

Además, como

$$|J_{T^{-1}}(x, u_2)| = \frac{1}{2\pi},$$

se tiene que

$$\begin{aligned} f_{Y_1, Y_2}(y_1, y_2) &= \frac{1}{2\pi} e^{-\frac{1}{2}(y_1^2 + y_2^2)} \mathbb{1}_{\{(y_1^2 + y_2^2) \geq 0\}} \mathbb{1}_{\{\arctan(y_2/y_1)/(2\pi) \in (0, 1)\}} \\ &= \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}y_1^2} \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}y_2^2}, \quad \forall y_1, y_2 \in \mathbb{R}. \end{aligned}$$

Por lo tanto, Y_1 y Y_2 son independientes y ambas tienen distribución $N(0, 1)$.

2.4.2. Distribución Gamma

En la sección anterior se utilizó el método de aceptación y rechazo para simular $X \sim \text{Gamma}(\alpha, 1)$ con $\alpha > 1$. Es fácil probar que $W = X/\beta$ tiene distribución $\text{Gamma}(\alpha, \beta)$ para $\beta > 0$. Además, también se puede usar cambio de variable para mostrar que si $\alpha \leq 1$, $U \sim U(0, 1)$ y $Z \sim \text{Gamma}(\alpha + 1, \beta)$, entonces

$$Y = ZU^{1/\alpha}$$

se distribuye como $\text{Gamma}(\alpha, \beta)$.

Otra forma de simular $X \sim \text{Gamma}(n, \beta)$ con $n \in \mathbb{N}$ es sumando $X_1, \dots, X_n$ variables independientes con distribución $\text{Exp}(\beta)$. Si tomamos una sucesión $U_1, \dots, U_n$ de variables independientes e idénticamente distribuidas uniformes en el intervalo $(0, 1)$, podemos utilizar el método de la transformada inversa para concluir que

$$-\frac{1}{\beta} \log \left(\prod_{i=1}^n U_i \right) \sim \text{Gamma}(n, \beta).$$

2.4.3. Distribución Poisson (con λ pequeña)

Sea $X \sim \text{Poisson}(\lambda)$ con λ pequeña. Para simular de esta variable aleatoria podemos usar lo siguiente: si $X_1, X_2, \dots$ son variables aleatorias independientes, tales que $X_i \sim \text{Exp}(\lambda)$ para toda $i = 1, 2, \dots$, y

$$Y = \max \left\{ k \geq 0 : \sum_{i=1}^k X_i \leq 1 \right\},$$

entonces

$$\begin{aligned}
\mathbb{P}[Y = j] &= \mathbb{P}[Y \geq j] - \mathbb{P}[Y \geq j + 1] \\
&= \mathbb{P}\left[\sum_{i=1}^j X_i \leq 1\right] - \mathbb{P}\left[\sum_{i=1}^{j+1} X_i \leq 1\right] \\
&= \int_0^1 \frac{x^{j-1} \lambda^j}{(j-1)!} e^{-\lambda x} dx - \int_0^1 \frac{x^j \lambda^{j+1}}{j!} e^{-\lambda x} dx \\
&= \int_0^1 \frac{\lambda^j}{j!} [j x^{j-1} e^{-\lambda x} - x^j \lambda e^{-\lambda x}] dx \\
&= \int_0^1 \frac{\lambda^j}{j!} \frac{d}{dx} (x^j e^{-\lambda x}) dx \\
&= \frac{\lambda^j}{j!} (x^j e^{-\lambda x}) \Big|_0^1 \\
&= e^{-\lambda} \frac{\lambda^j}{j!}.
\end{aligned}$$

Esto implica que $Y \sim \text{Poisson}(\lambda)$.

2.4.4. Distribuciones extras

Algunos otros ejemplos de distribuciones que podemos simular son: $\text{Log-Normal}(\mu, \sigma^2)$, $\chi_{(n)}^2$ y $\text{Laplace}(\mu, b)$. Si $X \sim N(0, 1)$, entonces

$$Y = \exp(\mu + \sigma X) \sim \text{Log-Normal}(\mu, \sigma^2).$$

Para simular de $Y \sim \chi_{(n)}^2$ debemos sumar n variables independientes con distribución normal estándar elevadas al cuadrado, o recordando que

$$Y \sim \text{Gamma}\left(\frac{n}{2}, \frac{1}{2}\right).$$

Para simular de la distribución Laplace existen los siguientes métodos:

- Si X_1 y X_2 son variables aleatorias independientes con distribución $\text{Exp}(b)$ y $\mu \in \mathbb{R}$, entonces

$$Y = \mu + (X_1 - X_2) \sim \text{Laplace}(\mu, b).$$

- Con el método de la función inversa, usando que esta es

$$F^{-1}(u) = \mu - b \operatorname{sgn}\left(u - \frac{1}{2}\right) \log\left(1 - 2\left|u - \frac{1}{2}\right|\right),$$

donde

$$\text{sgn}(x) = \begin{cases} 1, & \text{si } x > 0, \\ 0, & \text{si } x = 0, \\ -1, & \text{si } x < 0. \end{cases}$$

- Si $X \sim \text{Exp}(1)$ y $Z \sim N(0, 1)$ son independientes, se cumple que

$$Y = \mu + b\sqrt{2X} Z \sim \text{Laplace}(\mu, b).$$

2.4.5. Mezcla de distribuciones

Decimos que una variable aleatoria es una mezcla de distribuciones continuas si su función de densidad de probabilidad es de la forma

$$f(x) = \sum_{j=1}^K w_j f_j(x),$$

en donde $w_j \in (0, 1)$, $\sum_{j=1}^K w_j = 1$ y $f_j(x)$ es una función de densidad de probabilidad continua para toda $j = 1, 2, \dots, K$ y $K \in \mathbb{N}$. Es fácil demostrar que si Z es una variable aleatoria discreta que toma valores en $\{1, 2, \dots, K\}$, tal que $\mathbb{P}[Z = j] = w_j$ para $j = 1, 2, \dots, K$ y $X | Z = j \sim f_j(x)$, entonces $X \sim f(x)$, donde

$$f(x) = \sum_{j=1}^K w_j f_j(x).$$

2.5. Simulación de vectores aleatorios

En esta sección estudiaremos los métodos para generar muestras de vectores aleatorios. Estos procedimientos son similares al caso unidimensional.

2.5.1. Método de aceptación y rechazo multivariado

Sea $f(x_1, \dots, x_n)$ una función de densidad con soporte en $A \subseteq \mathbb{R}^n$. Sea $(X_1, \dots, X_n)$ con función de densidad $g(x_1, \dots, x_n)$ tal que:

1. El soporte de $g(x_1, \dots, x_n)$ contiene al soporte A .
2. Se conoce una forma de simular valores de la distribución $g(x_1, \dots, x_n)$.
3. Existe una constante $M \geq 1$ tal que

$$f(x_1, \dots, x_n) \leq Mg(x_1, \dots, x_n).$$

Sea $U \sim \text{Unif}(0, 1)$ independiente del vector $(X_1, \dots, X_n)$. Entonces

$$(X_1, \dots, X_n) \mid \left(U \leq \frac{f(X_1, \dots, X_n)}{Mg(X_1, \dots, X_n)} \right) \sim f(x_1, \dots, x_n).$$

2.5.2. Vector aleatorio con componentes independientes

Para generar vectores aleatorios independientes, solamente se debe simular una muestra independiente entrada por entrada. Por ejemplo, si queremos obtener una simulación de

$$Z \sim N(0, I_n),$$

debemos simular n variables aleatorias independientes normales estándar.

2.5.3. Vector aleatorio normal multivariado

Supongamos que $Z \sim N(0, I_n)$ y sea $X \sim N(\mu, \Sigma)$ tal que $\Sigma = LL^T$, con L una matriz triangular inferior. Entonces,

$$\mu + LZ \stackrel{d}{=} X.$$

2.5.4. Simular vectores aleatorios usando densidades condicionales

Sea (X, Y) un vector aleatorio con función de densidad de probabilidad conjunta $f_{X,Y}(x, y)$. Entonces, usando la regla de Bayes,

$$f_{X,Y}(x, y) = f_{X|Y}(x | y)f_Y(y).$$

Por lo tanto, si conocemos la manera de simular valores de $f_Y(y)$ y $f_{X|Y}(x | y)$, el siguiente algoritmo nos dará un método para simular muestras de (X, Y) :

1. Simular $Y \sim f_Y(y)$.
2. Simular de $X | Y = y \sim f_{X|Y}(x | y)$.
3. El vector $(X, Y) \sim f_{X,Y}(x, y)$.

Ejemplo 2.7. Sea (X, Y) con distribución uniforme en el disco de radio 1, es decir,

$$f_{X,Y}(x, y) = \frac{1}{\pi} \mathbb{1}_{\{x^2+y^2 \leq 1\}}.$$

Además, como

$$f_Y(y) = \int_{-\sqrt{1-y^2}}^{\sqrt{1-y^2}} \frac{1}{\pi} dx = \frac{2}{\pi} \sqrt{1-y^2}, \quad y \in (-1, 1),$$

se cumple que

$$\begin{aligned} f_{X|Y}(x | y) &= \frac{f_{X,Y}(x, y)}{f_Y(y)} \\ &= \frac{1}{2\sqrt{1-y^2}} \mathbb{1}_{\{|x| < \sqrt{1-y^2}\}}. \end{aligned}$$

Por lo tanto,

$$X | Y = y \sim \text{Unif} \left(-\sqrt{1-y^2}, \sqrt{1-y^2} \right).$$

Ejemplo 2.8. La distribución Normal-Inversa Gamma se utiliza en Estadística Bayesiana y se define de la siguiente manera: Sea (X, Y) un vector aleatorio tal que

$$X | Y = y \sim N \left(\mu, \frac{1}{y} \right)$$

y

$$Y \sim \text{Gamma}(a, b),$$

donde μ , a y b son constantes conocidas.

2.5.5. Distribución Dirichlet

La distribución Dirichlet es una distribución de probabilidad multivariada sobre el simplex de dimensión $K - 1$, es decir, sobre vectores $\mathbf{p} = (p_1, \dots, p_K)$ que satisfacen

$$p_i \geq 0, \quad \sum_{i=1}^K p_i = 1.$$

Es la generalización natural de la distribución Beta al caso multivariado y se utiliza ampliamente como distribución a priori para vectores de probabilidad, como en modelos de mezclas o en inferencia bayesiana para datos categóricos.

Un vector aleatorio $\mathbf{P} = (P_1, \dots, P_K)$ sigue una distribución Dirichlet con parámetro $\boldsymbol{\alpha} = (\alpha_1, \dots, \alpha_K)$, con $\alpha_i > 0$, si su función de densidad conjunta es

$$f(\mathbf{p} \mid \boldsymbol{\alpha}) = \frac{\Gamma\left(\sum_{i=1}^K \alpha_i\right)}{\prod_{i=1}^K \Gamma(\alpha_i)} \prod_{i=1}^K p_i^{\alpha_i-1},$$

para $\mathbf{p}$ en el simplex $p_i \geq 0$, $\sum_{i=1}^K p_i = 1$. Se denota

$$\mathbf{P} \sim \text{Dirichlet}(\boldsymbol{\alpha}).$$

La forma más sencilla de generar valores de una Dirichlet es mediante la siguiente propiedad: si $Y_1, \dots, Y_K$ son variables aleatorias independientes con

$$Y_i \sim \text{Gamma}(\alpha_i, 1),$$

entonces el vector

$$P_i = \frac{Y_i}{\sum_{j=1}^K Y_j}, \quad i = 1, \dots, K,$$

tiene distribución $\text{Dirichlet}(\boldsymbol{\alpha})$. Esta propiedad es fundamental para la simulación y también revela la estructura de la distribución.

Las distribuciones marginales de la Dirichlet tienen una forma simple y están estrechamente relacionadas con la distribución Beta. En particular, para cada i ,

$$P_i \sim \text{Beta}(\alpha_i, \alpha_0 - \alpha_i),$$

donde $\alpha_0 = \sum_{j=1}^K \alpha_j$. Es decir, cada componente individual sigue una distribución Beta con parámetros α_i y $\alpha_0 - \alpha_i$.

Más aún, si se agrupan componentes, la suma de un subconjunto también sigue una distribución Beta. Por ejemplo,

$$\sum_{i=1}^m P_i \sim \text{Beta}\left(\sum_{i=1}^m \alpha_i, \sum_{i=m+1}^K \alpha_i\right).$$

Esta propiedad de agregación es muy útil en modelos jerárquicos y en aplicaciones de agrupamiento.

Para simular un vector $\mathbf{P} \sim \text{Dirichlet}(\boldsymbol{\alpha})$, se sigue el siguiente algoritmo:

1. Para $i = 1, \dots, K$, generar $Y_i \sim \text{Gamma}(\alpha_i, 1)$ de forma independiente.
2. Calcular $S = \sum_{i=1}^K Y_i$.
3. Definir $P_i = Y_i/S$ para $i = 1, \dots, K$.

El vector resultante $(P_1, \dots, P_K)$ tiene distribución $\text{Dirichlet}(\boldsymbol{\alpha})$.

La distribución Dirichlet es una herramienta fundamental en estadística bayesiana, especialmente como distribución a priori para modelos multinomiales y en modelos de mezclas finitas. Su flexibilidad y la facilidad de simulación a partir de Gammas la convierten en una elección natural para problemas donde se requiere modelar probabilidades sobre categorías.

3. Simulación de Procesos Estocásticos

3.1. Proceso Poisson

Supongamos que una compañía de seguros recibe una reclamación en un tiempo exponencial de parámetro λ , denotado por T_1 . Entonces recibe otra reclamación en un tiempo

$$T_2 \sim \text{Exp}(\lambda),$$

independiente de T_1 . Por lo tanto, el tiempo en el que llega la segunda reclamación es

$$S_2 = T_1 + T_2.$$

Realizando esto de manera sucesiva, podemos concluir que el tiempo en el que llega la n -ésima reclamación es

$$S_n = \sum_{i=1}^n T_i.$$

Si para $t > 0$ definimos

$$N(t) = \text{máx}\{n \in \mathbb{N} : S_n \leq t\},$$

entonces a $N(t)$ se le llama **proceso Poisson** y representa el número de reclamaciones que han llegado hasta el tiempo t .




Figura 1: Trayectoria de un proceso de Poisson con tiempos entre llegadas T_i y tiempos de llegada S_i .

Notemos que para $k \geq 0$,

$$\begin{aligned} \mathbb{P}(N(t) = k) &= \mathbb{P}(N(t) = k) + \mathbb{P}(N(t) \geq k+1) - \mathbb{P}(N(t) \geq k+1) \\ &= \mathbb{P}(N(t) \geq k) - \mathbb{P}(N(t) \geq k+1) \\ &= \mathbb{P}(S_k \leq t) - \mathbb{P}(S_{k+1} \leq t). \end{aligned}$$

Como $S_k \sim \text{Gamma}(k, \lambda)$ para $k \in \mathbb{N}$, entonces

$$\begin{aligned}
\mathbb{P}(N(t) = k) &= \int_0^t \frac{\lambda^k x^{k-1} e^{-\lambda x}}{\Gamma(k)} dx - \int_0^t \frac{\lambda^{k+1} x^k e^{-\lambda x}}{\Gamma(k+1)} dx \\
&= \frac{\lambda^k}{\Gamma(k+1)} \int_0^t (k x^{k-1} e^{-\lambda x} - \lambda x^k e^{-\lambda x}) dx \\
&= \frac{\lambda^k}{\Gamma(k+1)} \int_0^t \frac{d}{dx} (x^k e^{-\lambda x}) dx \\
&= \frac{\lambda^k}{\Gamma(k+1)} t^k e^{-\lambda t}.
\end{aligned}$$

Como $\Gamma(k+1) = k!$, obtenemos

$$\mathbb{P}(N(t) = k) = \frac{(\lambda t)^k}{k!} e^{-\lambda t}.$$

Por lo tanto,

$$N(t) \sim \text{Poisson}(\lambda t).$$

Esta construcción del proceso de Poisson nos conduce de manera natural al siguiente algoritmo para su simulación hasta un tiempo final t_f :

1. Inicializamos $n = 0$, $T_0 = 0$.
2. Hasta que

$$S_n = \sum_{i=0}^n T_i > t_f$$

realizamos los siguientes pasos:

a) Simulamos

$$T_{n+1} \sim \text{Exp}(\lambda).$$

b) Definimos

$$N(t) = n \quad \text{para} \quad t \in [S_n, S_{n+1}).$$

c) Actualizamos $n \leftarrow n + 1$.

3.1.1. Definición del proceso de Poisson desde la perspectiva de los procesos de Lévy

Otra forma equivalente de caracterizar un proceso de Poisson $\{N(t)\}_{t \geq 0}$ de intensidad $\lambda > 0$ es mediante las siguientes propiedades:

1. $N(0) = 0$.
2. Tiene incrementos independientes: para cualquier sucesión $0 \leq t_0 < t_1 < \dots < t_n$, las variables

$$N(t_1) - N(t_0), N(t_2) - N(t_1), \dots, N(t_n) - N(t_{n-1})$$

son independientes.

3. Tiene incrementos estacionarios: para cualesquiera $s, t \geq 0$,

$$N(t + s) - N(s) \sim \text{Poisson}(\lambda t).$$

Precisamente esta caracterización es la que nos permite construir el siguiente algoritmo para simular el proceso sobre una malla de tiempos $t_0 = 0 < t_1 < \dots < t_n$. El procedimiento consiste en generar recursivamente los valores $N_i = N(t_i)$:

1. Inicializamos $N_0 = 0$.
2. Para $i = 1, \dots, n$:
 - a) Simulamos $X \sim \text{Poi}(\lambda(t_i - t_{i-1}))$.
 - b) Definimos $N_i = N_{i-1} + X$.

3.1.2. Caracterización del proceso de Poisson mediante tiempos de llegada condicionados

Una propiedad fundamental de los procesos de Poisson es la distribución de los tiempos de llegada condicionada a que haya ocurrido un número fijo de eventos. Para estudiarla, partimos de los tiempos entre llegadas $T_1, T_2, \dots$, que son variables aleatorias independientes con distribución $\text{Exp}(\lambda)$. Así, el vector $(T_1, \dots, T_n, T_{n+1})$ tiene densidad conjunta

$$f(\mathbf{s}) = \prod_{i=1}^{n+1} \lambda e^{-\lambda s_i} = \lambda^{n+1} e^{-\lambda \sum_{i=1}^{n+1} s_i}.$$

Ahora bien, los tiempos de llegada S_k se definen como las sumas acumuladas de los tiempos entre llegadas, es decir, $S_k = T_1 + \dots + T_k$. Para trabajar con ellos, consideramos la transformación

$$(T_1, \dots, T_n, T_{n+1}) \mapsto (S_1, \dots, S_n, S_{n+1}) = \left(T_1, T_1 + T_2, \dots, \sum_{i=1}^{n+1} T_i \right),$$

cuyo jacobiano es una matriz triangular inferior con unos en la diagonal,

$$J_f(\mathbf{x}) = \begin{pmatrix} 1 & 0 & 0 & \dots & 0 \\ 1 & 1 & 0 & \dots & 0 \\ 1 & 1 & 1 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & 1 & 1 & \dots & 1 \end{pmatrix},$$

por lo que su determinante es igual a 1.

Gracias a esto, podemos calcular la probabilidad conjunta de que los primeros n tiempos de llegada pertenezcan a un conjunto A y que además el proceso tenga exactamente n llegadas en el instante t , es decir, $\mathbb{P}[(S_1, \dots, S_n) \in A, N(t) = n]$. Para ello, integramos la densidad conjunta sobre la región en la que $0 < s_1 \leq s_2 \leq \dots \leq s_n \leq t < s_{n+1}$. Al sustituir la suma de exponenciales y simplificar, obtenemos

$$\begin{aligned} \mathbb{P}[(S_1, \dots, S_n) \in A, N(t) = n] &= \int_{(s_1, \dots, s_n, s_{n+1}) \in A \times [t, \infty)} \mathbb{1}\{0 < s_1 \leq s_2 \leq \dots \leq s_n \leq t\} \lambda^{n+1} e^{-\lambda s_{n+1}} ds_{n+1} \dots ds_1 \\ &= \int_{(s_1, \dots, s_n) \in A} \mathbb{1}\{0 < s_1 \leq s_2 \leq \dots \leq s_n \leq t\} \lambda^n e^{-\lambda t} ds_n \dots ds_1. \end{aligned}$$

Dado que $\mathbb{P}(N(t) = n) = e^{-\lambda t} (\lambda t)^n / n!$, al dividir la expresión anterior por esta probabilidad obtenemos la densidad condicional

$$f_{(S_1, \dots, S_n) | N(t)=n}(s_1, \dots, s_n) = \frac{n!}{t^n} \mathbb{1}\{0 < s_1 \leq s_2 \leq \dots \leq s_n \leq t\}.$$

Esta densidad es exactamente la de los estadísticos de orden de n variables aleatorias independientes con distribución $\text{Unif}(0, t)$. Por tanto, condicionado a que $N(t) = n$, los tiempos de llegada se comportan como los valores ordenados de una muestra uniforme en $[0, t]$.

Esta valiosa caracterización da lugar a un método alternativo y muy eficiente para simular el proceso de Poisson hasta un tiempo final t_f . En lugar de generar tiempos entre llegadas de forma secuencial, el algoritmo procede de la siguiente manera: primero se simula el número total de saltos que ocurrirán en el intervalo $[0, t_f]$, el cual sigue una distribución de Poisson de parámetro λt_f , es decir, $N \sim \text{Poi}(\lambda t_f)$. A continuación, se generan N variables aleatorias independientes $U_1, \dots, U_N$ con distribución uniforme en $[0, t_f]$. Finalmente, el proceso se reconstruye en cualquier instante t contando cuántos de esos valores uniformes son menores o iguales que t , esto es,

$$N(t) = \sum_{i=1}^N \mathbb{1}\{U_i \leq t\}.$$

Para verificar que este procedimiento es consistente con la definición original del proceso de Poisson, basta con comprobar que el valor esperado de $N(t)$ obtenido con esta construcción coincide con λt . Efectivamente,

$$\begin{aligned} \mathbb{E}[N(t)] &= \mathbb{E}[\#\{i : S_i \leq t\}] \\ &= \sum_{j=1}^{\infty} j \mathbb{P}(S_j \leq t, T_{j+1} > t - S_j) \\ &= \sum_{j=1}^{\infty} j \int_0^t \frac{\lambda^j}{(j-1)!} u^{j-1} e^{-\lambda u} e^{-\lambda(t-u)} du \\ &= e^{-\lambda t} \sum_{j=1}^{\infty} \frac{(\lambda t)^j}{(j-1)!} \\ &= \lambda t. \end{aligned}$$

Esta última igualdad confirma que el proceso así construido posee la media correcta y, por la forma en que se ha derivado a partir de las propiedades de los incrementos, también reproduce todas las características de un proceso de Poisson estándar.

3.2. Proceso de Poisson no homogéneo

Una generalización natural del proceso de Poisson homogéneo consiste en permitir que la intensidad varíe con el tiempo. Formalmente, dada una función medible $\lambda : \mathbb{R}^+ \rightarrow \mathbb{R}^+$, llamada *función de intensidad*, un proceso estocástico $\{N(t) : t \geq 0\}$ es un proceso de Poisson no homogéneo con intensidad λ si satisface las siguientes condiciones:

1. $N(0) = 0$.
2. Tiene incrementos independientes: para cualquier sucesión $0 \leq t_0 < t_1 < \dots < t_n$, las variables

$$N(t_1) - N(t_0), N(t_2) - N(t_1), \dots, N(t_n) - N(t_{n-1})$$

son independientes.

3. Tiene incrementos con distribución de Poisson no estacionaria: para cualesquiera $0 \leq s < t$,

$$N(t) - N(s) \sim \text{Poisson} \left(\int_s^t \lambda(u) du \right).$$

Esta caracterización es la contrapartida no homogénea de la que vimos para el caso de intensidad constante. A partir de ella, el algoritmo de simulación más directo consiste en discretizar el tiempo en una malla $t_0 = 0 < t_1 < \dots < t_n$ y generar los valores $N_i = N(t_i)$ de forma recursiva:

1. Inicializar $N_0 = 0$.
2. Para $i = 1, \dots, n$:
 - a) Simular $X \sim \text{Poi} \left(\int_{t_{i-1}}^{t_i} \lambda(s) ds \right)$.
 - b) Definir $N_i = N_{i-1} + X$.

Este procedimiento es sencillo de implementar siempre que se pueda calcular (o aproximar numéricamente) la integral de λ en cada subintervalo. Sin embargo, al igual que en el caso homogéneo, existe una caracterización alternativa basada en el condicionamiento que da lugar a un método de simulación cualitativamente distinto. En efecto, condicionado a que $N(t) = n$, la densidad conjunta de los tiempos de llegada $S_1, \dots, S_n$ (ordenados) viene dada por

$$f_{(S_1, \dots, S_n) | N(t)=n}(s_1, \dots, s_n) = n! \prod_{i=1}^n \left(\frac{\lambda(s_i)}{\int_0^t \lambda(u) du} \right) \mathbb{1} \{0 < s_1 \leq s_2 \leq \dots \leq s_n \leq t\}.$$

Esta expresión revela que, condicionado a que haya exactamente n eventos en $[0, t]$, los tiempos de llegada se distribuyen como los estadísticos de orden de n variables aleatorias independientes con densidad común

$$f(x) = \frac{\lambda(x)}{\int_0^t \lambda(u) du}, \quad 0 \leq x \leq t.$$

Este resultado sugiere el siguiente algoritmo alternativo para simular el proceso hasta un tiempo final t_f :

1. Simular el número total de saltos en $[0, t_f]$:

$$N \sim \text{Poi}\left(\int_0^{t_f} \lambda(u) du\right).$$

2. Si $N = 0$, el proceso no tiene saltos; en caso contrario, generar N variables aleatorias independientes $U_1, \dots, U_N$ con densidad

$$f(u) = \frac{\lambda(u)}{\int_0^{t_f} \lambda(u) du}, \quad 0 \leq u \leq t_f.$$

3. Ordenar los valores obtenidos: $S_{(1)} \leq S_{(2)} \leq \dots \leq S_{(N)}$. Estos son los tiempos de salto.
4. Definir el proceso en cualquier instante t como

$$N(t) = \sum_{i=1}^N \mathbb{1}\{S_{(i)} \leq t\}.$$

Este método es análogo al que vimos en el caso homogéneo, reemplazando la distribución uniforme por una distribución con densidad proporcional a λ . La generación de tales variables puede realizarse, por ejemplo, mediante el método de transformada inversa si la integral de λ es invertible, o mediante métodos de aceptación-rechazo como el conocido *algoritmo de thinning* de Lewis y Shedler (1979), que simula un proceso de Poisson homogéneo de intensidad $\lambda_{\max} = \sup_{0 \leq t \leq T} \lambda(t)$ y luego acepta cada salto con probabilidad $\lambda(t)/\lambda_{\max}$. Así, la caracterización condicional no solo tiene interés teórico, sino que proporciona herramientas prácticas muy útiles cuando λ es difícil de integrar en cada intervalo de la malla.

3.3. Proceso de Poisson compuesto

Sea $\{N(t) : t \geq 0\}$ un proceso de Poisson homogéneo con intensidad $\lambda > 0$ y sea $\{Y_i\}_{i \geq 1}$ una sucesión de variables aleatorias i.i.d., independientes de N , con

$$Y_i \geq 0.$$

El proceso estocástico $\{X(t) : t \geq 0\}$ definido por

$$X(t) = \sum_{i=1}^{N(t)} Y_i$$

se llama *proceso de Poisson compuesto*.

Una vez establecida la definición, podemos enunciar y demostrar sus propiedades fundamentales. En primer lugar, es inmediato que $X(0) = 0$, ya que $N(0) = 0$. Además, el proceso hereda la propiedad de incrementos independientes del proceso de Poisson subyacente: si tomamos intervalos disjuntos, los saltos de N en cada uno son independientes, y como las variables Y_i son independientes y se asignan a saltos distintos, las sumas correspondientes también resultan ser independientes.

Otra propiedad clave es que $X(t)$ tiene incrementos estacionarios. En efecto, para cualesquiera $s, t \geq 0$, se cumple que

$$X(t+s) - X(s) = \sum_{i=N(s)+1}^{N(t+s)} Y_i.$$

El número de saltos en el intervalo $(s, s+t]$ es $N(t+s) - N(s)$, cuya distribución es $\text{Poisson}(\lambda t)$ y depende únicamente de la longitud t del intervalo. Como los Y_i son i.i.d. e independientes de N , la distribución de la suma compuesta depende solo de t y no de s . Por tanto,

$$X(t+s) - X(s) \sim X(t) \quad .$$

En cuanto a los momentos, si $\mathbb{E}[Y_1] < \infty$, podemos calcular la esperanza condicionando al número de saltos:

$$\mathbb{E}[X(t)] = \mathbb{E} \left[\mathbb{E} \left[\sum_{i=1}^{N(t)} Y_i \mid N(t) \right] \right] = \mathbb{E} [N(t) \mathbb{E}[Y_1]] = \mathbb{E}[N(t)] \mathbb{E}[Y_1] = \lambda t \mathbb{E}[Y_1],$$

donde hemos usado la independencia entre $N(t)$ y la sucesión $\{Y_i\}$.

De manera análoga, si $\text{Var}(Y_1) < \infty$, aplicamos la fórmula de descomposición de la varianza:

$$\text{Var}(X(t)) = \mathbb{E} [\text{Var}(X(t) \mid N(t))] + \text{Var} (\mathbb{E}[X(t) \mid N(t)]) .$$

Condicionado a $N(t) = n$, la suma $\sum_{i=1}^n Y_i$ tiene varianza $n \text{Var}(Y_1)$ y esperanza $n \mathbb{E}[Y_1]$. Por tanto,

$$\text{Var}(X(t) \mid N(t)) = N(t) \text{Var}(Y_1), \quad \mathbb{E}[X(t) \mid N(t)] = N(t) \mathbb{E}[Y_1].$$

Sustituyendo en la fórmula anterior:

$$\text{Var}(X(t)) = \mathbb{E}[N(t)] \text{Var}(Y_1) + \text{Var}(N(t) \mathbb{E}[Y_1]) = \lambda t \text{Var}(Y_1) + (\mathbb{E}[Y_1])^2 \text{Var}(N(t)).$$

Como $\text{Var}(N(t)) = \lambda t$, y usando que $\text{Var}(Y_1) = \mathbb{E}[Y_1^2] - (\mathbb{E}[Y_1])^2$, obtenemos finalmente

$$\text{Var}(X(t)) = \lambda t \mathbb{E}[Y_1^2].$$

Resumimos estas propiedades en el siguiente listado:

- $X(0) = 0$.
- Tiene incrementos independientes.
- Tiene incrementos estacionarios.
- Si $\mathbb{E}[Y_1] < \infty$, entonces $\mathbb{E}[X(t)] = \lambda t \mathbb{E}[Y_1]$.
- Si $\text{Var}(Y_1) < \infty$, entonces $\text{Var}(X(t)) = \lambda t \mathbb{E}[Y_1^2]$.

3.4. Proceso de riesgo (modelo clásico de Cramér–Lundberg)

Dentro de las aplicaciones del proceso de Poisson compuesto, uno de los modelos más importantes es el proceso de riesgo, también conocido como el modelo clásico de Cramér–Lundberg, ampliamente utilizado en la teoría de la ruina para compañías de seguros.

Sea $\{X(t)\}_{t \geq 0}$ un proceso de Poisson compuesto que representa el monto total de reclamaciones acumuladas hasta el instante t . El proceso de capital o proceso de riesgo se define entonces como

$$U(t) = u + ct - X(t),$$

donde:

- $u \geq 0$ es el capital inicial de la aseguradora,
- $c > 0$ es la tasa constante de ingreso por primas (ingresos por unidad de tiempo),
- $X(t) = \sum_{i=1}^{N(t)} Y_i$ es el total de reclamaciones pagadas hasta el tiempo t .

La interpretación es clara: en ausencia de siniestros, el capital de la compañía crecería linealmente según $u + ct$. Sin embargo, en cada salto del proceso de Poisson subyacente ocurre un siniestro, y el capital disminuye en una cantidad igual al monto de la reclamación correspondiente (dado por la variable Y_i). Por lo tanto, la trayectoria de $U(t)$ es un proceso que combina un crecimiento determinista con saltos negativos aleatorios.

Un concepto central en este modelo es el de la *ruina*. Se dice que la ruina ocurre si en algún instante el capital de la compañía se vuelve estrictamente negativo, es decir, si existe $t \geq 0$ tal que $U(t) < 0$. En términos probabilísticos, la probabilidad de ruina se define como

$$\psi(u) = \mathbb{P}(\exists t \geq 0 : U(t) < 0 \mid U(0) = u),$$

y constituye la principal cantidad de interés en la teoría del riesgo.

Para que el modelo sea sostenible a largo plazo y no conduzca a la ruina casi segura, es necesario imponer una condición sobre los parámetros. Dado que el ingreso por primas es c por unidad de tiempo y el gasto esperado por reclamaciones por unidad de tiempo es $\lambda \mathbb{E}[Y_1]$ (como vimos en la propiedad de la esperanza del proceso compuesto), la condición

$$c > \lambda \mathbb{E}[Y_1]$$

garantiza que, en promedio, los ingresos superen a los egresos. Esta desigualdad se conoce como la *condición de beneficio neto* (o *net profit condition*) y es necesaria para que la probabilidad de ruina sea estrictamente menor que 1. Si no se cumple, es decir, si $c \leq \lambda \mathbb{E}[Y_1]$, el proceso tiene una deriva negativa o nula y la ruina ocurre con probabilidad 1.

Desde el punto de vista de la simulación, el proceso de riesgo se obtiene de manera muy sencilla una vez que sabemos simular el proceso de Poisson compuesto $X(t)$. Basta con generar la trayectoria de $X(t)$ (usando cualquiera de los algoritmos presentados en la sección anterior) y luego aplicar la transformación lineal

$$U(t) = u + ct - X(t).$$

Por ejemplo, si se utiliza el método de simulación global para $X(t)$ sobre una malla $t_0 = 0 < t_1 < \dots < t_n$, el capital en cada instante de la malla se calcula como

$$U(t_i) = u + ct_i - X(t_i), \quad i = 0, 1, \dots, n,$$

donde $X(t_i)$ se ha obtenido previamente mediante la suma acumulada de las reclamaciones en cada intervalo. De esta forma, se obtienen trayectorias completas del proceso de capital que permiten estimar, por ejemplo, la probabilidad de ruina mediante simulación de Monte Carlo, repitiendo el procedimiento un gran número de veces y contando en qué proporción de las trayectorias se alcanza un valor negativo.

3.5. Movimiento browniano

El movimiento browniano, también conocido como proceso de Wiener, es el proceso estocástico continuo más importante y constituye la base de gran parte de la modelización en finanzas, física y ecuaciones diferenciales estocásticas. Al igual que el proceso de Poisson, el movimiento browniano es un proceso de Lévy, pero con la particularidad de que sus trayectorias son continuas y sus incrementos siguen una distribución normal.

Un proceso estocástico $\{B(t) : t \geq 0\}$ se denomina *movimiento browniano estándar* (o browniano) si satisface las siguientes propiedades:

1. $B(0) = 0$ casi seguramente.
2. Tiene incrementos independientes: para cualesquiera $0 \leq t_0 < t_1 < \dots < t_n$, las variables

$$B(t_1) - B(t_0), B(t_2) - B(t_1), \dots, B(t_n) - B(t_{n-1})$$

son independientes.

3. Tiene incrementos estacionarios y normalmente distribuidos: para cualesquiera $0 \leq s < t$,

$$B(t) - B(s) \sim \mathcal{N}(0, t - s).$$

Es decir, la media es 0 y la varianza es igual a la longitud del intervalo.

4. Las trayectorias $t \mapsto B(t)$ son continuas casi seguramente.

De estas propiedades se deducen inmediatamente los momentos del proceso. Para todo $t \geq 0$, se tiene que

$$\mathbb{E}[B(t)] = 0, \quad \text{Var}(B(t)) = t.$$

Además, la función de autocovarianza para $0 \leq s \leq t$ es

$$\text{Cov}(B(s), B(t)) = \mathbb{E}[B(s)B(t)] = s,$$

lo que refleja la fuerte dependencia entre los valores del proceso en distintos instantes.

La simulación del movimiento browniano es considerablemente más sencilla que la del proceso de Poisson, precisamente porque no requiere generar tiempos de salto. Basta con discretizar el tiempo y generar incrementos gaussianos independientes.

Dada una malla de tiempos

$$t_0 = 0 < t_1 < \dots < t_n,$$

el algoritmo para simular el browniano evaluado en esos instantes es el siguiente:

1. Inicializamos $B(t_0) = 0$.

2. Para $i = 1, \dots, n$:

a) Calculamos la longitud del intervalo:

$$\Delta t_i = t_i - t_{i-1}.$$

b) Generamos una variable aleatoria

$$Z_i \sim \mathcal{N}(0, 1)$$

independiente de las anteriores.

c) Definimos el incremento del browniano como

$$\Delta B_i = \sqrt{\Delta t_i} Z_i.$$

d) Actualizamos el valor del proceso:

$$B(t_i) = B(t_{i-1}) + \Delta B_i.$$

La justificación de este algoritmo es inmediata: por la propiedad de incrementos estacionarios, sabemos que

$$B(t_i) - B(t_{i-1}) \sim \mathcal{N}(0, \Delta t_i),$$

y cualquier variable normal con media 0 y varianza Δt_i puede escribirse como $\sqrt{\Delta t_i} Z_i$, donde Z_i es una normal estándar. La independencia de los incrementos garantiza que los Z_i se puedan generar de forma independiente.

Si se desea simular un movimiento browniano con deriva μ y volatilidad $\sigma > 0$, es decir, el proceso

$$X(t) = \mu t + \sigma B(t),$$

el algoritmo es prácticamente el mismo. Basta con modificar la actualización:

$$X(t_i) = X(t_{i-1}) + \mu \Delta t_i + \sigma \sqrt{\Delta t_i} Z_i.$$

Este proceso, conocido como *movimiento browniano con deriva* o *proceso de Wiener con deriva*, es el bloque fundamental para construir el movimiento browniano geométrico, ampliamente utilizado en finanzas para modelizar precios de activos.

4. Método Monte Carlo

Sea f una función de densidad de probabilidad y $h : \mathbb{R} \rightarrow \mathbb{R}$ una función medible. Supongamos que nos interesa calcular

$$\mathbb{E}[h(X)], \quad \text{donde } X \sim f.$$

Por definición,

$$\mathbb{E}[h(X)] = \int_{\mathbb{R}} h(x)f(x) dx.$$

Si generamos una muestra independiente $X_1, \dots, X_n$ con distribución f , entonces un estimador natural de $\mathbb{E}[h(X)]$ es

$$\hat{\theta}_n = \frac{1}{n} \sum_{i=1}^n h(X_i).$$

Por la Ley de los Grandes Números,

$$\hat{\theta}_n \xrightarrow[n \rightarrow \infty]{} \mathbb{E}[h(X)] \quad \text{c.s.}$$

Además, el estimador es insesgado:

$$\mathbb{E}[\hat{\theta}_n] = \mathbb{E}[h(X)],$$

y su varianza es

$$\text{Var}(\hat{\theta}_n) = \frac{\text{Var}(h(X))}{n}.$$

Por el Teorema Central del Límite,

$$\sqrt{n} \left(\hat{\theta}_n - \mathbb{E}[h(X)] \right) \xrightarrow{d} \mathcal{N}(0, \text{Var}(h(X))).$$

Estas propiedades fundamentales garantizan la consistencia y la normalidad asintótica del estimador, lo que permite construir intervalos de confianza y cuantificar la incertidumbre de la aproximación. En la práctica, el método de Monte Carlo se aplica de forma recursiva: se simulan trayectorias de procesos estocásticos (como los que hemos estudiado: Poisson, browniano, compuesto o el modelo de Cramér–Lundberg), se evalúa la función de interés en cada trayectoria, y se promedia sobre el conjunto de simulaciones.

4.1. Integración numérica mediante Monte Carlo

Una de las aplicaciones más directas y poderosas del método de Monte Carlo es la estimación numérica de integrales definidas. Supongamos que tenemos una función integrable $h : [a, b] \rightarrow \mathbb{R}$ y deseamos calcular

$$I = \int_a^b h(x) dx.$$

Si $X \sim \text{Uniforme}(a, b)$, su función de densidad es

$$f(x) = \frac{1}{b-a}, \quad x \in (a, b),$$

y por lo tanto,

$$\mathbb{E}[h(X)] = \int_a^b h(x) \frac{1}{b-a} dx = \frac{1}{b-a} \int_a^b h(x) dx.$$

Despejando, obtenemos la identidad fundamental

$$\int_a^b h(x) dx = (b-a) \mathbb{E}[h(X)].$$

Esta igualdad reduce el problema del cálculo de una integral al de la estimación de una esperanza, que podemos aproximar mediante el método de Monte Carlo.

Para ello, generamos una muestra independiente $X_1, \dots, X_n$ con distribución uniforme en (a, b) y definimos el estimador

$$\hat{I}_n = (b-a) \frac{1}{n} \sum_{i=1}^n h(X_i).$$

Por la Ley de los Grandes Números, $\hat{I}_n$ converge casi seguramente a I cuando $n \rightarrow \infty$.

Para cuantificar la precisión de esta aproximación, supongamos que $\mathbb{E}[h^2(X)] < \infty$, de modo que la varianza de $h(X)$ es finita. Sea

$$\sigma^2 = \text{Var}(h(X)) = \mathbb{E}[h^2(X)] - (\mathbb{E}[h(X)])^2.$$

Definimos además el estimador de la media

$$\hat{h}_n = \frac{1}{n} \sum_{i=1}^n h(X_i),$$

que es simplemente la media muestral de los valores $h(X_i)$. El Teorema Central del Límite nos asegura que

$$\sqrt{n} \left(\hat{h}_n - \mathbb{E}[h(X)] \right) \xrightarrow{d} \mathcal{N}(0, \sigma^2).$$

Equivalentemente,

$$\frac{\sqrt{n} \left(\hat{h}_n - \mathbb{E}[h(X)] \right)}{\sigma} = \frac{1}{\sqrt{n}} \sum_{i=1}^n \frac{h(X_i) - \mathbb{E}[h(X)]}{\sigma} \xrightarrow{d} Z,$$

donde $Z \sim \mathcal{N}(0, 1)$.

En la práctica, σ^2 es desconocida, por lo que la estimamos mediante la varianza muestral

$$s_n^2 = \frac{1}{n} \sum_{i=1}^n \left(h(X_i) - \hat{h}_n \right)^2,$$

que converge en probabilidad a σ^2 cuando $n \rightarrow \infty$. Por el Teorema de Slutsky, se tiene que

$$\frac{\sqrt{n} \left(\hat{h}_n - \mathbb{E}[h(X)] \right)}{s_n} \xrightarrow{d} \mathcal{N}(0, 1).$$

Este resultado permite construir un intervalo de confianza asintótico al nivel $(1 - \alpha)100\%$ para $\mathbb{E}[h(X)]$, dado por

$$I_\alpha = \left(\hat{h}_n - z_{1-\alpha/2} \frac{s_n}{\sqrt{n}}, \quad \hat{h}_n + z_{1-\alpha/2} \frac{s_n}{\sqrt{n}} \right),$$

donde $z_{1-\alpha/2}$ es el cuantil $1 - \alpha/2$ de la distribución normal estándar.

Finalmente, multiplicando por $(b - a)$ obtenemos el correspondiente intervalo de confianza para la integral I :

$$\left(\hat{I}_n - (b - a) z_{1-\alpha/2} \frac{s_n}{\sqrt{n}}, \quad \hat{I}_n + (b - a) z_{1-\alpha/2} \frac{s_n}{\sqrt{n}} \right).$$

Ejemplo 4.1. *Un ejemplo clásico de integración Monte Carlo es la estimación del número π . Sean U_1, U_2 variables aleatorias i.i.d. $\text{Unif}(0, 1)$. Definimos*

$$X = 4 \mathbb{1}_{\{U_1^2 + U_2^2 \leq 1\}}.$$

Entonces

$$\mathbb{E}[X] = 4 \mathbb{P}(U_1^2 + U_2^2 \leq 1).$$

Además,

$$\mathbb{P}(U_1^2 + U_2^2 \leq 1) = \int_0^1 \int_0^{\sqrt{1-u_2^2}} du_1 du_2.$$

Por lo tanto,

$$\mathbb{E}[X] = 4 \int_0^1 \sqrt{1-u_2^2} du_2 = \pi.$$

Así, si tomamos una muestra

$$(U_1^{(1)}, U_2^{(1)}), \dots, (U_1^{(n)}, U_2^{(n)}),$$

podemos estimar π mediante

$$\hat{\pi} = \frac{4}{n} \sum_{i=1}^n \mathbb{1}_{\{(U_1^{(i)})^2 + (U_2^{(i)})^2 \leq 1\}}.$$

Este estimador es simplemente cuatro veces la proporción de puntos que caen dentro del círculo unitario inscrito en el cuadrado $[0, 1]^2$.

4.2. Estimación de la función de distribución

El método de Monte Carlo no solo permite estimar esperanzas e integrales, sino también aproximar la función de distribución completa de una variable aleatoria. Supongamos que disponemos de una muestra independiente $X_1, \dots, X_n$ con distribución $\mathcal{L}(F)$, donde F es la función de distribución acumulada (FDA) de una variable aleatoria real.

Definimos la función de distribución empírica como

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{\{X_i \leq x\}}, \quad x \in \mathbb{R}.$$

Esta función asigna a cada x la proporción de observaciones en la muestra que son menores o iguales que x . Por la Ley Fuerte de los Grandes Números, para cada $x \in \mathbb{R}$ fijo,

$$\hat{F}_n(x) \xrightarrow{\text{c.s.}} F(x),$$

es decir, la FDA empírica converge puntualmente a la FDA verdadera. Más aún, el Teorema de Glivenko–Cantelli establece una convergencia mucho más fuerte: la convergencia es uniforme en toda la recta real,

$$\|\hat{F}_n - F\|_\infty = \sup_{x \in \mathbb{R}} |\hat{F}_n(x) - F(x)| \xrightarrow{\text{c.s.}} 0.$$

Este resultado garantiza que, para n suficientemente grande, la función de distribución empírica aproxima uniformemente bien a la distribución subyacente.

Para cada $x \in \mathbb{R}$ fijo, la variable $n\hat{F}_n(x)$ cuenta el número de observaciones menores o iguales que x , y por tanto sigue una distribución binomial:

$$n\hat{F}_n(x) \sim \text{Binomial}(n, F(x)).$$

De aquí se deducen inmediatamente la esperanza y la varianza del estimador puntual:

$$\mathbb{E}[\hat{F}_n(x)] = F(x), \quad \text{Var}(\hat{F}_n(x)) = \frac{F(x)(1 - F(x))}{n}.$$

Esto permite construir intervalos de confianza exactos para $F(x)$ en cada punto fijo x , utilizando el intervalo de Clopper–Pearson para el parámetro $p = F(x)$ de una distribución Binomial(n, p). Los límites inferior y superior del intervalo de confianza al nivel $1 - \alpha$ se definen como

$$p_L(x) = \inf \left\{ p : \mathbb{P}_{Y \sim \text{Bin}(n, p)}(Y \leq n\hat{F}_n(x)) = \frac{\alpha}{2} \right\},$$

$$p_U(x) = \sup \left\{ p : \mathbb{P}_{Y \sim \text{Bin}(n, p)}(Y \geq n\hat{F}_n(x)) = \frac{\alpha}{2} \right\}.$$

Estos intervalos son conservadores y garantizan la cobertura nominal para cualquier tamaño de muestra.

Sin embargo, en muchas aplicaciones interesa construir una banda de confianza que cubra simultáneamente toda la función $F(x)$ para todos los x a la vez. La desigualdad de Dvoretzky–Kiefer–Wolfowitz (DKW) proporciona una herramienta fundamental para ello. Esta desigualdad acota la probabilidad de que la función empírica difiera de la verdadera en más de una constante $\varepsilon > 0$ en algún punto de la recta real:

$$\mathbb{P} \left(\sup_{x \in \mathbb{R}} |\hat{F}_n(x) - F(x)| > \varepsilon \right) \leq 2e^{-2n\varepsilon^2}, \quad \text{para todo } \varepsilon > 0.$$

A partir de esta cota, se puede construir una banda de confianza uniforme para $F(x)$ que contenga a la función verdadera con probabilidad $1 - \alpha$. En efecto, si elegimos

$$\varepsilon = \sqrt{\frac{\ln \left(\frac{2}{\alpha} \right)}{2n}},$$

entonces, con probabilidad al menos $1 - \alpha$, se cumple simultáneamente para todo $x \in \mathbb{R}$ que

$$\hat{F}_n(x) - \varepsilon \leq F(x) \leq \hat{F}_n(x) + \varepsilon.$$

Esta banda de confianza uniforme es especialmente útil en problemas de bondad de ajuste, comparación de distribuciones y en la validación de modelos simulados, ya que permite evaluar globalmente la calidad de la aproximación empírica a la distribución teórica.

4.3. Estimación de la función de densidad

Sea $X_1, \dots, X_n \sim \text{i.i.d. } \mathcal{L}(f)$, donde f es una función de densidad de probabilidad con función de distribución acumulada F . Por definición de densidad, se tiene que

$$f(x) = \lim_{h \downarrow 0} \frac{\mathbb{P}(x < X \leq x + h)}{h} = \lim_{h \downarrow 0} \mathbb{E} \left[\frac{\mathbb{1}_{\{x < X \leq x+h\}}}{h} \right].$$

Para $h > 0$ definimos el estimador puntual

$$A_h(x) = \frac{1}{h} \mathbb{1}_{\{x < X \leq x+h\}},$$

el cual es un estimador (generalmente sesgado) de $f(x)$. Su varianza está dada por

$$\text{Var}(A_h(x)) = \frac{\mathbb{P}(x < X \leq x+h)(1 - \mathbb{P}(x < X \leq x+h))}{h^2} = \frac{(F(x+h) - F(x))(1 - F(x+h) + F(x))}{h^2}.$$

Usando que $F(x+h) - F(x) \approx f(x)h$ cuando h es pequeño, obtenemos la aproximación

$$\text{Var}(A_h(x)) \approx \frac{f(x)}{h}.$$

Heurísticamente, cuando $h \rightarrow 0$ el sesgo de $A_h(x)$ tiende a cero, pero la varianza explota a infinito. Esto muestra la existencia de un compromiso entre sesgo y varianza.

Ahora consideremos m muestras independientes, cada una de tamaño n :

$$X_{1,1}, \dots, X_{1,n}, \dots, X_{m,1}, \dots, X_{m,n} \sim \text{i.i.d. } \mathcal{L}(f).$$

Podemos proponer el estimador de Monte Carlo para cada réplica

$$\hat{A}_h^{(i)}(x) = \frac{1}{n} \sum_{j=1}^n \frac{\mathbb{1}_{\{x < X_{i,j} \leq x+h\}}}{h},$$

y luego promediar sobre las m réplicas

$$\widehat{A}_h(x) = \frac{1}{m} \sum_{i=1}^m \widehat{A}_h^{(i)}(x).$$

En particular, el error cuadrático medio de este estimador satisface

$$\text{MSE}(\widehat{A}_h(x)) = \frac{1}{m} \text{Var}(A_h(x)) + (\text{bias}(A_h(x)))^2.$$

Además, se obtiene que el sesgo se aproxima por

$$\text{bias}(A_h(x)) = \mathbb{E}[A_h(x)] - f(x) = \frac{F(x+h) - F(x)}{h} - f(x) \approx h F''(x) = h f'(x).$$

Por lo tanto,

$$\text{MSE}(\widehat{A}_h(x)) \approx \frac{f(x)}{mh} + h^2 f'(x)^2.$$

Viendo esta expresión como función de h , se minimiza aproximadamente en

$$h = \left(\frac{f(x)^2}{f'(x)^2 m} \right)^{1/3}.$$

En consecuencia, en la práctica suele elegirse

$$h \approx m^{-1/3}.$$

Este resultado refleja nuevamente el compromiso entre sesgo y varianza: valores pequeños de h reducen el sesgo pero aumentan la varianza, mientras que valores grandes de h reducen la varianza pero incrementan el sesgo.

4.4. Estimación de la función cuantil

Sea

$$q_\alpha = F^{-1}(\alpha), \quad \alpha \in (0, 1),$$

el cuantil poblacional de orden α . Definimos el cuantil empírico como

$$\hat{q}_\alpha = \hat{F}_n^{-1}(\alpha),$$

donde $\hat{F}_n$ es la función de distribución empírica definida anteriormente.

Si F es diferenciable en q_α y $f(q_\alpha) > 0$, donde f es la densidad, entonces el estimador $\hat{q}_\alpha$ es consistente y asintóticamente normal:

$$\sqrt{n}(\hat{q}_\alpha - q_\alpha) \xrightarrow{d} \mathcal{N}(0, \sigma_\alpha^2),$$

donde

$$\sigma_\alpha^2 = \frac{\alpha(1-\alpha)}{f(q_\alpha)^2}.$$

En la práctica, la varianza asintótica es desconocida porque depende de la densidad f en el cuantil. Por tanto, la estimamos mediante

$$\hat{\sigma}_\alpha^2 = \frac{\alpha(1-\alpha)}{\hat{f}_n(\hat{q}_\alpha)^2},$$

donde $\hat{f}_n$ es un estimador de la densidad f (por ejemplo, un estimador de núcleo o el histograma con un ancho de banda adecuado).

Un intervalo de confianza asintótico al nivel $(1 - \tilde{\alpha})100\%$ para q_α es entonces

$$\hat{q}_\alpha \pm z_{1-\tilde{\alpha}/2} \sqrt{\frac{\alpha(1-\alpha)}{n \hat{f}_n(\hat{q}_\alpha)^2}}.$$

Este intervalo es válido para n grande y se utiliza frecuentemente en aplicaciones donde se necesita cuantificar la incertidumbre asociada a la estimación de percentiles, como en análisis de riesgos o en la validación de modelos de simulación.

4.5. Aproximación Monte Carlo de la esperanza del proceso Poisson compuesto

Recordemos que el proceso de Poisson compuesto se define como

$$X(t) = \sum_{i=1}^{N(t)} Y_i,$$

donde $N(t)$ es un proceso de Poisson homogéneo con intensidad λ , y las variables $Y_1, Y_2, \dots$ son i.i.d. con distribución F , independientes de $N(t)$.

Como vimos en la sección correspondiente, la esperanza de $X(t)$ se obtiene mediante esperanza condicional:

$$\begin{aligned}
\mu_t &= \mathbb{E}[X(t)] \\
&= \mathbb{E}[\mathbb{E}(X(t) \mid N(t))] \\
&= \sum_{n=0}^{\infty} \mathbb{E} \left[\sum_{i=1}^{N(t)} Y_i \mid N(t) = n \right] \mathbb{P}(N(t) = n) \\
&= \sum_{n=0}^{\infty} \mathbb{E} \left[\sum_{i=1}^n Y_i \right] \mathbb{P}(N(t) = n) \\
&= \sum_{n=0}^{\infty} n \mathbb{E}[Y_1] \mathbb{P}(N(t) = n) \\
&= \mathbb{E}[Y_1] \sum_{n=0}^{\infty} n \mathbb{P}(N(t) = n) \\
&= \mathbb{E}[Y_1] \mathbb{E}[N(t)] \\
&= \lambda t \mathbb{E}[Y_1].
\end{aligned}$$

Por lo tanto, la esperanza del proceso compuesto en el instante t es

$$\mathbb{E}[X(t)] = \lambda t \mathbb{E}[Y_1].$$

Supongamos ahora que el parámetro λ es desconocido y deseamos estimarlo a partir de observaciones del proceso compuesto. Para ello, podemos simular n trayectorias independientes del proceso $X(t)$ hasta el tiempo t , obteniendo los valores $X_1(t), \dots, X_n(t)$. Un estimador Monte Carlo natural para $\mu_t = \mathbb{E}[X(t)]$ es la media muestral

$$\hat{\mu}_t = \frac{1}{n} \sum_{i=1}^n X_i(t).$$

Por la Ley de los Grandes Números, $\hat{\mu}_t$ converge a μ_t cuando $n \rightarrow \infty$. A partir de la expresión teórica $\mu_t = \lambda t \mathbb{E}[Y_1]$, podemos despejar λ y obtener el estimador

$$\hat{\lambda} = \frac{\hat{\mu}_t}{t \mathbb{E}[Y_1]}.$$

Para cuantificar la incertidumbre de $\hat{\lambda}$, necesitamos su varianza. Recordemos que la varianza del proceso Poisson compuesto es

$$\text{Var}(X(t)) = \lambda t \mathbb{E}[Y_1^2],$$

siempre que $\mathbb{E}[Y_1^2] < \infty$. Por lo tanto, la varianza del estimador $\hat{\mu}_t$ es

$$\text{Var}(\hat{\mu}_t) = \frac{\text{Var}(X(t))}{n} = \frac{\lambda t \mathbb{E}[Y_1^2]}{n}.$$

Como $\hat{\lambda} = \hat{\mu}_t / (t \mathbb{E}[Y_1])$ es una transformación lineal de $\hat{\mu}_t$, su varianza es

$$\text{Var}(\hat{\lambda}) = \frac{\text{Var}(\hat{\mu}_t)}{(t \mathbb{E}[Y_1])^2} = \frac{\lambda t \mathbb{E}[Y_1^2]}{n t^2 (\mathbb{E}[Y_1])^2} = \frac{\lambda \mathbb{E}[Y_1^2]}{n t (\mathbb{E}[Y_1])^2}.$$

En la práctica, el valor de λ es desconocido, por lo que lo sustituimos por su estimador $\hat{\lambda}$ para obtener una estimación de la varianza:

$$\widehat{\text{Var}}(\hat{\lambda}) = \frac{\hat{\lambda} \mathbb{E}[Y_1^2]}{n t (\mathbb{E}[Y_1])^2}.$$

Aplicando el Teorema Central del Límite, el estimador $\hat{\lambda}$ es asintóticamente normal:

$$\frac{\hat{\lambda} - \lambda}{\sqrt{\widehat{\text{Var}}(\hat{\lambda})}} \xrightarrow{d} \mathcal{N}(0, 1).$$

Esto permite construir un intervalo de confianza aproximado al nivel $(1 - \alpha)100\%$ para λ :

$$\hat{\lambda} \pm z_{1-\alpha/2} \sqrt{\frac{\hat{\lambda} \mathbb{E}[Y_1^2]}{n t (\mathbb{E}[Y_1])^2}},$$

donde $z_{1-\alpha/2}$ es el cuantil $1 - \alpha/2$ de la distribución normal estándar.

Este intervalo es válido para n suficientemente grande y proporciona una herramienta práctica para estimar la intensidad del proceso de Poisson subyacente a partir de observaciones del proceso compuesto, sin necesidad de observar directamente el proceso de conteo $N(t)$.

4.6. Proceso de Cramér–Lundberg y probabilidad de ruina

El modelo clásico de Cramér–Lundberg describe la evolución del capital de una compañía de seguros. El proceso de riesgo se define como

$$U(t) = u + ct - X(t),$$

donde:

- $u > 0$ es el capital inicial,
- $c > 0$ es la tasa constante de ingreso por primas,

- $X(t)$ es un proceso de Poisson compuesto que representa el monto total de reclamaciones hasta el tiempo t .

Recordemos que $X(t) = \sum_{i=1}^{N(t)} Y_i$, con $N(t)$ un proceso de Poisson de intensidad λ y Y_i i.i.d. con media $\mathbb{E}[Y_1]$. Por lo tanto, la esperanza del capital en el instante t es

$$\mathbb{E}[U(t)] = u + ct - \mathbb{E}[X(t)] = u + ct - \lambda t \mathbb{E}[Y_1] = u + t(c - \lambda \mathbb{E}[Y_1]).$$

Para que el modelo sea sostenible a largo plazo, es necesario que, en promedio, los ingresos superen a los gastos. Esto se traduce en la llamada *condición de ganancia neta* (o condición de beneficio neto):

$$c > \lambda \mathbb{E}[Y_1].$$

Equivalentemente, se puede escribir

$$c = (1 + \theta) \lambda \mathbb{E}[Y_1],$$

donde $\theta > 0$ se denomina *factor de recargo* (o *loading factor*). Este factor mide el margen de seguridad que la aseguradora añade sobre la prima pura (el valor esperado de las reclamaciones por unidad de tiempo).

Supongamos ahora que la intensidad λ es desconocida y deseamos estimarla a partir de la observación del proceso de capital. De la expresión para la esperanza del capital, podemos despejar λ :

$$\lambda = \frac{1}{\mathbb{E}[Y_1]} \left(c - \frac{\mathbb{E}[U(t)] - u}{t} \right).$$

Si disponemos de n trayectorias independientes del proceso de capital hasta el tiempo t , podemos estimar $\mathbb{E}[U(t)]$ mediante la media muestral $\hat{\mu}_t^U = \frac{1}{n} \sum_{i=1}^n U_i(t)$. Sustituyendo en la expresión anterior, obtenemos el estimador de Monte Carlo para λ :

$$\hat{\lambda} = \frac{1}{\mathbb{E}[Y_1]} \left(c - \frac{\hat{\mu}_t^U - u}{t} \right).$$

Este estimador es una alternativa al que obtuvimos directamente del proceso compuesto, y puede ser útil cuando solo se dispone de observaciones del capital.

4.6.1. Probabilidad de ruina

Uno de los conceptos centrales en la teoría del riesgo es la probabilidad de ruina. Se define el tiempo de ruina como

$$\tau = \inf\{t > 0 : U(t) < 0\},$$

es decir, el primer instante en el que el capital se vuelve estrictamente negativo. La probabilidad de ruina en horizonte infinito es

$$\psi(u) = \mathbb{P}(\tau < \infty \mid U(0) = u),$$

mientras que en horizonte finito $T > 0$ se define como

$$\psi(u, T) = \mathbb{P}(\tau \leq T \mid U(0) = u).$$

La probabilidad de ruina goza de las siguientes propiedades:

1. $u \mapsto \psi(u, T)$ es decreciente: a mayor capital inicial, menor probabilidad de ruina.
2. $\lim_{u \rightarrow \infty} \psi(u, T) = 0$: con capital infinito, la ruina es imposible.
3. $T \mapsto \psi(u, T)$ es creciente: a mayor horizonte temporal, mayor probabilidad de haber arruinado.
4. $\lim_{T \rightarrow \infty} \psi(u, T) = \psi(u)$: la probabilidad en horizonte finito converge a la de horizonte infinito cuando el horizonte crece.

En general, $\psi(u)$ no tiene una expresión analítica cerrada, salvo en casos particulares (por ejemplo, cuando las reclamaciones son exponenciales). Por esta razón, la simulación Monte Carlo es una herramienta fundamental para estimar estas probabilidades.

Para estimar $\psi(u, T)$ mediante Monte Carlo, definimos para cada trayectoria simulada la variable indicadora

$$X_i = \mathbb{1}_{\{\tau_i \leq T\}},$$

donde τ_i es el tiempo de ruina en la i -ésima réplica. Entonces, X_i es una variable de Bernoulli con parámetro $p = \psi(u, T)$:

$$X_i \sim \text{Bernoulli}(p), \quad p = \psi(u, T).$$

El estimador natural de p es la proporción de trayectorias que han experimentado ruina antes del tiempo T :

$$\hat{p} = \frac{1}{n} \sum_{i=1}^n X_i.$$

Este estimador es insesgado, es decir,

$$\mathbb{E}[\hat{p}] = p,$$

y su varianza está dada por

$$\text{Var}(\hat{p}) = \frac{p(1-p)}{n}.$$

Por el Teorema Central del Límite, para n suficientemente grande,

$$\frac{\hat{p} - p}{\sqrt{\hat{p}(1-\hat{p})/n}} \xrightarrow{d} \mathcal{N}(0, 1).$$

Por lo tanto, un intervalo de confianza asintótico al nivel $(1 - \alpha)100\%$ para $p = \psi(u, T)$ es

$$\hat{p} \pm z_{1-\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}.$$

Este intervalo proporciona una medida de la incertidumbre asociada a la estimación de la probabilidad de ruina y es de gran utilidad en la práctica para la toma de decisiones en la gestión de riesgos de una compañía aseguradora.

4.7. Valor en Riesgo (VaR) y Valor en Riesgo Condicional (CVaR)

En el contexto de la gestión de riesgos financieros y de seguros, dos medidas de riesgo ampliamente utilizadas son el Valor en Riesgo (VaR) y el Valor en Riesgo Condicional (CVaR). Estas medidas cuantifican la exposición a pérdidas extremas y son fundamentales para la toma de decisiones bajo incertidumbre.

Sea X una variable aleatoria que representa pérdidas (valores positivos indican pérdidas). El *Valor en Riesgo* al nivel $\alpha \in (0, 1)$ se define como el cuantil α de la distribución de X :

$$\text{VaR}_\alpha(X) = F_X^{-1}(\alpha) = \inf\{x \in \mathbb{R} : F_X(x) \geq \alpha\},$$

donde F_X es la función de distribución acumulada de X . Intuitivamente, el VaR es la pérdida máxima que no se supera con probabilidad α (o, equivalentemente, la pérdida que se supera solo con probabilidad $1 - \alpha$).

El *Valor en Riesgo Condicional* (CVaR) al nivel α se define como la pérdida esperada condicionada a que la pérdida supere el VaR:

$$\text{CVaR}_\alpha(X) = \mathbb{E}[X \mid X \geq \text{VaR}_\alpha(X)].$$

Es decir, el CVaR mide la severidad promedio de las pérdidas en los casos más extremos, aquellos que superan el umbral del VaR.

Para obtener una expresión analítica del CVaR, observemos que para $t \geq \text{VaR}_\alpha(X)$,

$$\mathbb{P}(X \leq t \mid X \geq \text{VaR}_\alpha(X)) = \frac{\mathbb{P}(X \leq t, X \geq \text{VaR}_\alpha(X))}{\mathbb{P}(X \geq \text{VaR}_\alpha(X))} = \frac{F_X(t) - F_X(\text{VaR}_\alpha(X))}{1 - \alpha} = \frac{F_X(t) - \alpha}{1 - \alpha}.$$

Por lo tanto, la función de distribución condicional de X dado que $X \geq \text{VaR}_\alpha(X)$ es

$$F_{X|X \geq \text{VaR}_\alpha(X)}(t) = \frac{F_X(t) - \alpha}{1 - \alpha}, \quad t \geq \text{VaR}_\alpha(X).$$

Si X posee una función de densidad f_X , entonces la densidad condicional es $f_X(t)/(1 - \alpha)$ para $t \geq \text{VaR}_\alpha(X)$. Así,

$$\text{CVaR}_\alpha(X) = \frac{1}{1 - \alpha} \int_{\text{VaR}_\alpha(X)}^{\infty} x f_X(x) dx = \frac{1}{1 - \alpha} \mathbb{E} \left(X \mathbb{1}_{\{X \geq \text{VaR}_\alpha(X)\}} \right).$$

En muchas aplicaciones financieras, la variable de interés X representa rendimientos (ganancias o pérdidas), donde los valores negativos indican pérdidas. En este caso, las definiciones se ajustan para trabajar con la cola izquierda de la distribución. Para un nivel de confianza α (típicamente 95 % o 99 %), el VaR para rendimientos se define como el cuantil $1 - \alpha$:

$$\text{VaR}_\alpha^R(X) = F_X^{-1}(1 - \alpha) = \inf\{x \in \mathbb{R} : F_X(x) \geq 1 - \alpha\}.$$

Es decir, es el valor que deja una probabilidad α en la cola izquierda (las pérdidas más severas). El CVaR correspondiente es la pérdida esperada condicionada a que el rendimiento sea menor o igual que el VaR:

$$\text{CVaR}_\alpha^R(X) = \mathbb{E}[X \mid X \leq \text{VaR}_\alpha^R(X)].$$

Análogamente al caso de pérdidas, se obtiene la expresión integral:

$$\text{CVaR}_\alpha^R(X) = \frac{1}{1 - \alpha} \int_{-\infty}^{\text{VaR}_\alpha^R(X)} x f_X(x) dx = \frac{1}{1 - \alpha} \mathbb{E} \left(X \mathbb{1}_{\{X \leq \text{VaR}_\alpha^R(X)\}} \right).$$

Esta versión del CVaR es la que se utiliza comúnmente en la regulación financiera (por ejemplo, en el marco de Basilea III) para medir el riesgo de mercado.

4.7.1. Caso particular: distribución exponencial

Para ilustrar el cálculo de estas medidas, supongamos que $X \sim \text{Exp}(\lambda)$, con función de distribución $F_X(x) = 1 - e^{-\lambda x}$ para $x \geq 0$. Entonces, el VaR al nivel α es

$$\text{VaR}_\alpha(X) = F_X^{-1}(\alpha) = -\frac{1}{\lambda} \log(1 - \alpha).$$

El CVaR correspondiente se calcula integrando la cola de la distribución exponencial:

$$\text{CVaR}_\alpha(X) = \frac{1}{1 - \alpha} \int_{\text{VaR}_\alpha(X)}^{\infty} x \lambda e^{-\lambda x} dx.$$

Resolviendo la integral, se obtiene

$$\text{CVaR}_\alpha(X) = \frac{1}{\lambda} (1 - \log(1 - \alpha)).$$

Este resultado muestra que, para la distribución exponencial, el CVaR es mayor que el VaR en una cantidad que depende de λ y α , lo que refleja la severidad adicional de las pérdidas en la cola.

4.7.2. Estimación empírica mediante Monte Carlo

En la práctica, la distribución de X no es conocida y debe estimarse a partir de datos. Dada una muestra i.i.d. $X_1, \dots, X_n$ de X , el estimador natural del VaR es el cuantil empírico:

$$\hat{q}_\alpha = \hat{F}_X^{-1}(\alpha),$$

donde $\hat{F}_X$ es la función de distribución empírica definida anteriormente. Como vimos en la sección de estimación de cuantiles, un intervalo de confianza asintótico de nivel $(1 - \beta) \times 100\%$ para el VaR viene dado por

$$\hat{q}_\alpha \pm z_{1-\beta/2} \sqrt{\frac{\alpha(1-\alpha)}{n f(\hat{q}_\alpha)^2}},$$

donde f es la densidad de X evaluada en el cuantil, y $z_{1-\beta/2}$ es el cuantil de la distribución normal estándar. En la práctica, la densidad $f(\hat{q}_\alpha)$ se estima mediante un estimador de densidad (como un histograma o un estimador de núcleo).

El estimador del CVaR se obtiene como el promedio de las observaciones que exceden el VaR estimado:

$$\widehat{\text{CVaR}}_\alpha(X) = \frac{1}{n(1 - \alpha)} \sum_{i=1}^n X_i \mathbb{1}_{\{X_i \geq \hat{q}_\alpha\}}.$$

Este estimador es consistente y converge al CVaR verdadero cuando $n \rightarrow \infty$, siempre que $\mathbb{E}[|X|] < \infty$. En el caso de rendimientos, el estimador se adapta reemplazando la condición $X_i \geq \hat{q}_\alpha$ por $X_i \leq \hat{q}_\alpha$.

5. Métodos de reducción de varianza

El método de Monte Carlo estándar proporciona estimadores insesgados y consistentes, pero su precisión está limitada por la varianza del estimador. Como vimos, el error estándar del estimador Monte Carlo decrece como $1/\sqrt{n}$, lo que implica que para reducir el error a la mitad se necesita cuadruplicar el tamaño de la muestra. En muchas aplicaciones, especialmente cuando cada simulación es costosa computacionalmente, este enfoque resulta ineficiente.

Los métodos de reducción de varianza son técnicas que permiten obtener estimadores con menor varianza para un mismo número de simulaciones n , o equivalentemente, alcanzar una precisión deseada con menos réplicas. La idea general es aprovechar el conocimiento que tenemos sobre el problema (estructura del modelo, dependencias, simetrías, etc.) para modificar el esquema de muestreo o el estimador, de modo que se reduzca la variabilidad sin alterar el valor esperado.

A continuación presentamos algunas de las técnicas más comunes y utilizadas en la práctica.

5.1. Variables antitéticas

El método de variables antitéticas es una de las técnicas de reducción de varianza más sencillas y efectivas. Se basa en la siguiente idea: si generamos dos muestras que están correlacionadas negativamente, la varianza de su promedio puede ser menor que la varianza del promedio de dos muestras independientes.

Supongamos que queremos estimar $\theta = \mathbb{E}[h(X)]$, donde $X \sim \mathcal{L}(f)$. En el método estándar, generamos n réplicas independientes $X_1, \dots, X_n$ y calculamos

$$\hat{\theta}_n = \frac{1}{n} \sum_{i=1}^n h(X_i).$$

En el método de variables antitéticas, en lugar de generar n variables independientes, generamos $n/2$ pares de variables (X_i, X'_i) tales que:

- X_i y X'_i tienen la misma distribución marginal que X ,
- X_i y X'_i están negativamente correlacionadas (antitéticas),
- los pares (X_i, X'_i) son independientes entre sí.

El estimador se define entonces como

$$\hat{\theta}_n^{\text{ant}} = \frac{1}{n} \sum_{i=1}^{n/2} (h(X_i) + h(X'_i)).$$

Es inmediato comprobar que este estimador es insesgado:

$$\mathbb{E}[\hat{\theta}_n^{\text{ant}}] = \frac{1}{n} \sum_{i=1}^{n/2} (\mathbb{E}[h(X_i)] + \mathbb{E}[h(X'_i)]) = \frac{1}{n} \sum_{i=1}^{n/2} 2\theta = \theta.$$

La varianza del estimador antitético es

$$\text{Var}(\hat{\theta}_n^{\text{ant}}) = \frac{1}{n^2} \sum_{i=1}^{n/2} \text{Var}(h(X_i) + h(X'_i)) = \frac{1}{n^2} \sum_{i=1}^{n/2} (2\sigma^2 + 2\text{Cov}(h(X_i), h(X'_i))),$$

donde $\sigma^2 = \text{Var}(h(X))$. Como hay $n/2$ términos,

$$\text{Var}(\hat{\theta}_n^{\text{ant}}) = \frac{1}{n^2} \cdot \frac{n}{2} (2\sigma^2 + 2\text{Cov}(h(X_i), h(X'_i))) = \frac{\sigma^2}{n} + \frac{\text{Cov}(h(X_i), h(X'_i))}{n}.$$

Para el estimador estándar con n réplicas, la varianza es σ^2/n . Por lo tanto, el método antitético reduce la varianza si y solo si

$$\text{Cov}(h(X_i), h(X'_i)) < 0.$$

Es decir, la ganancia en precisión depende de que $h(X)$ y $h(X')$ estén negativamente correlacionadas. En particular, si h es monótona, la correlación negativa entre X y X' se traslada a $h(X)$ y $h(X')$.

Un caso típico de construcción de variables antitéticas ocurre cuando X se genera mediante la transformada inversa: si $U \sim \text{Unif}(0, 1)$ y $X = F^{-1}(U)$, entonces $X' = F^{-1}(1 - U)$ es antitética a X , ya que U y $1 - U$ están perfectamente correlacionadas negativamente. Para distribuciones simétricas, como la normal o la uniforme, esto equivale a tomar $X' = -X$ o $X' = 2\mu - X$.

El algoritmo para implementar el método de variables antitéticas es el siguiente:

1. Fijar el número de pares $m = n/2$ (donde n es el número total de evaluaciones de h).
2. Para $i = 1, \dots, m$:
 - a) Generar una variable aleatoria X_i con distribución f .
 - b) Construir su antitética X'_i mediante algún método (por ejemplo, transformada inversa con $1 - U$).
 - c) Calcular $Y_i = \frac{1}{2}(h(X_i) + h(X'_i))$.
3. El estimador es $\hat{\theta}_n^{\text{ant}} = \frac{1}{m} \sum_{i=1}^m Y_i$.

La ventaja principal del método es su simplicidad y el hecho de que no requiere ningún conocimiento adicional sobre el problema, más allá de saber generar variables antitéticas. La desventaja es que la reducción de varianza no está garantizada para cualquier función h ; si h no es monótona, la correlación puede ser positiva, empeorando la estimación. Por ello, es recomendable verificar en cada aplicación si el método produce una reducción efectiva.

Ejemplo 5.1. Supongamos que queremos calcular

$$I = \int_a^b f(x) dx,$$

donde f es monótona.

Sea $U \sim \text{Unif}(0, 1)$. Entonces $1 - U \sim \text{Unif}(0, 1)$ y

$$\text{Cov}(U, 1 - U) = \text{Cov}(U, 1) + \text{Cov}(U, -U) = -\text{Cov}(U, U) = -\text{Var}(U) < 0.$$

Es decir, U y $1 - U$ están negativamente correlacionadas.

Además, si $U \sim \text{Unif}(0, 1)$, entonces

$$X = a + (b - a)U \sim \text{Unif}(a, b),$$

con $a < b$.

Por lo tanto, podemos considerar la muestra

$$(X_1, Y_1), (X_2, Y_2), \dots, (X_n, Y_n),$$

donde

$$X_i = a + (b - a)U_i, \quad Y_i = a + (b - a)V_i,$$

con

$$U_1, \dots, U_n \stackrel{i.i.d.}{\sim} \text{Unif}(0, 1), \quad V_i = 1 - U_i.$$

Esto permite construir el estimador

$$\hat{I} = (b - a) \frac{1}{n} \sum_{i=1}^n \frac{f(X_i) + f(Y_i)}{2}.$$

Este estimador es insesgado y, si f es monótona, tiene varianza menor que el estimador estándar basado en $2n$ muestras independientes.

Ejemplo 5.2 (Monte Carlo con normal multivariada y variables antitéticas). Sea $X \in \mathbb{R}^d$ una variable aleatoria con distribución normal multivariada

$$X \sim \mathcal{N}(\mu, \Sigma),$$

donde $\mu \in \mathbb{R}^d$ es el vector de medias y $\Sigma \in \mathbb{R}^{d \times d}$ es la matriz de covarianza, simétrica definida positiva. Nuestro objetivo es estimar

$$\theta = \mathbb{E}[f(X)],$$

para alguna función medible $f : \mathbb{R}^d \rightarrow \mathbb{R}$.

Para generar muestras de X , utilizamos la factorización de Cholesky $\Sigma = LL^\top$. Si $Z \sim \mathcal{N}(0, I_d)$, entonces

$$X = \mu + LZ \sim \mathcal{N}(\mu, \Sigma).$$

Dada una muestra $Z_1, \dots, Z_n \sim \mathcal{N}(0, I_d)$, construimos $X_i = \mu + LZ_i$ para $i = 1, \dots, n$. El estimador Monte Carlo estándar es

$$\hat{\theta}_{MC} = \frac{1}{n} \sum_{i=1}^n f(X_i).$$

Este estimador es insesgado y su varianza es $\text{Var}(\hat{\theta}_{MC}) = \text{Var}(f(X))/n$.

Para reducir la varianza, podemos usar variables antitéticas. Observemos que si $Z \sim \mathcal{N}(0, I_d)$, entonces también $-Z \sim \mathcal{N}(0, I_d)$. Por lo tanto, si definimos

$$X_1 = \mu + LZ, \quad X_2 = \mu - LZ,$$

ambas variables tienen la misma distribución $\mathcal{N}(\mu, \Sigma)$. Definimos el par antitético

$$Y = \frac{f(X_1) + f(X_2)}{2}.$$

Si generamos n pares antitéticos independientes, el estimador antitético es

$$\hat{\theta}_A = \frac{1}{n} \sum_{i=1}^n \frac{f(X_{i,1}) + f(X_{i,2})}{2}.$$

Este estimador es insesgado y, si f es monótona en cada componente, tendrá una varianza menor que el estimador estándar.

5.2. Variables de control

El método de variables de control es una técnica de reducción de varianza que aprovecha la información de variables auxiliares correlacionadas con la variable de interés. La idea fundamental es utilizar el conocimiento de la esperanza de una variable auxiliar W para corregir el estimador de $\mathbb{E}[X]$, reduciendo así su variabilidad.

Supongamos que queremos estimar $\theta = \mathbb{E}[X]$ mediante simulación Monte Carlo, y que existe otra variable W (la variable de control) cuya esperanza $\mu_W = \mathbb{E}[W]$ es conocida. Definimos el estimador con control como

$$\tilde{\theta} = \bar{X} - C(\bar{W} - \mu_W),$$

donde

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, \quad \bar{W} = \frac{1}{n} \sum_{i=1}^n W_i,$$

y C es una constante a elegir.

Este estimador es insesgado para cualquier valor de C , ya que

$$\mathbb{E}[\tilde{\theta}] = \mathbb{E}[\bar{X}] - C(\mathbb{E}[\bar{W}] - \mu_W) = \theta - C(\mu_W - \mu_W) = \theta.$$

La varianza del estimador es

$$\text{Var}(\tilde{\theta}) = \text{Var}(\bar{X}) + C^2 \text{Var}(\bar{W}) - 2C \text{Cov}(\bar{X}, \bar{W}) = \frac{1}{n} (\text{Var}(X) + C^2 \text{Var}(W) - 2C \text{Cov}(X, W)).$$

Esta expresión es una función cuadrática en C . Para encontrar el valor que minimiza la varianza, derivamos e igualamos a cero:

$$\frac{d}{dC} \text{Var}(\tilde{\theta}) = \frac{1}{n} (2C \text{Var}(W) - 2 \text{Cov}(X, W)) = 0.$$

Resolviendo, obtenemos el coeficiente óptimo

$$C^* = \frac{\text{Cov}(X, W)}{\text{Var}(W)}.$$

Sustituyendo C^* en la expresión de la varianza, obtenemos la varianza mínima alcanzable:

$$\text{Var}(\tilde{\theta}) = \frac{1}{n} \left(\text{Var}(X) - \frac{(\text{Cov}(X, W))^2}{\text{Var}(W)} \right).$$

Esta expresión muestra que la reducción de varianza es tanto mayor cuanto mayor sea la correlación (en valor absoluto) entre X y W . En el caso extremo en que X y W están perfectamente correlacionadas, la varianza se reduce a cero.

En la práctica, $\text{Cov}(X, W)$ y $\text{Var}(W)$ no son conocidos, por lo que el coeficiente óptimo C^* debe estimarse a partir de la muestra. Un estimador natural es

$$\hat{C}_n = \frac{\sum_{i=1}^n (X_i - \bar{X})(W_i - \bar{W})}{\sum_{i=1}^n (W_i - \bar{W})^2}.$$

Este estimador es consistente, es decir, $\hat{C}_n \xrightarrow[n \rightarrow \infty]{\text{c.s.}} C^*$. Cuando se utiliza $\hat{C}_n$ en lugar de C^* , el estimador $\tilde{\theta}$ sigue siendo asintóticamente insesgado y su varianza converge a la varianza mínima.

El método de variables de control es especialmente eficaz cuando:

- La variable de control W está fuertemente correlacionada con X .
- La esperanza $\mu_W = \mathbb{E}[W]$ se conoce de forma exacta.
- Simular W no añade un coste computacional significativo.

En la práctica, es común que W sea una función de las mismas variables aleatorias que generan X , de modo que el coste adicional de simular W es mínimo.

Ejemplo 5.3. Retomemos el ejemplo de la estimación de π mediante el método del cuadrado inscrito. Recordemos que

$$X = 4 \mathbb{1}_{\{U_1^2 + U_2^2 \leq 1\}},$$

donde $U_1, U_2 \sim i.i.d. \text{ Unif}(0, 1)$, y que $\mathbb{E}[X] = \pi$.

Consideremos ahora la variable de control

$$W = \mathbb{1}_{\{U_1 + U_2 > \sqrt{2}\}}.$$

Su esperanza se puede calcular analíticamente:

$$\mathbb{E}[W] = \mathbb{P}(U_1 + U_2 > \sqrt{2}) = \mathbb{P}(U_1 > \sqrt{2} - U_2).$$

Esta probabilidad se obtiene integrando sobre la región correspondiente del cuadrado unitario:

$$\mathbb{E}[W] = \int_{\sqrt{2}-1}^1 \int_{\sqrt{2}-u_2}^1 du_1 du_2 = \int_{\sqrt{2}-1}^1 (1 - \sqrt{2} + u_2) du_2 = 3 - 2\sqrt{2}.$$

Como $\mathbb{E}[W]$ es conocido, podemos utilizarlo como variable de control para estimar π . El estimador con control es

$$\tilde{\pi} = \hat{\mathbb{E}}[X] - C \left(\hat{\mathbb{E}}[W] - \mathbb{E}[W] \right),$$

donde

$$C = -\frac{\text{Cov}(X, W)}{\text{Var}(W)}.$$

5.3. Monte Carlo condicionado

El método de Monte Carlo condicionado, también conocido como *muestreo condicional* o *integración anidada*, es una técnica de reducción de varianza que explota la estructura de dependencia del problema para promediar de forma analítica algunas de las variables aleatorias. La idea fundamental se basa en la identidad de la esperanza condicional:

$$\mathbb{E}[X] = \mathbb{E}[\mathbb{E}[X | Y]],$$

donde Y es alguna variable aleatoria auxiliar. Si podemos calcular $\mathbb{E}[X | Y = y]$ de forma explícita, entonces el estimador

$$\hat{\theta}_{\text{cond}} = \frac{1}{n} \sum_{i=1}^n \mathbb{E}[X | Y_i]$$

es insesgado para $\mathbb{E}[X]$ y, además, tiene varianza menor o igual que el estimador estándar $\hat{\theta} = \frac{1}{n} \sum_{i=1}^n X_i$. Esto se deduce de la descomposición de la varianza:

$$\text{Var}(X) = \text{Var}(\mathbb{E}[X | Y]) + \mathbb{E}[\text{Var}(X | Y)] \geq \text{Var}(\mathbb{E}[X | Y]).$$

Por lo tanto,

$$\text{Var}(\hat{\theta}_{\text{cond}}) = \frac{1}{n} \text{Var}(\mathbb{E}[X | Y]) \leq \frac{1}{n} \text{Var}(X) = \text{Var}(\hat{\theta}).$$

La reducción es tanto mayor cuanto mayor sea la varianza de $\mathbb{E}[X | Y]$ relativa a la varianza total. En el caso extremo en que X está determinada por Y , la varianza del estimador condicional se reduce a cero.

Ejemplo 5.4. Retomemos el ejemplo de la estimación de π mediante el método del cuadrado inscrito. Teníamos

$$X = 4 \mathbb{1}_{\{U_1^2 + U_2^2 \leq 1\}},$$

con $U_1, U_2 \sim i.i.d. \text{ Unif}(0, 1)$, y sabemos que $\mathbb{E}[X] = \pi$.

En lugar de estimar directamente $\mathbb{E}[X]$, podemos condicionar respecto a U_1 . Definimos

$$X_{\text{cond}} = \mathbb{E}[X | U_1].$$

Entonces,

$$X_{\text{cond}} = 4 \mathbb{P}(U_1^2 + U_2^2 \leq 1 | U_1) = 4 \mathbb{P}(U_2 \leq \sqrt{1 - U_1^2} | U_1) = 4\sqrt{1 - U_1^2}.$$

Por lo tanto, si generamos una muestra $U_1^{(1)}, \dots, U_1^{(n)}$ independientes con distribución $\text{Unif}(0, 1)$, podemos estimar π mediante

$$\hat{\pi}_{\text{cond}} = \frac{1}{n} \sum_{i=1}^n 4\sqrt{1 - (U_1^{(i)})^2}.$$

5.4. Muestreo estratificado

El muestreo estratificado es una técnica de reducción de varianza que consiste en dividir el dominio de integración (o el espacio muestral) en subregiones disjuntas, llamadas *estratos*, y muestrear de

forma independiente en cada uno de ellos. La idea es garantizar que todas las regiones del dominio estén representadas en la muestra, evitando que el estimador esté dominado por fluctuaciones en zonas de baja probabilidad.

Supongamos que queremos estimar $\theta = \mathbb{E}[h(X)]$, donde X tiene densidad f sobre un dominio Ω . Particionamos Ω en S estratos $\Omega_1, \dots, \Omega_S$, disjuntos y cuya unión es Ω . Sea $p_s = \mathbb{P}(X \in \Omega_s) = \int_{\Omega_s} f(x) dx$ la probabilidad de que X caiga en el estrato s . Entonces,

$$\theta = \mathbb{E}[h(X)] = \sum_{s=1}^S p_s \mathbb{E}[h(X) \mid X \in \Omega_s].$$

Si para cada estrato s generamos una muestra independiente de tamaño n_s condicionada a que $X \in \Omega_s$, el estimador estratificado se define como

$$\hat{\theta}_{\text{est}} = \sum_{s=1}^S p_s \hat{\mu}_s, \quad \hat{\mu}_s = \frac{1}{n_s} \sum_{i=1}^{n_s} h(X_{s,i}),$$

donde $X_{s,1}, \dots, X_{s,n_s} \sim \mathcal{L}(X \mid X \in \Omega_s)$. Este estimador es insesgado:

$$\mathbb{E}[\hat{\theta}_{\text{est}}] = \sum_{s=1}^S p_s \mathbb{E}[\hat{\mu}_s] = \sum_{s=1}^S p_s \mathbb{E}[h(X) \mid X \in \Omega_s] = \theta.$$

Su varianza es

$$\text{Var}(\hat{\theta}_{\text{est}}) = \sum_{s=1}^S p_s^2 \frac{\sigma_s^2}{n_s}, \quad \sigma_s^2 = \text{Var}(h(X) \mid X \in \Omega_s).$$

Si se eligen los tamaños muestrales proporcionales a las probabilidades de los estratos, es decir, $n_s = np_s$, la varianza se reduce a

$$\text{Var}(\hat{\theta}_{\text{est}}) = \frac{1}{n} \sum_{s=1}^S p_s \sigma_s^2.$$

Comparando con la varianza del estimador simple (sin estratificar), que es $\text{Var}(h(X))/n$, se tiene que

$$\text{Var}(\hat{\theta}_{\text{est}}) \leq \frac{1}{n} \text{Var}(h(X)),$$

con igualdad solo cuando las medias condicionales son todas iguales. En general, el muestreo estratificado reduce la varianza porque elimina la variabilidad entre estratos.

Ejemplo 5.5 (Integración Monte Carlo Estratificada). Sea $\Omega = [0, 1]$, $U \sim \text{Unif}(0, 1)$ y definimos $X = a + (b - a)U$, con $a < b$. Queremos estimar

$$I = \int_a^b f(x) dx = (b - a)\mathbb{E}[f(X)].$$

Dividimos el intervalo $[0, 1]$ en N estratos:

$$\Omega_n = \left\{ \omega : \frac{n-1}{N} \leq U(\omega) < \frac{n}{N} \right\}, \quad n = 1, \dots, N,$$

de modo que $\Omega = \bigcup_{n=1}^N \Omega_n$. Sea U_n la variable U restringida al estrato Ω_n . Su función de distribución es

$$\mathbb{P}(U_n \leq x) = \begin{cases} 0, & x \leq \frac{n-1}{N}, \\ N \left(x - \frac{n-1}{N} \right), & \frac{n-1}{N} < x < \frac{n}{N}, \\ 1, & x \geq \frac{n}{N}. \end{cases}$$

Por lo tanto, $U_n \sim \text{Unif}\left(\frac{n-1}{N}, \frac{n}{N}\right)$. En consecuencia,

$$X_n = a + (b - a)U_n \sim \text{Unif}\left(a + \frac{n-1}{N}(b - a), a + \frac{n}{N}(b - a)\right).$$

Cada estrato tiene probabilidad $p_n = 1/N$. Si generamos R_n simulaciones en cada estrato, el estimador estratificado de la integral es

$$\hat{I} = (b - a) \sum_{n=1}^N p_n \hat{\mu}_n, \quad \hat{\mu}_n = \frac{1}{R_n} \sum_{j=1}^{R_n} f(X_{n,j}).$$

Su varianza es

$$\text{Var}(\hat{I}) = (b - a)^2 \sum_{n=1}^N p_n^2 \frac{\sigma_n^2}{R_n},$$

donde $\sigma_n^2 = \text{Var}(f(X_n))$.

Ejemplo 5.6 (Estimación de π mediante estratificación). Retomemos la estimación de π usando el método del cuadrado inscrito. Para reducir la varianza del estimador, dividimos el intervalo $[0, 1]$ en S estratos:

$$I_s = \left[\frac{s-1}{S}, \frac{s}{S} \right], \quad s = 1, \dots, S.$$

Sea $U_1^{(s)} \sim \text{Unif}(\frac{s-1}{S}, \frac{s}{S})$ y $U_2 \sim \text{Unif}(0, 1)$, independiente de $U_1^{(s)}$. Definimos

$$X_s = 4 \mathbb{1}_{\{(U_1^{(s)})^2 + U_2^2 \leq 1\}}.$$

Sea $\mu_s = \mathbb{E}[X_s]$. Como todos los estratos tienen la misma probabilidad $p_s = 1/S$, se tiene que

$$\pi = \sum_{s=1}^S p_s \mu_s = \frac{1}{S} \sum_{s=1}^S \mu_s.$$

Si generamos n simulaciones en cada estrato, obtenemos el estimador

$$\hat{\mu}_s = \frac{1}{n} \sum_{i=1}^n X_{s,i},$$

y el estimador estratificado de π es

$$\hat{\pi}_{est} = \frac{1}{S} \sum_{s=1}^S \hat{\mu}_s.$$

Sea $\sigma_s^2 = \text{Var}(X_s)$. La varianza del estimador estratificado es

$$\text{Var}(\hat{\pi}_{est}) = \sum_{s=1}^S p_s^2 \frac{\sigma_s^2}{n} = \frac{1}{S^2 n} \sum_{s=1}^S \sigma_s^2.$$

En la práctica, estimamos esta varianza mediante

$$\widehat{\text{Var}}(\hat{\pi}_{est}) = \frac{1}{S^2 n} \sum_{s=1}^S \hat{\sigma}_s^2, \quad \hat{\sigma}_s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_{s,i} - \hat{\mu}_s)^2.$$

Este estimador tiene varianza menor que el estimador simple, especialmente cuando la probabilidad de caer dentro del círculo varía significativamente entre estratos.

5.5. Muestreo por importancia

El método de Monte Carlo permite aproximar cantidades de la forma

$$\mu = \mathbb{E}_f[h(X)] = \int h(x)f(x) dx$$

cuando es difícil calcular la integral analíticamente. Si podemos simular muestras $X_1, \dots, X_n \sim f$, un estimador natural es

$$\hat{\mu}_{MC} = \frac{1}{n} \sum_{i=1}^n h(X_i).$$

Sin embargo, cuando la función h toma valores grandes en regiones de baja probabilidad bajo f , el estimador puede tener una varianza muy elevada. El **muestreo por importancia** (*importance sampling*) es una técnica de reducción de varianza que consiste en introducir una densidad auxiliar g tal que $g(x) > 0$ siempre que $f(x)h(x) \neq 0$. Entonces,

$$\mu = \int h(x)f(x) dx = \int h(x) \frac{f(x)}{g(x)} g(x) dx = \mathbb{E}_g \left[h(Y) \frac{f(Y)}{g(Y)} \right],$$

donde $Y \sim g$. Esto conduce al estimador de Monte Carlo

$$\hat{\mu}_{IS} = \frac{1}{n} \sum_{i=1}^n h(Y_i) \frac{f(Y_i)}{g(Y_i)}, \quad Y_i \sim g.$$

El cociente $w(y) = f(y)/g(y)$ se denomina *peso de importancia* o *razón de verosimilitud*. El estimador es insesgado:

$$\mathbb{E}_g[\hat{\mu}_{IS}] = \mathbb{E}_g \left[h(Y) \frac{f(Y)}{g(Y)} \right] = \mathbb{E}_f[h(Y)] = \mu.$$

Su varianza es

$$\text{Var}_g(\hat{\mu}_{IS}) = \frac{1}{n} \text{Var}_g \left(h(Y) \frac{f(Y)}{g(Y)} \right).$$

Ejemplo 5.7 (Estimación de probabilidades de cola de una normal). Sea $Z \sim \mathcal{N}(0, 1)$. Queremos estimar la probabilidad

$$p(x) = \mathbb{P}(Z \geq x),$$

para x grande. Esta cantidad puede escribirse como

$$p(x) = \mathbb{E}[\mathbb{1}_{\{Z \geq x\}}] = \int \mathbb{1}_{\{y \geq x\}} \varphi(y) dy,$$

donde φ es la densidad de la normal estándar $\varphi(y) = \frac{1}{\sqrt{2\pi}} e^{-y^2/2}$.

El estimador Monte Carlo directo consiste en generar $Z_1, \dots, Z_n \sim \mathcal{N}(0, 1)$ y calcular

$$\hat{p}_{MC} = \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{\{Z_i \geq x\}}.$$

Cuando x es grande, esta probabilidad es muy pequeña y la mayoría de las simulaciones no contribuyen al estimador, lo que provoca una varianza elevada.

Para mejorar la eficiencia, introducimos una densidad auxiliar definida sobre $[x, \infty)$:

$$g(y) = e^{-(y-x)} \mathbb{1}_{\{y \geq x\}},$$

la cual corresponde a una distribución exponencial desplazada. Si $Y \sim g$, entonces $Y = x + E$, donde $E \sim \text{Exp}(1)$.

La probabilidad buscada puede reescribirse como

$$p(x) = \int_x^\infty \varphi(y) dy = \int \mathbb{1}_{\{y \geq x\}} \frac{\varphi(y)}{g(y)} g(y) dy = \mathbb{E}_g \left[\mathbb{1}_{\{Y \geq x\}} \frac{\varphi(Y)}{g(Y)} \right].$$

El estimador de importancia es entonces

$$\hat{p}_{IS} = \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{\{Y_i \geq x\}} \frac{\varphi(Y_i)}{g(Y_i)}, \quad Y_i \sim g.$$

Su varianza se estima mediante

$$\widehat{\text{Var}}(\hat{p}_{IS}) = \frac{1}{n} \widehat{\text{Var}}_g \left(\mathbb{1}_{\{Y \geq x\}} \frac{\varphi(Y)}{g(Y)} \right).$$

El valor exacto de la probabilidad se conoce: $p(x) = 1 - \Phi(x)$, donde Φ es la función de distribución acumulada de la normal estándar. Esto permite comparar la precisión de ambos estimadores.

La elección adecuada de g puede reducir significativamente esta varianza. En particular, si se elige g proporcional a $|h|f$, la varianza se anula, aunque en la práctica esto no es posible porque precisamente μ es desconocido. No obstante, una buena elección de g concentra el muestreo en las regiones donde h es grande, mejorando la eficiencia del estimador.

Ejemplo 5.8 (Estimación de la función generadora de momentos de una normal). Sea X una variable aleatoria con densidad f . La **función generadora de momentos** (FGM) de X se define como

$$M_X(t) = \mathbb{E}[e^{tX}],$$

siempre que la esperanza exista. Para una variable normal $X \sim \mathcal{N}(\mu, \sigma^2)$, se conoce que

$$M_X(t) = \exp \left(\mu t + \frac{\sigma^2 t^2}{2} \right).$$

En términos de integrales, la FGM puede escribirse como

$$M_X(t) = \int e^{tx} f(x) dx.$$

Un estimador Monte Carlo natural es

$$\widehat{M}_{MC}(t) = \frac{1}{n} \sum_{i=1}^n e^{tX_i}, \quad X_i \sim f.$$

Este estimador es insesgado, pero su varianza puede crecer rápidamente cuando t es grande debido al término exponencial e^{tX} .

Para reducir la varianza, podemos utilizar muestreo por importancia. La FGM se escribe como

$$M_X(t) = \mathbb{E}_f[h(X)], \quad h(x) = e^{tx}.$$

Introduciendo una densidad auxiliar g , obtenemos

$$M_X(t) = \mathbb{E}_g \left[h(Y) \frac{f(Y)}{g(Y)} \right], \quad Y \sim g.$$

El estimador de importancia es

$$\widehat{M}_{IS}(t) = \frac{1}{n} \sum_{i=1}^n h(Y_i) \frac{f(Y_i)}{g(Y_i)}, \quad Y_i \sim g.$$

Para el muestreo utilizemos función de densidad que minimiza la varianza del estimador, es decir,

$$g(x) = \frac{|h(x)|f(x)}{c}, \quad c = \int |h(x)|f(x) dx.$$

En este problema $h(x) = e^{tx} > 0$, por lo que

$$g(x) \propto e^{tx} f(x).$$

Sustituyendo la densidad normal,

$$g(x) \propto e^{tx} \exp \left(-\frac{(x - \mu)^2}{2\sigma^2} \right).$$

Agrupando los exponentes,

$$g(x) \propto \exp \left(tx - \frac{(x - \mu)^2}{2\sigma^2} \right).$$

Expandimos el cuadrado $(x - \mu)^2 = x^2 - 2\mu x + \mu^2$. Entonces,

$$tx - \frac{(x - \mu)^2}{2\sigma^2} = -\frac{x^2}{2\sigma^2} + \left(\frac{\mu}{\sigma^2} + t\right)x - \frac{\mu^2}{2\sigma^2}.$$

Completando el cuadrado en x , se obtiene

$$g(x) \propto \exp\left(-\frac{(x - (\mu + \sigma^2 t))^2}{2\sigma^2}\right).$$

Por lo tanto, la densidad de importancia óptima es

$$g(x) = \mathcal{N}(\mu + \sigma^2 t, \sigma^2).$$

Es decir, se toma una normal con la misma varianza que la original pero con la media desplazada en $\sigma^2 t$. Con esta elección, la varianza del estimador se reduce considerablemente, especialmente para valores grandes de t .

5.5.1. Valoración de una opción Call mediante Monte Carlo e Importance Sampling

Una **opción call europea** es un derivado financiero que otorga al tenedor el derecho, pero no la obligación, de comprar un activo subyacente en una fecha futura T a un precio predeterminado K (precio de ejercicio). El pago (*payoff*) de una call europea al tiempo T está dado por

$$(S_T - K)^+ = \max(S_T - K, 0),$$

donde S_T es el precio del activo subyacente en el tiempo T .

En el modelo de Black–Scholes se supone que el precio del activo sigue la ecuación diferencial estocástica

$$dS_t = rS_t dt + \sigma S_t dW_t,$$

donde r es la tasa libre de riesgo, σ es la volatilidad y W_t es un movimiento browniano estándar. La solución de esta ecuación es

$$S_t = S_0 \exp\left(\left(r - \frac{\sigma^2}{2}\right)t + \sigma W_t\right).$$

Como $W_t \sim \mathcal{N}(0, t)$, podemos escribir

$$S_t = S_0 \exp\left(\left(r - \frac{\sigma^2}{2}\right)t + \sigma\sqrt{t}Z\right),$$

donde $Z \sim \mathcal{N}(0, 1)$. Este proceso se conoce como **movimiento browniano geométrico**.

El precio de la opción es el valor esperado descontado del payoff:

$$C = e^{-rT} \mathbb{E}[(S_T - K)^+].$$

Para el modelo de Black–Scholes existe una fórmula cerrada:

$$C = S_0 \Phi(d_1) - K e^{-rT} \Phi(d_2),$$

donde Φ es la función de distribución de la normal estándar y

$$d_1 = \frac{\log(S_0/K) + (r + \sigma^2/2)T}{\sigma\sqrt{T}}, \quad d_2 = d_1 - \sigma\sqrt{T}.$$

Utilizando la representación de S_T , el precio puede estimarse simulando variables normales estándar $Z_1, \dots, Z_n$ y calculando

$$S_T^{(i)} = S_0 \exp \left(\left(r - \frac{\sigma^2}{2} \right) T + \sigma\sqrt{T} Z_i \right).$$

El estimador Monte Carlo del precio es

$$\hat{C}_{MC} = e^{-rT} \frac{1}{n} \sum_{i=1}^n (S_T^{(i)} - K)^+.$$

Para reducir la varianza del estimador, podemos utilizar el muestreo por importancia. Recordemos que

$$C = e^{-rT} \mathbb{E}_f[h(Z)],$$

donde

$$h(Z) = \left(S_0 \exp \left(\left(r - \frac{\sigma^2}{2} \right) T + \sigma\sqrt{T} Z \right) - K \right)^+$$

y $Z \sim \mathcal{N}(0, 1)$ con densidad f . En lugar de muestrear de f , se introduce una densidad propuesta g dada por $Z \sim \mathcal{N}(\theta, 1)$. Entonces

$$C = e^{-rT} \mathbb{E}_g \left[h(Z) \frac{f(Z)}{g(Z)} \right].$$

Si $Z \sim \mathcal{N}(\theta, 1)$, el cociente de densidades es

$$\frac{f(Z)}{g(Z)} = \exp \left(-\theta Z + \frac{\theta^2}{2} \right).$$

Por lo tanto, el estimador de importancia es

$$\hat{C}_{IS} = e^{-rT} \frac{1}{n} \sum_{i=1}^n h(Z_i) \exp \left(-\theta Z_i + \frac{\theta^2}{2} \right),$$

con $Z_i \sim \mathcal{N}(\theta, 1)$.

En la práctica se utiliza

$$\theta = \frac{\log(K/S_0) - (r - \sigma^2/2)T}{\sigma\sqrt{T}}.$$

Este valor desplaza la distribución de Z hacia la región donde $S_T > K$, es decir, donde la opción tiene payoff positivo. De esta forma se incrementa la frecuencia de trayectorias relevantes y se reduce la varianza del estimador.

5.5.2. Muestreo por importancia normalizado

En muchos problemas estadísticos se conoce únicamente el *kernel* de una densidad, es decir, $f_{\text{ker}}(x)$, pero no la densidad normalizada

$$f(x) = \frac{f_{\text{ker}}(x)}{\int f_{\text{ker}}(x) dx}.$$

Esto ocurre frecuentemente en inferencia bayesiana, donde la distribución posterior se conoce sólo hasta una constante de normalización.

Supongamos que queremos calcular

$$\mathbb{E}_f[h(X)] = \int h(x)f(x) dx.$$

Si podemos muestrear de una densidad propuesta g , entonces usando muestreo por importancia se obtiene

$$\mathbb{E}_f[h(X)] = \frac{\int h(x)f_{\text{ker}}(x) dx}{\int f_{\text{ker}}(x) dx}.$$

Sea $X_1, \dots, X_n \sim g$. Entonces, por el Teorema de Slutsky, se puede utilizar el estimador Monte Carlo

$$\mathbb{E}_f[h(X)] \approx \frac{\frac{1}{n} \sum_{i=1}^n h(X_i) \frac{f_{\text{ker}}(X_i)}{g(X_i)}}{\frac{1}{n} \sum_{i=1}^n \frac{f_{\text{ker}}(X_i)}{g(X_i)}}.$$

Este estimador puede escribirse como un promedio ponderado

$$\mathbb{E}_f[h(X)] \approx \sum_{i=1}^n W_i h(X_i),$$

donde los pesos normalizados son

$$W_i = \frac{\frac{f_{\text{ker}}(X_i)}{g(X_i)}}{\sum_{j=1}^n \frac{f_{\text{ker}}(X_j)}{g(X_j)}}, \quad X_i \sim g.$$

A este procedimiento se le conoce como **muestreo por importancia normalizado** (*Normalized Importance Sampling*). La ventaja de este enfoque es que no requiere conocer la constante de normalización de f , solo su kernel. Sin embargo, los pesos W_i son ahora aleatorios y el estimador puede tener un sesgo de orden $1/n$, aunque es asintóticamente insesgado.

Caso multivariado Sea ahora $X = (X_1, \dots, X_d)$ un vector aleatorio con densidad conjunta $f(x_1, \dots, x_d)$. Entonces,

$$\mathbb{E}[X_i] = \int_{\mathbb{R}^d} x_i f(x_1, \dots, x_d) dx_1 \cdots dx_d.$$

Si f sólo se conoce hasta una constante de normalización, es decir, $f(x) \propto f_{\text{ker}}(x)$, podemos utilizar muestreo por importancia normalizado con una densidad propuesta g sobre $\mathbb{R}^d$.

Si $X_1, \dots, X_n \sim g$, los pesos de importancia son

$$W_i = \frac{\frac{f_{\text{ker}}(X_i)}{g(X_i)}}{\sum_{j=1}^n \frac{f_{\text{ker}}(X_j)}{g(X_j)}}.$$

Entonces, para cualquier función $h : \mathbb{R}^d \rightarrow \mathbb{R}$,

$$\mathbb{E}_f[h(X)] \approx \sum_{i=1}^n W_i h(X_i).$$

Este enfoque es especialmente útil en problemas de alta dimensión o cuando la densidad objetivo tiene una forma compleja y solo se conoce hasta una constante, como ocurre en los modelos jerárquicos bayesianos.

Ejemplo 5.9 (Regresión logística bayesiana). *Sea un conjunto de datos (x_i, y_i) para $i = 1, \dots, n$ donde*

$$x_i \in \mathbb{R}^d, \quad y_i \in \{0, 1\}.$$

El modelo de regresión logística supone

$$\mathbb{P}(Y_i = 1 \mid x_i, \beta) = \sigma(x_i^\top \beta),$$

donde

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

es la función sigmoide y $\beta \in \mathbb{R}^d$ es el vector de parámetros. Es decir,

$$Y_i \mid x_i, \beta \sim \text{Bernoulli}(\sigma(x_i^\top \beta)).$$

Adicionalmente, supongamos que las observaciones son independientes y que la distribución a priori es $\beta \sim \mathcal{N}(0, \sigma_0^2 I_d)$. Entonces, la verosimilitud del modelo es

$$L(Y \mid X, \beta) = \prod_{i=1}^n \sigma(x_i^\top \beta)^{y_i} (1 - \sigma(x_i^\top \beta))^{1-y_i},$$

y por lo tanto, la distribución posterior es

$$p(\beta \mid X, Y) = \frac{p(\beta, X, Y)}{p(X, Y)} \propto L(Y \mid X, \beta) p(\beta).$$

Esta densidad solo se conoce hasta una constante de normalización, por lo que es natural utilizar muestreo por importancia normalizado.

Para ello, se introduce una distribución propuesta

$$g(\beta) = \mathcal{N}(0, \sigma_q^2 I_d).$$

Si $\beta_1, \dots, \beta_n \sim g$, los pesos no normalizados son

$$w_i = \frac{f_{ker}(\beta_i)}{g(\beta_i)} = \frac{L(\beta_i | X, Y) p(\beta_i)}{g(\beta_i)}.$$

Los pesos normalizados son

$$W_i = \frac{w_i}{\sum_{j=1}^n w_j}.$$

La media posterior de β se aproxima mediante

$$\hat{\beta} = \sum_{i=1}^n W_i \beta_i.$$

Este estimador corresponde al promedio ponderado de las muestras según los pesos de importancia. De esta forma, se obtiene una aproximación de la media posterior sin necesidad de conocer la constante de normalización de $p(\beta | X, Y)$.

6. Monte Carlo vía cadenas de Markov

El método de Monte Carlo vía cadenas de Markov (MCMC) es una técnica que permite generar muestras de distribuciones complejas, especialmente cuando no es posible muestrear directamente de ellas. La idea es construir una cadena de Markov cuya distribución estacionaria sea precisamente la distribución de interés, y simular la cadena durante un tiempo suficientemente largo para que sus valores se aproximen a muestras de dicha distribución. Este enfoque es fundamental en problemas de alta dimensión y en inferencia bayesiana, donde las distribuciones posteriores suelen ser intratables.

6.1. Cadenas de Markov con espacio de estados continuo

Un proceso estocástico $\{X_t : t = 0, 1, 2, \dots\}$ con espacio de estados $S \subseteq \mathbb{R}^d$ es una cadena de Markov si cumple la propiedad de Markov:

$$\mathbb{P}(X_{t+1} \in A | X_t = x_t, \dots, X_0 = x_0) = \mathbb{P}(X_{t+1} \in A | X_t = x_t),$$

para cualquier conjunto medible $A \subset S$ y cualquier secuencia de estados $x_0, \dots, x_t \in S$, con $t \geq 0$ entero. Es decir, el futuro solo depende del presente, no de la historia pasada.

En este curso nos centraremos en cadenas de Markov *homogéneas en el tiempo*, lo que significa que las probabilidades de transición no dependen del instante t . Más aún, supondremos que estas probabilidades se pueden expresar mediante una función de densidad de transición (o kernel) $p(x, y)$, de modo que

$$\mathbb{P}(X_{t+1} \in A \mid X_t = x) = \int_A p(x, y) dy.$$

La función $p : S \times S \rightarrow [0, \infty)$ se denomina *kernel de transición en un paso*. Para cada $x \in S$, la función $y \mapsto p(x, y)$ es una densidad de probabilidad, por lo que

$$\int_S p(x, y) dy = 1, \quad \forall x \in S.$$

La notación $p(x, y)$ también puede escribirse como $p(y \mid x)$ o $p_x(y)$, enfatizando que x es el estado inicial y y el estado final.

Ejemplo 6.1 (Paseo aleatorio con ruido gaussiano). *Un ejemplo clásico de cadena de Markov con espacio de estados continuo es el paseo aleatorio con kernel de transición gaussiano:*

$$p(x, y) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y-x)^2}{2\sigma^2}\right).$$

En este caso, el siguiente estado X_{t+1} se obtiene sumando al estado actual X_t un ruido normal con media 0 y varianza σ^2 :

$$X_{t+1} = X_t + \varepsilon_{t+1}, \quad \varepsilon_{t+1} \sim \mathcal{N}(0, \sigma^2).$$

Este kernel es simétrico ($p(x, y) = p(y, x)$) y es la base de muchos algoritmos MCMC, como el muestreador de Metropolis–Hastings.

Ejemplo 6.2. *Consideremos nuevamente el paseo aleatorio con kernel gaussiano*

$$p(x, y) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y-x)^2}{2\sigma^2}\right).$$

En este caso, la densidad de transición en n pasos también es gaussiana:

$$p^{(n)}(x, y) = \frac{1}{\sqrt{2\pi n\sigma^2}} \exp\left(-\frac{(y-x)^2}{2n\sigma^2}\right).$$

Es decir, la suma de n ruidos normales independientes con varianza σ^2 tiene varianza $n\sigma^2$.

6.1.1. Funciones de transición en n pasos

Además de las transiciones en un solo paso, en una cadena de Markov es natural considerar las probabilidades de transición en n pasos. Para $n \geq 1$, definimos

$$\mathbb{P}(X_n \in A \mid X_0 = x)$$

como la probabilidad de que, partiendo del estado x , la cadena tome un valor dentro del conjunto medible $A \subset S$ después de exactamente n pasos. Al igual que en el caso de un paso, supondremos que esta probabilidad se puede expresar mediante una función de densidad de transición en n pasos, denotada por $p^{(n)}(x, y)$, de modo que

$$\mathbb{P}(X_n \in A \mid X_0 = x) = \int_A p^{(n)}(x, y) dy.$$

La función $p^{(n)}(x, y)$ es no negativa y, para cada $x \in S$, satisface

$$\int_S p^{(n)}(x, y) dy = 1,$$

pues es una densidad en la variable y .

Una propiedad fundamental que relaciona las transiciones en diferentes horizontes temporales es la *ecuación de Chapman-Kolmogorov*. Esta ecuación establece que, para cualesquiera enteros $0 \leq k \leq n$,

$$p^{(n)}(x, y) = \int_S p^{(k)}(x, z) p^{(n-k)}(z, y) dz.$$

La interpretación es clara: para ir de x a y en n pasos, la cadena debe pasar por algún estado intermedio z después de k pasos, y luego completar el resto del camino en $n - k$ pasos. La integral promedia sobre todos los posibles estados intermedios z , y la igualdad refleja la propiedad de Markov.

En el caso particular $k = 1$, la ecuación se reduce a

$$p^{(n)}(x, y) = \int_S p(x, z) p^{(n-1)}(z, y) dz,$$

lo que permite calcular recursivamente las densidades de transición en n pasos a partir del kernel de un paso.

6.1.2. Irreducibilidad, periodicidad y recurrencia

En el estudio de cadenas de Markov con espacio de estados continuo, es necesario extender conceptos clave que ya conocíamos para el caso discreto. Estas propiedades son fundamentales para

garantizar la convergencia de la cadena a una distribución estacionaria y, por tanto, para la validez de los métodos MCMC.

Irreducibilidad. La irreducibilidad significa que, con probabilidad positiva, la cadena puede visitar cualquier región del espacio de estados, independientemente del punto de partida. Formalmente, sea π una función de densidad sobre el espacio de estados S . Se dice que la cadena con kernel $p(x, y)$ es π -irreducible si para todo $x \in S$ y para todo conjunto medible $A \subset S$ con $\pi(A) > 0$, existe un entero $n \geq 0$ tal que

$$p^{(n)}(x, A) = \int_A p^{(n)}(x, y) dy > 0.$$

En palabras, desde cualquier estado inicial x hay una probabilidad estrictamente positiva de alcanzar el conjunto A en algún número finito de pasos. Esta propiedad asegura que la cadena no está confinada a subregiones del espacio y que puede explorar todo el soporte de π .

Periodicidad. La periodicidad se refiere a la existencia de ciclos deterministas en la cadena. Para una cadena π -irreducible, se dice que tiene un ciclo de longitud $d \geq 1$ si existen conjuntos medibles, no vacíos y disjuntos $A_1, A_2, \dots, A_d$ tales que:

1. Para todo $x \in A_k$, se cumple $p(x, A_{k+1}) = 1$ para $k = 1, \dots, d-1$.
2. Para todo $x \in A_d$, se cumple $p(x, A_1) = 1$.
3. $\pi \left(\left(\bigcup_{i=1}^d A_i \right)^c \right) = 0$, es decir, la unión de los conjuntos cubre casi todo el espacio según π .

Esto significa que la cadena se mueve cíclicamente a través de los conjuntos $A_1 \rightarrow A_2 \rightarrow \dots \rightarrow A_d \rightarrow A_1$ con probabilidad 1. El *periodo* de la cadena es el entero d más grande para el cual existe tal ciclo. Si $d = 1$, la cadena se denomina *aperiódica*. La aperiocidad es una condición necesaria para que la cadena converja a la distribución estacionaria sin oscilaciones.

Recurrencia. La recurrencia mide la frecuencia con la que la cadena regresa a una región determinada. Para una cadena π -irreducible, se dice que es *recurrente* si para todo conjunto medible A con $\pi(A) > 0$ y para todo estado inicial $x_0 \in S$, se tiene que

$$\mathbb{P}(X_n \in A \text{ para infinitos } n \mid X_0 = x_0) > 0.$$

Es decir, existe una probabilidad positiva de visitar A infinitas veces. Una propiedad más fuerte es la *recurrencia de Harris*, que exige que

$$\mathbb{P}(X_n \in A \text{ para infinitos } n \mid X_0 = x_0) = 1,$$

para todo x_0 y todo A con $\pi(A) > 0$. En una cadena recurrente de Harris, la cadena regresa a cualquier conjunto de probabilidad positiva con probabilidad 1, lo que garantiza un comportamiento ergódico muy fuerte.

Estas tres propiedades (irreducibilidad, aperiocidad y recurrencia de Harris) son las que suelen exigirse para demostrar la convergencia de la cadena a su distribución estacionaria y la validez de los estimadores MCMC.

6.1.3. Distribuciones estacionarias, distribuciones límite y reversibilidad

Si $\pi_0(x)$ es una distribución de probabilidad sobre el espacio de estados S de una cadena de Markov en un tiempo dado, entonces la distribución en la siguiente unidad de tiempo es

$$\pi_1(y) = \int_S \pi_0(x)p(x, y) dx, \quad y \in S.$$

Cuando una distribución permanece sin cambio bajo esta transformación, se dice que es *estacionaria* o *invariante en el tiempo*. Formalmente, una distribución de probabilidad $\pi(x)$ definida sobre S es una distribución estacionaria para la cadena con kernel $p(x, y)$ si

$$\pi(y) = \int_S \pi(x)p(x, y) dx, \quad y \in S.$$

Si la cadena es π -irreducible, entonces $\pi(x)$ es la *única* distribución estacionaria de la cadena. Esta unicidad es fundamental, ya que garantiza que no existen múltiples distribuciones invariantes que puedan confundir el análisis.

Por otro lado, la *distribución límite* se define como el límite de la función de transición en n pasos:

$$\pi(y) = \lim_{n \rightarrow \infty} p^{(n)}(x, y), \quad y \in S,$$

siempre que el límite exista y no dependa del estado inicial x . Sin embargo, no siempre está garantizado que este límite sea una distribución de probabilidad válida; pueden existir límites que sean todos cero, por ejemplo.

El siguiente resultado establece condiciones suficientes para la existencia de la distribución límite y la convergencia en variación total. Sea $p(x, y)$ una cadena de Markov con espacio de estados continuo S tal que:

1. Posee una distribución estacionaria $\pi(x)$.
2. Es irreducible respecto de $\pi(x)$.
3. Es aperiódica.

Entonces:

1. Para casi cualquier $x \in S$ según la medida π , se cumple que

$$\lim_{n \rightarrow \infty} \|p^{(n)}(x, \cdot) - \pi(\cdot)\|_{TV} = 0,$$

donde $\|\cdot\|_{TV}$ es la norma de variación total entre dos medidas de probabilidad, definida como

$$\|\pi_1 - \pi_2\|_{TV} = \sup_A |\pi_1(A) - \pi_2(A)|.$$

2. Si $p(x, y)$ es una cadena recurrente de Harris, entonces la convergencia se verifica para cualquier $x \in S$.

Finalmente, una propiedad de gran importancia práctica es la *reversibilidad*. Se dice que una cadena de Markov con kernel $p(x, y)$ es *reversible* respecto de una distribución $\pi(x)$ si se cumple la *ecuación de balance detallado*:

$$\pi(x)p(x, y) = \pi(y)p(y, x), \quad x, y \in S.$$

Esta condición es más fuerte que la estacionariedad: si una distribución π satisface la ecuación de balance detallado, entonces es estacionaria. En efecto,

$$\int_S \pi(x)p(x, y) dx = \int_S \pi(y)p(y, x) dx = \pi(y) \int_S p(y, x) dx = \pi(y),$$

donde la última igualdad se debe a que $\int_S p(y, x) dx = 1$ para todo y . La reversibilidad es la base de muchos algoritmos MCMC, como el muestreador de Metropolis-Hastings, porque facilita la construcción de cadenas con una distribución estacionaria deseada.

Ejemplo 6.3. Consideremos el paseo aleatorio gaussiano en $\mathbb{R}$ con kernel

$$p(x, y) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y-x)^2}{2\sigma^2}\right).$$

Este kernel es simétrico, es decir, $p(x, y) = p(y, x)$. Por lo tanto, la distribución uniforme (si el espacio fuera compacto) o la distribución normal estándar (si el espacio es $\mathbb{R}$ y la cadena tiene deriva) pueden ser estacionarias. En particular, si tomamos $\pi(x)$ como la densidad normal con media 0 y varianza σ^2 , se puede comprobar que satisface la ecuación de balance detallado:

$$\pi(x)p(x, y) = \pi(y)p(y, x),$$

por lo que π es la distribución estacionaria de la cadena. Este ejemplo muestra cómo la simetría del kernel y una elección adecuada de π permiten verificar la reversibilidad de forma sencilla.

6.2. Algoritmo de Metropolis-Hastings

El algoritmo de Metropolis-Hastings es uno de los métodos MCMC más utilizados para generar muestras de distribuciones complejas, especialmente cuando no es posible muestrear directamente de ellas. La idea es construir una cadena de Markov con espacio de estados continuo S cuya distribución estacionaria sea precisamente la densidad objetivo $f(x)$, que supondremos conocida salvo una constante de normalización (es decir, solo conocemos su kernel $f_{\text{ker}}(x)$). De esta manera, tras un periodo de quemado (*burn-in*), los valores generados por la cadena se distribuirán aproximadamente según f .

Para ello, se necesita una *densidad de propuesta* o *kernel de transición propuesto* $q(x, y)$, definida sobre $S \times S$, donde x es el estado actual y y el estado propuesto. Se supone que, para cada x fijo, sabemos simular valores de la densidad $y \mapsto q(x, y)$.

La construcción de la cadena de Markov $\{X_t : t = 0, 1, 2, \dots\}$ es la siguiente:

1. Fijar un estado inicial $X_0 = x_0 \in S$.
2. Para $t = 1, 2, \dots$:
 - a) Generar un valor Y de la distribución propuesta $y \mapsto q(X_{t-1}, y)$.
 - b) Calcular la probabilidad de aceptación

$$\alpha(X_{t-1}, Y) = \min \left\{ 1, \frac{f(Y)}{f(X_{t-1})} \cdot \frac{q(Y, X_{t-1})}{q(X_{t-1}, Y)} \right\}.$$

- c) Definir

$$X_t = \begin{cases} Y, & \text{con probabilidad } \alpha(X_{t-1}, Y), \\ X_{t-1}, & \text{con probabilidad } 1 - \alpha(X_{t-1}, Y). \end{cases}$$

En la práctica, puede ser numéricamente más estable trabajar en escala logarítmica al calcular la probabilidad de aceptación. En lugar de comparar directamente con α , se puede utilizar el siguiente criterio equivalente:

$$\log(U) \leq \min \{0, \log f(Y) + \log q(Y, X_{t-1}) - \log f(X_{t-1}) - \log q(X_{t-1}, Y)\}.$$

El uso de logaritmos evita problemas de desbordamiento numérico y mejora la estabilidad computacional, especialmente cuando se trabajan con densidades muy pequeñas.

El proceso $\{X_t\}$ así construido es una cadena de Markov con función de densidad de transición

$$p(x, y) = q(x, y) \alpha(x, y) + r(x) \delta_x(y),$$

donde $\delta_x(y)$ es la delta de Dirac y

$$r(x) = 1 - \int_S q(x, s) \alpha(x, s) ds$$

es la probabilidad de rechazo. Es inmediato comprobar que $p(x, y)$ es una densidad en y , ya que

$$\int_S p(x, y) dy = \int_S q(x, y) \alpha(x, y) dy + r(x) = 1.$$

La propiedad clave del algoritmo es que la densidad objetivo $f(x)$ es una distribución estacionaria de la cadena. Esto se verifica mediante la *ecuación de balance detallado*:

$$f(x) p(x, y) = f(y) p(y, x), \quad \forall x, y \in S.$$

En efecto, para $x \neq y$,

$$f(x) p(x, y) = f(x) q(x, y) \alpha(x, y) = f(x) q(x, y) \min \left\{ 1, \frac{f(y) q(y, x)}{f(x) q(x, y)} \right\} = \min \{f(y) q(y, x), f(x) q(x, y)\}.$$

Por simetría, el mismo resultado se obtiene para $f(y) p(y, x)$, lo que demuestra la igualdad. Integrando la ecuación de balance,

$$\int_S f(x) p(x, y) dx = \int_S f(y) p(y, x) dx = f(y) \int_S p(y, x) dx = f(y),$$

por lo que f es efectivamente una distribución estacionaria.

Elección del kernel de propuesta El desempeño del algoritmo depende críticamente de la elección de $q(x, y)$. A continuación se presentan algunas opciones comunes.

Kernel simétrico. Si $q(x, y) = q(y, x)$, la probabilidad de aceptación se simplifica a

$$\alpha(x, y) = \min \left\{ 1, \frac{f(y)}{f(x)} \right\}.$$

Este es el caso del *algoritmo de Metropolis* original.

Ejemplo 6.4 (Estimación del precio de una opción call mediante Metropolis-Hastings). *El precio de una opción call europea bajo el modelo de Black-Scholes se puede expresar como*

$$C = e^{-rT} \mathbb{E} [\max(S_T - K, 0)],$$

donde el precio del activo en el tiempo T es

$$S_T = S_0 \exp \left((r - \frac{1}{2}\sigma^2)T + \sigma\sqrt{T} Z \right),$$

con $Z \sim \mathcal{N}(0, 1)$. Por lo tanto,

$$C = e^{-rT} \int \text{payoff}(z) \phi(z) dz,$$

donde $\phi(z)$ es la densidad de la normal estándar.

Para reducir la varianza del estimador, se introduce la distribución de mínima varianza:

$$\pi(z) = \frac{\text{payoff}(z) \phi(z)}{c},$$

donde $c = \int \text{payoff}(z) \phi(z) dz$. En el caso de la opción call, esta constante puede calcularse explícitamente como

$$c = \sqrt{2\pi} \left[S_0 e^{rT} \Phi(\theta - \sigma\sqrt{T}) - K \Phi(\theta) \right],$$

donde Φ es la función de distribución de la normal estándar y

$$\theta = \frac{\log(K/S_0) - (r - \frac{1}{2}\sigma^2)T}{\sigma\sqrt{T}}.$$

Sin embargo, no es posible muestrear directamente de π , por lo que se utiliza el algoritmo de Metropolis-Hastings. Se construye una cadena de Markov $\{Z_n\}$ cuya distribución estacionaria es $\pi(z)$. Utilizamos un kernel de propuesta de caminata aleatoria:

$$Y = X + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma_q^2).$$

La probabilidad de aceptación es

$$\alpha(x, y) = \min \left\{ 1, \frac{\pi(y)}{\pi(x)} \right\}.$$

Dado que $\pi(z) \propto \text{payoff}(z) \phi(z)$, se obtiene

$$\alpha(x, y) = \min \left\{ 1, \frac{\text{payoff}(y) \phi(y)}{\text{payoff}(x) \phi(x)} \right\}.$$

En la práctica, se trabaja en escala logarítmica:

$$\log \alpha = \log \text{payoff}(y) + \log \phi(y) - \log \text{payoff}(x) - \log \phi(x).$$

Una vez generadas las muestras $\{Z_i\}_{i=1}^m$ de la cadena (después del periodo de burn-in), se estima el precio mediante el estimador de importancia

$$\hat{C} = e^{-rT} \frac{1}{m} \sum_{i=1}^m \frac{\text{payoff}(Z_i) \phi(Z_i)}{\pi(Z_i)},$$

Nótese que este es un ejemplo de integración de MCMC con muestreo por importancia: la cadena de Metropolis-Hastings proporciona muestras de π , que luego se usan para estimar la integral de interés.

Kernel independiente. En este caso, la propuesta no depende del estado actual: $q(x, y) = q(y)$. La probabilidad de aceptación se reduce a

$$\alpha(x, y) = \min \left\{ 1, \frac{f(y)}{f(x)} \cdot \frac{q(x)}{q(y)} \right\}.$$

Este tipo de kernel es útil cuando se conoce una distribución que aproxima bien a la objetivo y de la cual es fácil simular. Sin embargo, si la propuesta no cubre bien toda la región de soporte de f , la cadena puede tener problemas de exploración. Un ejemplo de este tipo se presenta a continuación al muestrear una distribución gama utilizando una propuesta exponencial.

Ejemplo 6.5 (Muestreo de una distribución gama). Supongamos que deseamos obtener valores de la distribución gama con parámetros $\alpha > 0$ y $\beta > 0$. La función de densidad objetivo es

$$f(x) = \frac{\beta^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\beta x}, \quad x > 0.$$

El espacio de estados es $S = (0, \infty)$. Como función propuesta, tomamos una distribución exponencial con parámetro β :

$$q(y) = \beta e^{-\beta y}, \quad y > 0,$$

que no depende del estado actual x (es decir, $q(x, y) = q(y)$). Esto es un caso particular de propuesta independiente. Los valores de q se pueden generar mediante el método de la transformada inversa: $y = -\frac{1}{\beta} \log u$, con $u \sim \text{Unif}(0, 1)$.

La probabilidad de aceptación es

$$\alpha(x, y) = \min \left\{ 1, \frac{f(y)}{f(x)} \cdot \frac{q(x)}{q(y)} \right\}.$$

Calculando el cociente,

$$\frac{f(y)}{f(x)} \cdot \frac{q(x)}{q(y)} = \frac{y^{\alpha-1}e^{-\beta y}}{x^{\alpha-1}e^{-\beta x}} \cdot \frac{\beta e^{-\beta x}}{\beta e^{-\beta y}} = \left(\frac{y}{x}\right)^{\alpha-1}.$$

Por lo tanto,

$$\alpha(x, y) = \min \left\{ 1, \left(\frac{y}{x}\right)^{\alpha-1} \right\}.$$

El algoritmo procede como sigue: se toma un valor inicial $x_0 > 0$. Para $t = 1, 2, \dots$, se genera $y \sim \text{Exp}(\beta)$ y se acepta con probabilidad $\alpha(x_{t-1}, y)$; en caso contrario, se mantiene x_{t-1} . Tras un periodo de quemado, la cadena produce valores que se distribuyen aproximadamente como una $\text{Gamma}(\alpha, \beta)$.

Caminata aleatoria. Un caso particular muy usado es cuando la propuesta depende solo de la diferencia $y - x$, es decir, $q(x, y) = q(y - x)$. Ejemplos típicos son

$$q(x, \cdot) = \mathcal{N}(x, \sigma^2), \quad q(x, \cdot) = \text{Uniforme}(x - \delta, x + \delta).$$

Este enfoque es sencillo de implementar y funciona bien en muchas aplicaciones, aunque la elección de la escala (como σ^2 o δ) es crucial para obtener una tasa de aceptación razonable.

Algoritmo de Langevin. Para mejorar la exploración en dimensiones altas, se puede usar el *algoritmo de Langevin*, que incorpora información del gradiente de $\log f$. Para un paso $\delta > 0$ pequeño, se propone

$$Y \sim \mathcal{N} \left(X + \frac{\delta}{2} \nabla \log f(X), \delta I \right).$$

Esta propuesta guía los movimientos hacia regiones de mayor densidad, lo que puede aumentar la eficiencia, aunque requiere calcular el gradiente de f .

6.2.1. Regresión lineal bayesiana con Metropolis-Hastings

Consideremos el modelo de regresión lineal bayesiana con datos $y \in \mathbb{R}^n$ y matriz de diseño $X \in \mathbb{R}^{n \times d}$. Se supone que

$$y \mid X, \beta, \sigma^2 \sim \mathcal{N}(X\beta, \sigma^2 I_n),$$

con prioris

$$\beta \sim \mathcal{N}(0, \tau^2 I_d), \quad \sigma^2 \sim \text{Inverse-Gamma}(a, b).$$

La densidad de la inversa-gamma es

$$p(\sigma^2) = \frac{b^a}{\Gamma(a)} (\sigma^2)^{-(a+1)} \exp \left(-\frac{b}{\sigma^2} \right), \quad \sigma^2 > 0.$$

El logaritmo de la posterior (salvo constantes) es

$$\log p(\beta, \sigma^2 \mid y, X) \propto \log p(y \mid X, \beta, \sigma^2) + \log p(\beta) + \log p(\sigma^2),$$

donde

$$\begin{aligned}\log p(y \mid X, \beta, \sigma^2) &= -\frac{n}{2} \log \sigma^2 - \frac{1}{2\sigma^2} \|y - X\beta\|^2, \\ \log p(\beta) &= -\frac{1}{2\tau^2} \|\beta\|^2,\end{aligned}$$

y

$$\log p(\sigma^2) = -(a+1) \log \sigma^2 - \frac{b}{\sigma^2}.$$

Dado que $\sigma^2 > 0$ y el kernel de propuesta normal tiene soporte en todo $\mathbb{R}$, es necesario transformar el parámetro. Definimos

$$\eta = \log(\sigma^2),$$

de modo que $\eta \in \mathbb{R}$. Aplicando la fórmula de cambio de variable, la densidad inducida sobre η satisface

$$p(\eta) = p(\sigma^2) \left| \frac{d\sigma^2}{d\eta} \right| = p(\sigma^2) e^\eta,$$

por lo que

$$\log p(\eta) = \log p(\sigma^2) + \eta.$$

Por tanto, la log-posterior en términos de (β, η) es

$$\log p(\beta, \eta \mid y) = -\left(\frac{n}{2} + a\right) \eta - \frac{1}{2e^\eta} \|y - X\beta\|^2 - \frac{b}{e^\eta} - \frac{1}{2\tau^2} \|\beta\|^2.$$

El algoritmo de Metropolis-Hastings para muestrear de la posterior $p(\beta, \eta \mid y)$ procede como sigue:

1. Inicializar $\beta^{(0)}$ y $\eta^{(0)}$.
2. Para $t = 1, \dots, T$:

a) Generar propuestas mediante paseo aleatorio gaussiano:

$$\begin{aligned}\beta' &= \beta^{(t-1)} + \varepsilon_\beta, & \varepsilon_\beta &\sim \mathcal{N}(0, s^2 I_d), \\ \eta' &= \eta^{(t-1)} + \varepsilon_\eta, & \varepsilon_\eta &\sim \mathcal{N}(0, s^2).\end{aligned}$$

b) Calcular la razón de aceptación en escala logarítmica:

$$\log \alpha = \log p(\beta', \eta' \mid y) - \log p(\beta^{(t-1)}, \eta^{(t-1)} \mid y).$$

La probabilidad de aceptación es $\alpha = \min(1, e^{\log \alpha})$.

c) Generar $u \sim \text{Unif}(0, 1)$. Aceptar la propuesta si $\log u \leq \log \alpha$; en caso contrario, rechazar.

d) Actualizar:

$$(\beta^{(t)}, \eta^{(t)}) = \begin{cases} (\beta', \eta'), & \text{si se acepta,} \\ (\beta^{(t-1)}, \eta^{(t-1)}), & \text{en otro caso.} \end{cases}$$

Tras un periodo de quemado, las muestras generadas $\{(\beta^{(t)}, \eta^{(t)})\}$ se distribuyen aproximadamente según la posterior $p(\beta, \eta \mid y)$. A partir de ellas, se pueden obtener estimaciones puntuales (como la media posterior) o intervalos de credibilidad para los coeficientes de regresión y la varianza. Este ejemplo muestra cómo el algoritmo Metropolis-Hastings puede adaptarse a problemas de inferencia bayesiana, incluso cuando los parámetros tienen soporte restringido, mediante transformaciones adecuadas.

6.3. Muestreo de Gibbs

El muestreo de Gibbs es un algoritmo MCMC particularmente útil cuando la distribución objetivo $\pi(x)$ es multidimensional y difícil de muestrear directamente, pero las distribuciones condicionales completas $p(x_i | x_{-i})$ son fáciles de simular. Aquí, x_{-i} denota todas las coordenadas excepto la i -ésima.

Una de las propiedades más importantes del muestreo de Gibbs es que es un caso especial del algoritmo de Metropolis-Hastings en el que la probabilidad de aceptación es siempre 1. Por lo tanto, todas las propuestas son aceptadas, lo que elimina la necesidad de calcular razones de aceptación y hace que el algoritmo sea muy eficiente cuando las condicionales son tratables.

Sea $x = (x_1, \dots, x_d) \in S \subseteq \mathbb{R}^d$ el vector de parámetros. Definimos

$$x_{-i} = (x_1, \dots, x_{i-1}, x_{i+1}, \dots, x_d),$$

es decir, el vector x sin la i -ésima coordenada. La distribución condicional completa de x_i dado el resto es

$$p(x_i | x_{-i}) = \frac{\pi(x)}{\int \pi(x) dx_i}.$$

El algoritmo de Gibbs se basa en actualizar secuencialmente cada coordenada muestreando de estas distribuciones condicionales.

El muestreo de Gibbs produce una cadena de Markov cuya distribución estacionaria es $\pi(x)$. Esto se verifica fácilmente observando que el kernel de transición satisface la ecuación de balance detallado cuando se consideran actualizaciones de una sola coordenada.

Una ventaja importante del Gibbs sampling es que no requiere ajustar parámetros de escala (como la varianza de la propuesta en Metropolis-Hastings), ya que todas las propuestas se aceptan. Sin embargo, su eficiencia depende críticamente de la estructura de dependencia entre las coordenadas: si las variables están fuertemente correlacionadas, la cadena puede mezclarse muy lentamente, recorriendo el espacio de forma errática.

En la práctica, el Gibbs sampling es ampliamente utilizado en inferencia bayesiana, especialmente en modelos jerárquicos y en problemas donde las distribuciones condicionales completas tienen formas conocidas (por ejemplo, distribuciones normales, gamma o beta). Cuando alguna condicional no es fácil de muestrear, se puede combinar con un paso de Metropolis-Hastings dentro de Gibbs (algoritmo de Metropolis-within-Gibbs).

6.3.1. Esquema secuencial (Gibbs Secuencial)

En el esquema secuencial, las coordenadas se actualizan en un orden fijo y determinista en cada iteración. El algoritmo es el siguiente:

1. Inicializar $x^{(0)} = (x_1^{(0)}, \dots, x_d^{(0)})$.
2. Para $t = 1, 2, \dots, T$:

a) Para $i = 1, 2, \dots, d$:

$$x_i^{(t)} \sim p\left(x_i \mid x_1^{(t)}, \dots, x_{i-1}^{(t)}, x_{i+1}^{(t-1)}, \dots, x_d^{(t-1)}\right).$$

Es decir, se actualiza x_i utilizando los valores más recientes de las otras coordenadas (las anteriores ya actualizadas en esta iteración y las posteriores aún con el valor de la iteración anterior).

Este esquema es sencillo de implementar y, bajo condiciones de regularidad (irreducibilidad y aperiocidad de la cadena), garantiza que la distribución de $x^{(t)}$ converja a $\pi(x)$ cuando $t \rightarrow \infty$.

6.3.2. Esquema aleatorio (Gibbs Random Scan)

En el esquema random scan, en cada iteración se selecciona una coordenada al azar y se actualiza, manteniendo las demás fijas. Este enfoque puede ser útil cuando algunas coordenadas se mezclan más lentamente que otras, ya que permite actualizar más frecuentemente las coordenadas "problemáticas".

1. Inicializar $x^{(0)}$.
2. Para $t = 1, 2, \dots, T$:
 - a) Elegir un índice $i_t \sim \text{Uniforme}\{1, \dots, d\}$.
 - b) Actualizar la coordenada seleccionada:

$$x_{i_t}^{(t)} \sim p\left(x_{i_t} \mid x_{-i_t}^{(t-1)}\right),$$

mientras que para $j \neq i_t$, se mantiene $x_j^{(t)} = x_j^{(t-1)}$.

El random scan tiene la ventaja de que la cadena resultante es reversible con respecto a π , lo que facilita el análisis teórico de convergencia en algunos casos.

6.3.3. Restauración de imágenes mediante Gibbs sampling

La restauración de imágenes es un problema clásico en visión por computadora y procesamiento de señales. Consiste en recuperar una imagen original a partir de una versión ruidosa, aprovechando la estructura espacial de los píxeles. Este problema se presta de manera natural a un enfoque bayesiano, donde la imagen original se modela como una realización de un campo aleatorio de Markov (MRF) y el ruido se describe mediante una distribución de probabilidad. El muestreo de Gibbs resulta especialmente adecuado para este problema, ya que las distribuciones condicionales completas son fáciles de calcular y muestrear.

Planteamiento del modelo. Sea $\theta = (\theta_{i,j})$ una matriz de tamaño $n \times m$ con valores en $\{-1, 1\}$, que representa la imagen original (binaria). Observamos una versión ruidosa

$$X_{i,j} = \theta_{i,j} + \varepsilon_{i,j},$$

donde $\varepsilon_{i,j}$ son variables aleatorias independientes con media cero. En este ejemplo, supondremos que el ruido es gaussiano blanco: $\varepsilon_{i,j} \sim \mathcal{N}(0, \sigma^2)$.

El objetivo es obtener muestras de la distribución posterior $p(\theta \mid X)$, es decir, la distribución de la imagen original condicionada a la imagen observada. Esta distribución no es directamente manejable, pero podemos construir un muestreador de Gibbs para generar muestras de ella.

Modelo a priori (campo de Markov). Para modelar la dependencia espacial entre píxeles, se utiliza un campo aleatorio de Markov con parámetro $\lambda > 0$. La distribución condicional de un píxel dado el resto está dada por

$$P(\theta_{i,j} \mid \theta_{-(i,j)}) \propto \exp(\lambda \theta_{i,j} \Sigma_{i,j}),$$

donde $\Sigma_{i,j}$ es la suma de los cuatro vecinos (arriba, abajo, izquierda, derecha):

$$\Sigma_{i,j} = \theta_{i-1,j} + \theta_{i+1,j} + \theta_{i,j-1} + \theta_{i,j+1}.$$

Se adopta la convención de que los píxeles fuera de la imagen son cero: $\theta_{0,j} = \theta_{i,0} = \theta_{n+1,j} = \theta_{i,m+1} = 0$. Este prior favorece configuraciones donde los píxeles vecinos tienden a ser iguales, promoviendo la suavidad de la imagen.

Verosimilitud (ruido gaussiano). Dado que $\varepsilon_{i,j} \sim \mathcal{N}(0, \sigma^2)$, la verosimilitud es

$$p(X \mid \theta) \propto \exp\left(-\frac{1}{2\sigma^2} \sum_{i,j} (X_{i,j} - \theta_{i,j})^2\right).$$

Por el teorema de Bayes, la posterior es proporcional al producto de la verosimilitud y la priori:

$$p(\theta \mid X) \propto p(X \mid \theta) p(\theta).$$

Distribuciones condicionales completas. La clave del muestreo de Gibbs es obtener la distribución de cada píxel condicionada al resto de la imagen y a los datos observados. Para el píxel (i, j) , se tiene

$$p(\theta_{i,j} \mid \theta_{-(i,j)}, X) \propto \exp\left(\theta_{i,j} \left[\lambda \Sigma_{i,j} + \frac{X_{i,j}}{\sigma^2}\right]\right),$$

donde $\theta_{-(i,j)}$ denota todos los píxeles excepto el (i, j) . Esta expresión se obtiene combinando el término de la verosimilitud que involucra a $\theta_{i,j}$ (que es $-\frac{1}{2\sigma^2}(\theta_{i,j} - X_{i,j})^2$) con el término del prior (que es $\lambda \theta_{i,j} \Sigma_{i,j}$).

Dado que $\theta_{i,j}$ solo puede tomar los valores $+1$ o -1 , la probabilidad de que sea 1 es

$$\mathbb{P}(\theta_{i,j} = 1 \mid \theta_{-(i,j)}, X) = \frac{\exp\left(\lambda \Sigma_{i,j} + \frac{X_{i,j}}{\sigma^2}\right)}{\exp\left(\lambda \Sigma_{i,j} + \frac{X_{i,j}}{\sigma^2}\right) + \exp\left(-\lambda \Sigma_{i,j} - \frac{X_{i,j}}{\sigma^2}\right)} = g\left(2 \left[\lambda \Sigma_{i,j} + \frac{X_{i,j}}{\sigma^2}\right]\right),$$

donde $g(x) = \frac{1}{1+e^{-x}}$ es la función sigmoide. Esta es una distribución de Bernoulli con probabilidad $p_{i,j}$.

Algoritmo de Gibbs. El muestreador de Gibbs procede actualizando cada píxel secuencialmente, utilizando su distribución condicional completa:

1. Inicializar $\theta^{(0)}$ (por ejemplo, con valores aleatorios o con la imagen observada X umbralizada).
2. Para $t = 1, 2, \dots, T$ (número de iteraciones):
 - a) Para cada píxel (i, j) (en orden raster o aleatorio):

- Calcular la suma de vecinos utilizando los valores más recientes (los ya actualizados en esta iteración para los píxeles anteriores):

$$\Sigma_{i,j}^{(t)} = \theta_{i-1,j}^{(t)} + \theta_{i+1,j}^{(t-1)} + \theta_{i,j-1}^{(t)} + \theta_{i,j+1}^{(t-1)}.$$

(Nótese que en un barrido secuencial, algunos vecinos ya se han actualizado y otros no).

- Calcular la probabilidad:

$$p_{i,j} = g\left(2\left[\lambda\Sigma_{i,j}^{(t)} + \frac{X_{i,j}}{\sigma^2}\right]\right).$$

- Actualizar el píxel:

$$\theta_{i,j}^{(t)} = \begin{cases} 1, & \text{con probabilidad } p_{i,j}, \\ -1, & \text{en otro caso.} \end{cases}$$

Tras un número suficiente de iteraciones (período de quemado), las configuraciones $\theta^{(t)}$ generadas por la cadena se distribuyen aproximadamente según la posterior $p(\theta \mid X)$. Se puede entonces promediar varias de estas configuraciones (por ejemplo, la media de los valores de cada píxel) para obtener una imagen restaurada, o calcular la moda de la posterior (estimación MAP) a partir de las muestras.

Este ejemplo ilustra cómo el muestreo de Gibbs permite resolver un problema de inferencia en alta dimensión (miles de píxeles) mediante actualizaciones locales sencillas, aprovechando la estructura de Markov del modelo. Es una de las aplicaciones más clásicas y didácticas del MCMC en procesamiento de imágenes.

6.3.4. Regresión lineal bayesiana con Gibbs sampling

La regresión lineal bayesiana es uno de los ejemplos más clásicos y didácticos de aplicación del muestreo de Gibbs. En este modelo, las distribuciones condicionales completas de los parámetros tienen formas conocidas (normal e inversa-gamma), lo que permite implementar un muestreador de Gibbs puro, sin necesidad de pasos de Metropolis-Hastings.

Modelo y prioris. Sean $y \in \mathbb{R}^n$ el vector de respuestas y $X \in \mathbb{R}^{n \times d}$ la matriz de diseño. El modelo de regresión lineal supone

$$y \mid X, \beta, \sigma^2 \sim \mathcal{N}(X\beta, \sigma^2 I_n),$$

es decir,

$$p(y \mid X, \beta, \sigma^2) = (2\pi\sigma^2)^{-n/2} \exp\left(-\frac{1}{2\sigma^2}\|y - X\beta\|^2\right).$$

Se consideran las siguientes distribuciones a priori:

$$\beta \sim \mathcal{N}(0, \tau^2 I_d), \quad \sigma^2 \sim \text{Inv-Gamma}(a, b),$$

donde $a > 0$, $b > 0$ y $\tau > 0$ son hiperparámetros conocidos. La densidad de la inversa-gamma es

$$p(\sigma^2) = \frac{b^a}{\Gamma(a)} (\sigma^2)^{-(a+1)} \exp\left(-\frac{b}{\sigma^2}\right), \quad \sigma^2 > 0.$$

Distribución condicional de β . Dado σ^2 y los datos, la posterior condicional de β es

$$\beta \mid \sigma^2, y \sim \mathcal{N}(\mu_n, \Sigma_n),$$

donde

$$\Sigma_n = \left(\frac{1}{\sigma^2} X^\top X + \frac{1}{\tau^2} I_d \right)^{-1}, \quad \mu_n = \Sigma_n \left(\frac{1}{\sigma^2} X^\top y \right).$$

Esta expresión se obtiene completando el cuadrado en el exponente de la verosimilitud combinada con el prior normal de β . Es la versión bayesiana del estimador de mínimos cuadrados regularizado (ridge regression).

Distribución condicional de σ^2 . Dado β y los datos, la posterior condicional de σ^2 es

$$\sigma^2 \mid \beta, y \sim \text{Inv-Gamma}(a_n, b_n),$$

con

$$a_n = a + \frac{n}{2}, \quad b_n = b + \frac{1}{2}\|y - X\beta\|^2.$$

Esto se deriva directamente de combinar la verosimilitud normal con el prior inversa-gamma, que es conjugado para la varianza en el modelo normal.

Algoritmo de Gibbs. El muestreador de Gibbs para este modelo procede iterando entre las dos condicionales completas:

1. Inicializar $(\beta^{(0)}, \sigma^{2(0)})$.
2. Para $t = 1, 2, \dots, T$:

a) Muestrear $\beta^{(t)}$ de la normal condicional:

$$\beta^{(t)} \sim \mathcal{N}(\mu_n^{(t-1)}, \Sigma_n^{(t-1)}),$$

donde

$$\Sigma_n^{(t-1)} = \left(\frac{1}{\sigma^{2(t-1)}} X^\top X + \frac{1}{\tau^2} I_d \right)^{-1},$$

$$\mu_n^{(t-1)} = \Sigma_n^{(t-1)} \left(\frac{1}{\sigma^{2(t-1)}} X^\top y \right).$$

b) Muestrear $\sigma^{2(t)}$ de la inversa-gamma condicional:

$$\sigma^{2(t)} \sim \text{Inv-Gamma} \left(a + \frac{n}{2}, b + \frac{1}{2} \|y - X\beta^{(t)}\|^2 \right).$$

Tras un periodo de quemado, las muestras $\{(\beta^{(t)}, \sigma^{2(t)})\}$ se distribuyen aproximadamente según la posterior conjunta $p(\beta, \sigma^2 | y)$. A partir de ellas, se pueden obtener estimaciones puntuales (como la media posterior de β , que es el estimador bayesiano bajo pérdida cuadrática), intervalos de credibilidad para los coeficientes, o predicciones para nuevas observaciones.

La implementación de este algoritmo es sencilla, ya que solo requiere generar muestras de distribuciones normal multivariada e inversa-gamma, disponibles en la mayoría de los lenguajes de programación estadísticos. La elección de los hiperparámetros a , b y τ puede influir en los resultados. Si no se tiene información previa, se pueden usar priors poco informativos (por ejemplo, a y b pequeños, y τ grande).

6.4. Monte Carlo Hamiltoniano (HMC)

El Monte Carlo Hamiltoniano es un método avanzado de MCMC que mejora significativamente el muestreo en problemas de alta dimensión, reduciendo la correlación entre las muestras y explorando el espacio de estados de manera más eficiente que los algoritmos de Metropolis-Hastings estándar o el muestreo de Gibbs. Está inspirado en la dinámica de una partícula que se mueve en un campo de fuerzas, y utiliza las ecuaciones de Hamilton para generar propuestas que son aceptadas con alta probabilidad.

Espacio fase y Hamiltoniano. Supongamos que queremos muestrear de una distribución objetivo $p(\theta)$, donde $\theta \in \mathbb{R}^d$ representa la posición de una partícula. Introducimos una variable auxiliar $v \in \mathbb{R}^d$, llamada *momento*, que tiene la misma dimensión que θ . El espacio de estados conjunto (θ, v) se denomina *espacio fase*.

Definimos el *Hamiltoniano* o energía total del sistema como

$$H(\theta, v) = E(\theta) + K(v),$$

donde:

- $E(\theta) = -\log p(\theta)$ es la *energía potencial* (que depende solo de la posición),

- $K(v) = \frac{1}{2}v^\top \Sigma^{-1}v$ es la *energía cinética*, con Σ una matriz definida positiva (típicamente la identidad o una estimación de la covarianza de p).

Entonces, la distribución conjunta en el espacio fase se define como

$$p(\theta, v) \propto \exp[-H(\theta, v)] = \exp\left(-E(\theta) - \frac{1}{2}v^\top \Sigma^{-1}v\right).$$

Integrando sobre v , se recupera la distribución objetivo:

$$\int p(\theta, v) dv \propto \int e^{-E(\theta)} e^{-\frac{1}{2}v^\top \Sigma^{-1}v} dv \propto e^{-E(\theta)} = p(\theta).$$

Es decir, la marginal de θ bajo $p(\theta, v)$ es exactamente la distribución que queremos muestrear.

Dinámica Hamiltoniana. El movimiento de la partícula en el espacio fase está gobernado por las *ecuaciones de Hamilton*:

$$\frac{d\theta}{dt} = \frac{\partial H}{\partial v} = \frac{\partial K}{\partial v} = \Sigma^{-1}v, \quad \frac{dv}{dt} = -\frac{\partial H}{\partial \theta} = -\frac{\partial E}{\partial \theta} = \nabla \log p(\theta).$$

Estas ecuaciones describen una trayectoria determinista que conserva la energía $H(\theta, v)$ y es reversible en el tiempo. Si pudiéramos resolverlas exactamente, podríamos generar propuestas que se mueven a lo largo de curvas de energía constante, con probabilidad de aceptación 1. Sin embargo, en la práctica no podemos resolverlas analíticamente, por lo que debemos recurrir a una aproximación numérica.

Integrador Leapfrog. Para aproximar la dinámica Hamiltoniana, se utiliza el *integrador leapfrog*, que es un método de diferencias finitas que preserva la energía mucho mejor que otros esquemas (como Euler). Dado un tamaño de paso $\eta > 0$, el integrador leapfrog realiza los siguientes pasos:

$$\begin{aligned} v_{t+\frac{1}{2}} &= v_t - \frac{\eta}{2} \nabla E(\theta_t), \\ \theta_{t+1} &= \theta_t + \eta \Sigma^{-1} v_{t+\frac{1}{2}}, \\ v_{t+1} &= v_{t+\frac{1}{2}} - \frac{\eta}{2} \nabla E(\theta_{t+1}). \end{aligned}$$

Este esquema es reversible y simétrico, lo que lo hace adecuado para su uso en un algoritmo MCMC.

Algoritmo HMC. El algoritmo de Monte Carlo Hamiltoniano procede de la siguiente manera:

1. Fijar un estado inicial θ_0 .
2. Para $t = 1, 2, \dots, T$:
 - a) Muestrear un nuevo momento $v_{t-1} \sim \mathcal{N}(0, \Sigma)$.
 - b) Inicializar $(\theta'_0, v'_0) = (\theta_{t-1}, v_{t-1})$.

- c) Aplicar L pasos del integrador leapfrog con tamaño de paso η para obtener (θ'_L, v'_L) .
- d) Proponer $(\theta^*, v^*) = (\theta'_L, v'_L)$.
- e) Calcular la probabilidad de aceptación:

$$\alpha = \min \left(1, \exp \left(- H(\theta^*, v^*) + H(\theta_{t-1}, v_{t-1}) \right) \right).$$

- f) Aceptar la propuesta $(\theta_t = \theta^*)$ con probabilidad α ; en caso contrario, mantener el estado anterior $(\theta_t = \theta_{t-1})$.

Es importante muestrear un nuevo momento v en cada iteración, ya que esto garantiza que la cadena sea ergódica y pueda explorar todo el espacio de estados. Si siempre usáramos el mismo momento, la cadena quedaría confinada a una región de energía constante.

Selección de hiperparámetros. El desempeño de HMC depende críticamente de tres hiperparámetros: el número de pasos leapfrog L , el tamaño de paso η y la matriz de covarianza Σ .

- **Número de pasos L :** Debe ser lo suficientemente grande para que la trayectoria explore la región de energía constante, pero no tanto como para que la trayectoria “regrese sobre sí misma”, lo que desperdiciaría cómputo. En la práctica, el muestreador No-U-Turn (NUTS) adapta L automáticamente.
- **Tamaño de paso η :** Una heurística común es fijar $\Sigma = I$ y $L = 1$, y ajustar η hasta que la tasa de aceptación esté entre el 40 % y el 80 %. Un η demasiado grande produce bajas tasas de aceptación; demasiado pequeño genera exploración lenta.
- **Matriz de covarianza Σ :** Si la distribución objetivo tiene correlaciones fuertes, usar $\Sigma = I$ puede ser ineficiente. Se puede estimar Σ durante un periodo de calentamiento:
 1. Ejecutar HMC con $\Sigma = I$ durante un periodo de quemado.
 2. Estimar la matriz de covarianza empírica de las muestras:

$$\Sigma = \mathbb{E} \left[(\theta - \bar{\theta})(\theta - \bar{\theta})^\top \right].$$
 3. Usar esta Σ estimada en las iteraciones posteriores.

El algoritmo HMC es especialmente eficaz en problemas de alta dimensión donde la distribución objetivo tiene estructura compleja, ya que utiliza la información del gradiente de $\log p(\theta)$ para guiar las propuestas, reduciendo drásticamente la correlación entre muestras y mejorando la convergencia.

7. Optimización estocástica

En esta sección abordaremos métodos iterativos que combinan ideas de optimización y simulación para resolver problemas de estimación en presencia de datos incompletos, variables latentes o modelos complejos. Estos métodos son fundamentales en estadística computacional y aprendizaje automático.

7.1. Algoritmo EM

El algoritmo EM es un procedimiento iterativo cuyo objetivo es encontrar el estimador máximo verosímil (EMV) de un parámetro desconocido θ en un modelo probabilístico. Es particularmente útil en situaciones donde existen datos incompletos o variables latentes, ya que en lugar de maximizar directamente la verosimilitud observada (que puede ser difícil o imposible), maximiza iterativamente una función auxiliar más sencilla.

Planteamiento del problema. Sea $f(x | \theta)$ una función de densidad (o masa) que depende de un parámetro desconocido $\theta \in \Theta$, y que deseamos estimar a partir de los datos. Supongamos que disponemos de dos conjuntos de datos: $x = (x_1, \dots, x_{n_1})$, los datos *observados* o completos. $z = (z_1, \dots, z_{n_2})$, los datos *incompletos* o faltantes, que no se conocen completamente.

El objetivo es maximizar la verosimilitud de los datos observados:

$$L(\theta | x) = f(x | \theta) = \int f(x, z | \theta) dz,$$

pero la integral (o suma) sobre los datos faltantes suele ser intratable. El algoritmo EM evita esta dificultad trabajando con la verosimilitud completa $L(\theta | x, z) = f(x, z | \theta)$, y alterna entre dos pasos:

1. **Paso E (Expectation):** Se calcula la esperanza condicional del logaritmo de la verosimilitud completa, dados los datos observados y una estimación actual del parámetro.
2. **Paso M (Maximization):** Se maximiza esta esperanza con respecto a θ , obteniendo una nueva estimación.

La función Q y el paso E. Sea $\hat{\theta}_0$ una estimación inicial para θ . Esta puede ser una propuesta arbitraria o basada en los datos completos. La función Q se define como la esperanza condicional del logaritmo de la verosimilitud completa:

$$Q(\theta | \hat{\theta}_0, x) = \mathbb{E} \left[\log L(\theta | x, z) \mid \hat{\theta}_0, x \right],$$

donde la esperanza se toma con respecto a la distribución condicional de los datos faltantes dados los observados y la estimación actual:

$$f(z | \hat{\theta}_0, x) = \frac{f(x, z | \hat{\theta}_0)}{f(x | \hat{\theta}_0)}.$$

En el paso E, se calcula explícitamente $Q(\theta | \hat{\theta}_0, x)$ para todos los θ (o al menos para los necesarios en el paso M).

Para comprender el origen de la función Q , observemos que el logaritmo de la verosimilitud de los datos observados puede expresarse de la siguiente manera. Dado que $\int f(z | \hat{\theta}_0, x) dz = 1$, se tiene

$$\ln L(\theta | x) = \ln L(\theta | x) \cdot \int f(z | \hat{\theta}_0, x) dz = \int [\ln L(\theta | x)] f(z | \hat{\theta}_0, x) dz.$$

Pero $L(\theta | x) = f(x | \theta)$ y, por la regla de Bayes,

$$f(x | \theta) = \frac{f(x, z | \theta)}{f(z | \theta, x)}.$$

Sustituyendo,

$$\ln L(\theta | x) = \int [\ln f(x, z | \theta) - \ln f(z | \theta, x)] f(z | \hat{\theta}_0, x) dz.$$

Por lo tanto,

$$\ln L(\theta | x) = \mathbb{E} \left[\ln L(\theta | x, Z) \mid \hat{\theta}_0, x \right] - \mathbb{E} \left[\ln f(Z | \theta, x) \mid \hat{\theta}_0, x \right].$$

El primer término es precisamente la función $Q(\theta | \hat{\theta}_0, x)$. El segundo término, aunque depende de θ , no es necesario maximizarlo directamente porque, en el paso M, solo maximizamos Q ; la diferencia entre $\ln L(\theta | x)$ y Q está acotada y, bajo condiciones de regularidad, maximizar Q produce un incremento en la verosimilitud observada.

Paso M: maximización. En el paso M, se encuentra el valor de θ que maximiza la función Q :

$$\hat{\theta}_1 = \arg \max_{\theta} Q(\theta | \hat{\theta}_0, x).$$

Este nuevo valor $\hat{\theta}_1$ reemplaza a $\hat{\theta}_0$, y el proceso se repite. De esta manera se genera una secuencia de estimaciones

$$\hat{\theta}_0, \hat{\theta}_1, \hat{\theta}_2, \dots$$

que, bajo condiciones de regularidad (como la concavidad de la función de verosimilitud), converge al estimador máximo verosímil $\hat{\theta}_{\text{EMV}}$.

Una propiedad fundamental del algoritmo EM es que cada iteración no disminuye la verosimilitud observada:

$$L(\hat{\theta}_{t+1} | x) \geq L(\hat{\theta}_t | x).$$

Esto garantiza una mejora monótona, aunque la convergencia puede ser lenta en problemas de alta dimensión.

Ejemplo 7.1 (Mezcla de distribuciones normales (EM)). *Consideremos el modelo de mezcla de d componentes normales. Sean $Z_1, \dots, Z_n$ variables latentes que indican la componente de la cual proviene cada observación:*

$$Z_i \sim \text{Categorical}(p_1, \dots, p_d), \quad X_i | Z_i = j \sim \mathcal{N}(\mu_j, \sigma_j^2).$$

El parámetro desconocido es $\theta = (p_1, \dots, p_d, \mu_1, \dots, \mu_d, \sigma_1^2, \dots, \sigma_d^2)$.

La verosimilitud completa (datos observados x y latentes z) es

$$\log L(\theta | x, z) = \sum_{i=1}^n \sum_{j=1}^d \mathbb{1}_{\{z_i=j\}} (\log p_j + \log \mathcal{N}(x_i | \mu_j, \sigma_j^2)).$$

Sea $\hat{\theta}_0$ una estimación inicial para θ . En el paso E , se calcula la función Q como la esperanza condicional del logaritmo de la verosimilitud completa:

$$Q(\theta \mid \hat{\theta}_0, x) = \mathbb{E} \left[\log L(\theta \mid x, Z) \mid \hat{\theta}_0, x \right],$$

Sustituyendo la expresión de la verosimilitud completa y usando la linealidad de la esperanza:

$$Q(\theta \mid \hat{\theta}_0, x) = \sum_{i=1}^n \sum_{j=1}^d \gamma_{ij}(\hat{\theta}_0) (\log p_j + \log \mathcal{N}(x_i \mid \mu_j, \sigma_j^2)),$$

donde las responsabilidades $\gamma_{ij}(\hat{\theta}_0)$ son las probabilidades condicionales de pertenencia:

$$\gamma_{ij}(\hat{\theta}_0) = \mathbb{P}_{\hat{\theta}_0}(Z_i = j \mid X_i = x_i) = \frac{\hat{p}_j^{(0)} \mathcal{N}(x_i \mid \hat{\mu}_j^{(0)}, (\hat{\sigma}_j^2)^{(0)})}{\sum_{m=1}^d \hat{p}_m^{(0)} \mathcal{N}(x_i \mid \hat{\mu}_m^{(0)}, (\hat{\sigma}_m^2)^{(0)})}.$$

En el paso M , se maximiza la función Q con respecto a θ :

$$\hat{\theta}_1 = \arg \max_{\theta} Q(\theta \mid \hat{\theta}_0, x).$$

Definiendo $n_j = \sum_{i=1}^n \gamma_{ij}(\hat{\theta}_0)$, las actualizaciones que maximizan Q son:

$$\begin{aligned} \hat{p}_j^{(1)} &= \frac{n_j}{n}, & \hat{\mu}_j^{(1)} &= \frac{1}{n_j} \sum_{i=1}^n \gamma_{ij}(\hat{\theta}_0) x_i, \\ (\hat{\sigma}_j^2)^{(1)} &= \frac{1}{n_j} \sum_{i=1}^n \gamma_{ij}(\hat{\theta}_0) (x_i - \hat{\mu}_j^{(1)})^2. \end{aligned}$$

El proceso se repite: a partir de $\hat{\theta}_1$ se calcula $Q(\theta \mid \hat{\theta}_1, x)$ y se maximiza para obtener $\hat{\theta}_2$, y así sucesivamente. La secuencia de estimaciones $\hat{\theta}_0, \hat{\theta}_1, \hat{\theta}_2, \dots$ converge, bajo condiciones de regularidad, al estimador máximo verosímil de θ .

Estas expresiones se generalizan de manera natural al caso multivariado, donde $x_i \in \mathbb{R}^d$, $\mu_j \in \mathbb{R}^d$ y $\Sigma_j \in \mathbb{R}^{d \times d}$ es la matriz de covarianza. Las responsabilidades toman la forma

$$\gamma_{ij}(\hat{\theta}_0) = \frac{\hat{p}_j^{(0)} \mathcal{N}(x_i \mid \hat{\mu}_j^{(0)}, \hat{\Sigma}_j^{(0)})}{\sum_{m=1}^K \hat{p}_m^{(0)} \mathcal{N}(x_i \mid \hat{\mu}_m^{(0)}, \hat{\Sigma}_m^{(0)})}.$$

Las actualizaciones del paso M son entonces

$$\begin{aligned} \hat{p}_j^{(1)} &= \frac{n_j}{n}, & \hat{\mu}_j^{(1)} &= \frac{1}{n_j} \sum_{i=1}^n \gamma_{ij}(\hat{\theta}_0) x_i, \\ \hat{\Sigma}_j^{(1)} &= \frac{1}{n_j} \sum_{i=1}^n \gamma_{ij}(\hat{\theta}_0) (x_i - \hat{\mu}_j^{(1)})(x_i - \hat{\mu}_j^{(1)})^\top. \end{aligned}$$

Este es el algoritmo EM clásico para mezclas de gaussianas, ampliamente utilizado en agrupamiento (clustering) y estimación de densidades.

7.1.1. Monte Carlo EM

En muchas aplicaciones del algoritmo EM, la integral que define la función Q puede ser difícil o imposible de calcular analíticamente. Esto ocurre, por ejemplo, cuando la distribución condicional de los datos faltantes no tiene una forma cerrada o cuando el modelo es complejo. En estos casos, se puede recurrir a una aproximación mediante simulación: en lugar de calcular la esperanza exacta, se genera una muestra de los datos faltantes a partir de la distribución condicional y se aproxima Q por su promedio empírico.

Monte Carlo EM. Dada una estimación actual $\hat{\theta}_0$, sean $z^{(1)}, \dots, z^{(m)}$ valores generados de manera independiente a partir de la densidad condicional $f(z \mid \hat{\theta}_0, x)$. La función $Q(\theta \mid \hat{\theta}_0, x)$ se reemplaza por su aproximación Monte Carlo:

$$\tilde{Q}(\theta \mid \hat{\theta}_0, x) = \frac{1}{m} \sum_{i=1}^m \log L(\theta \mid x, z^{(i)}).$$

A continuación, se realiza el paso M maximizando $\tilde{Q}$ con respecto a θ para obtener $\hat{\theta}_1$. El proceso se repite iterativamente: en cada iteración, se simulan nuevos valores de los datos faltantes usando la estimación actual y se maximiza la función Q aproximada.

Este enfoque, conocido como *Monte Carlo EM* (MCEM), es especialmente útil cuando la esperanza condicional no se puede calcular de forma cerrada, pero sí se puede simular de la distribución condicional. La precisión de la aproximación mejora al aumentar el número de simulaciones m , aunque en la práctica se suele usar un m moderado y aumentarlo conforme el algoritmo se acerca a la convergencia.

Ejemplo 7.2 (Estimación de la media de una normal con datos faltantes). Sea $x = (x_1, \dots, x_{n_1})$ un vector de n_1 observaciones independientes de una distribución $\mathcal{N}(\theta, 1)$, donde θ es desconocido y se desea estimar por máxima verosimilitud. Denotaremos por $f(x \mid \theta)$ a la densidad de una $\mathcal{N}(\theta, 1)$. Sea $z = (z_1, \dots, z_{n_2})$ un vector de n_2 observaciones faltantes de la misma distribución, generadas de manera independiente y también independientes de x . Los valores $z_1, \dots, z_{n_2}$ no se conocen.

Los datos completos son (x, z) , con función de verosimilitud

$$L(\theta \mid x, z) = f(x, z \mid \theta) = \prod_{i=1}^{n_1} f(x_i \mid \theta) \cdot \prod_{i=1}^{n_2} f(z_i \mid \theta),$$

por la independencia entre todas las observaciones. Los datos observados son únicamente x , por lo que la verosimilitud observada es

$$L(\theta \mid x) = f(x \mid \theta) = \prod_{i=1}^{n_1} f(x_i \mid \theta).$$

La distribución condicional de los datos faltantes dados los observados y el parámetro es

$$f(z \mid \theta, x) = \frac{f(x, z \mid \theta)}{f(x \mid \theta)} = \prod_{i=1}^{n_2} f(z_i \mid \theta),$$

que, debido a la independencia, no depende de x . En este caso, la integral para Q es sencilla, por lo que no es necesario recurrir a Monte Carlo, pero el ejemplo ilustra la mecánica del algoritmo EM.

Sea $\hat{\theta}_0$ una estimación inicial. En el paso E, se calcula

$$Q(\theta \mid \hat{\theta}_0, x) = \mathbb{E} \left[\log L(\theta \mid x, Z) \mid \hat{\theta}_0, x \right].$$

Sustituyendo la verosimilitud completa y usando la independencia,

$$Q(\theta \mid \hat{\theta}_0, x) = \sum_{i=1}^{n_2} \mathbb{E} \left[\log f(Z_i \mid \theta) \mid \hat{\theta}_0 \right] + \sum_{i=1}^{n_1} \log f(x_i \mid \theta),$$

donde la esperanza se toma respecto a la densidad $f(z \mid \hat{\theta}_0) = \mathcal{N}(\hat{\theta}_0, 1)$. Dado que $Z_i \sim \mathcal{N}(\hat{\theta}_0, 1)$, se tiene que

$$\mathbb{E}[Z_i \mid \hat{\theta}_0] = \hat{\theta}_0, \quad \mathbb{E}[Z_i^2 \mid \hat{\theta}_0] = \hat{\theta}_0^2 + 1.$$

Para maximizar Q , derivamos con respecto a θ . Usando que para $f(x \mid \theta) = \mathcal{N}(\theta, 1)$ se cumple

$$\frac{\partial}{\partial \theta} \log f(x \mid \theta) = x - \theta,$$

obtenemos

$$\frac{\partial}{\partial \theta} Q(\theta \mid \hat{\theta}_0, x) = n_2(\hat{\theta}_0 - \theta) + \sum_{i=1}^{n_1} (x_i - \theta) = n_2(\hat{\theta}_0 - \theta) + n_1(\bar{x} - \theta),$$

donde $\bar{x} = \frac{1}{n_1} \sum_{i=1}^{n_1} x_i$. Igualando a cero y resolviendo para θ ,

$$n_2(\hat{\theta}_0 - \theta) + n_1(\bar{x} - \theta) = 0 \implies (n_1 + n_2)\theta = n_2\hat{\theta}_0 + n_1\bar{x}.$$

Por lo tanto, la actualización de EM es

$$\hat{\theta}_1 = \frac{n_1}{n_1 + n_2} \bar{x} + \frac{n_2}{n_1 + n_2} \hat{\theta}_0.$$

En general, la recurrencia es

$$\hat{\theta}_{t+1} = \frac{n_1}{n} \bar{x} + \frac{n_2}{n} \hat{\theta}_t, \quad n = n_1 + n_2.$$

Tomando el límite cuando $t \rightarrow \infty$, y suponiendo que $\hat{\theta}_t \rightarrow \hat{\theta}$, se tiene

$$\hat{\theta} = \frac{n_1}{n} \bar{x} + \frac{n_2}{n} \hat{\theta} \implies \hat{\theta} = \bar{x}.$$

Es decir, el algoritmo EM converge a la media muestral de los datos observados, que es el estimador máximo verosímil de θ en este modelo.

7.2. Descenso de Gradiente Estocástico (SGD)

El descenso de gradiente estocástico (SGD) es un método iterativo para minimizar funciones objetivo que se expresan como una esperanza o como una suma finita de términos. Es ampliamente utilizado en aprendizaje automático y estadística computacional, especialmente cuando el tamaño de los datos es grande, ya que permite actualizar los parámetros utilizando solo una o unas pocas observaciones en cada iteración, reduciendo drásticamente el coste computacional por paso.

Consideramos el problema de optimización estocástica

$$\min_{\theta \in \mathbb{R}^d} F(\theta) = \mathbb{E}_{\xi \sim P}[\ell(\theta, \xi)],$$

donde $\xi : \Omega \rightarrow E$ es una variable aleatoria que representa los datos, y $\ell : \mathbb{R}^d \times E \rightarrow \mathbb{R}$ es una función de pérdida que se supone suficientemente regular (por ejemplo, convexa y diferenciable). Sea θ^* el minimizador global de F .

La actualización de SGD, partiendo de un valor inicial θ_0 , es

$$\theta_{n+1} = \theta_n - \eta_n \nabla \ell(\theta_n, \xi_{n+1}),$$

donde $\{\xi_n\}_{n \geq 1}$ son variables i.i.d. con distribución P , y $\eta_n > 0$ es la *tasa de aprendizaje* (o paso) en la iteración n . La condición clave es que el gradiente estocástico sea insesgado:

$$\mathbb{E}[\nabla \ell(\theta_n, \xi_{n+1}) \mid \mathcal{F}_n] = \nabla F(\theta_n),$$

donde $\mathcal{F}_n = \sigma(\xi_1, \dots, \xi_n)$ es la historia hasta el tiempo n .

Convergencia casi segura. Bajo condiciones de regularidad (como la convexidad fuerte de ℓ y la existencia de momentos acotados del gradiente), y si la tasa de aprendizaje satisface

$$\sum_{n=1}^{\infty} \eta_n = \infty, \quad \sum_{n=1}^{\infty} \eta_n^2 < \infty,$$

entonces se tiene que

$$\theta_n \xrightarrow[n \rightarrow \infty]{\text{c.s.}} \theta^*,$$

donde θ^* es el minimizador global de F . Estas condiciones sobre η_n son las típicas para garantizar convergencia casi segura en optimización estocástica. Ejemplos comunes de tasas que cumplen estas condiciones son $\eta_n = 1/n$ o $\eta_n = 1/\sqrt{n}$ (esta última no cumple la segunda condición en dimensión 1, pero sí la primera; en la práctica se usan variantes con suma de cuadrados finita).

Convergencia en distribución para tasa constante. En muchas aplicaciones prácticas, se utiliza una tasa de aprendizaje constante $\eta_n = \eta > 0$ para todo n . En este caso, el algoritmo no converge casi seguramente a un punto fijo, sino que oscila alrededor del mínimo. Sin embargo, bajo condiciones de convexidad fuerte y regularidad del gradiente, se puede demostrar que la distribución de θ_n converge a una distribución normal en torno a θ^* . Más precisamente,

$$\sqrt{n}(\theta_n - \theta^*) \xrightarrow{d} \mathcal{N}(0, \eta^2 \Sigma),$$

donde Σ es una matriz que depende de la covarianza del gradiente estocástico y de la curvatura de F en θ^* . Este resultado justifica el uso de tasas constantes en problemas donde se acepta un error estacionario y se prefiere una convergencia rápida en las primeras iteraciones.

Versión Mini-batch. En la práctica, en lugar de usar una única observación para estimar el gradiente, se utiliza un *mini-batch* de tamaño m . Dado un lote de observaciones independientes $\xi_{n+1}^{(1)}, \dots, \xi_{n+1}^{(m)}$, la actualización es

$$\theta_{n+1} = \theta_n - \frac{\eta_n}{m} \sum_{j=1}^m \nabla \ell(\theta_n, \xi_{n+1}^{(j)}).$$

Esta variante reduce la varianza del gradiente estocástico (en un factor $1/m$ si los gradientes son independientes), lo que permite usar tasas de aprendizaje ligeramente mayores y acelera la convergencia en la práctica. El coste por iteración escala linealmente con m , por lo que existe un compromiso entre la reducción de varianza y el coste computacional.

Ejemplo 7.3 (SGD para una función cuadrática unidimensional). *Consideremos la función objetivo*

$$F(\theta) = \frac{1}{2}(\theta - \mu)^2, \quad \theta \in \mathbb{R},$$

donde $\mu \in \mathbb{R}$ es el valor que minimiza F (el mínimo global es $\theta^* = \mu$). El gradiente verdadero es

$$\nabla F(\theta) = \theta - \mu.$$

Supongamos que, en cada iteración, no disponemos del gradiente verdadero, sino de una versión ruidosa:

$$\nabla \ell(\theta, \xi) = \nabla F(\theta) + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2),$$

donde ε es independiente del estado actual y de todo el pasado. Es decir, el gradiente estocástico es el gradiente verdadero más un ruido gaussiano.

La actualización de SGD con tasa de aprendizaje constante $\eta > 0$ es entonces

$$\theta_{n+1} = \theta_n - \eta(\theta_n - \mu + \varepsilon_{n+1}),$$

donde $\{\varepsilon_{n+1}\}_{n \geq 0}$ son i.i.d. $\mathcal{N}(0, \sigma^2)$.

Reescribiendo la ecuación,

$$\theta_{n+1} - \mu = (1 - \eta)(\theta_n - \mu) - \eta\varepsilon_{n+1}.$$

Sea $e_n = \theta_n - \mu$. Entonces

$$e_{n+1} = (1 - \eta)e_n - \eta\varepsilon_{n+1}.$$

Esta es una recurrencia lineal con ruido aditivo.

Tomando esperanza condicional (dado $\mathcal{F}_n = \sigma(\varepsilon_1, \dots, \varepsilon_n)$),

$$\mathbb{E}[e_{n+1} \mid \mathcal{F}_n] = (1 - \eta)e_n,$$

y por lo tanto,

$$\mathbb{E}[e_n] = (1 - \eta)^n e_0.$$

Si $0 < \eta < 2$, entonces $|1 - \eta| < 1$, y la esperanza de e_n tiende a 0, es decir, el valor esperado de θ_n converge a μ .

En cuanto a la varianza, de la recurrencia,

$$\text{Var}(e_{n+1}) = (1 - \eta)^2 \text{Var}(e_n) + \eta^2 \sigma^2.$$

La solución estacionaria (cuando $n \rightarrow \infty$) satisface

$$\text{Var}(e_\infty) = \frac{\eta^2 \sigma^2}{1 - (1 - \eta)^2} = \frac{\eta \sigma^2}{2 - \eta}.$$

Por lo tanto, en el régimen estacionario,

$$\theta_n \sim \mathcal{N}\left(\mu, \frac{\eta \sigma^2}{2 - \eta}\right).$$

Es decir, con tasa de aprendizaje constante, el algoritmo no converge a μ de forma casi segura, sino que oscila alrededor del mínimo con una distribución normal de varianza $\eta \sigma^2 / (2 - \eta)$. Si se desea convergencia casi segura, se debe usar una tasa de aprendizaje decreciente que cumpla las condiciones de Robbins-Monro: $\sum \eta_n = \infty$ y $\sum \eta_n^2 < \infty$. En ese caso, $\theta_n \rightarrow \mu$ casi seguramente.

Aplicación a la minimización del riesgo empírico. Supongamos que tenemos un conjunto de entrenamiento

$$\mathcal{D} = \{(x_1, y_1), \dots, (x_N, y_N)\},$$

donde $x_i \in \mathcal{X}$ e $y_i \in \mathcal{Y}$. El objetivo es minimizar el riesgo empírico:

$$L(\theta) = \frac{1}{N} \sum_{i=1}^N \ell(y_i, f(x_i, \theta)),$$

donde $f(x, \theta)$ es el modelo paramétrico y ℓ es una función de pérdida. El gradiente completo es

$$\nabla_\theta L(\theta) = \frac{1}{N} \sum_{i=1}^N \nabla_\theta \ell(y_i, f(x_i, \theta)).$$

SGD aproxima este gradiente usando un subconjunto aleatorio (mini-batch) $\mathcal{B} \subset \{1, \dots, N\}$ de tamaño B :

$$\nabla_\theta L(\theta) \approx \frac{1}{B} \sum_{i \in \mathcal{B}} \nabla_\theta \ell(y_i, f(x_i, \theta)).$$

Ejemplo 7.4 (SGD para regresión lineal). Consideremos el modelo de regresión lineal con pérdida cuadrática:

$$\ell(\theta; x_i, y_i) = (y_i - x_i^\top \theta)^2,$$

donde $\theta \in \mathbb{R}^d$ es el vector de coeficientes. El riesgo empírico es

$$L(\theta) = \frac{1}{N} \sum_{i=1}^N (y_i - x_i^\top \theta)^2.$$

El gradiente completo es

$$\nabla L(\theta) = -\frac{2}{N} \sum_{i=1}^N x_i (y_i - x_i^\top \theta).$$

La actualización de SGD con una sola observación (x_i, y_i) es

$$\theta_{n+1} = \theta_n + 2\eta_n x_i(y_i - x_i^\top \theta_n).$$

Con mini-batch de tamaño B , la actualización es

$$\theta_{n+1} = \theta_n + \frac{2\eta_n}{B} \sum_{i \in \mathcal{B}} x_i(y_i - x_i^\top \theta_n).$$

Este algoritmo converge al estimador de mínimos cuadrados ordinarios $\theta^* = (X^\top X)^{-1} X^\top y$ bajo las condiciones habituales de regularidad. En el caso de tasa constante $\eta_n = \eta$, la cadena de Markov resultante oscila alrededor de θ^* con una distribución estacionaria aproximadamente normal, como se mencionó anteriormente.

7.3. Búsqueda Aleatoria

Una estrategia sorprendentemente efectiva en problemas donde no se dispone de información sobre la función objetivo es la *búsqueda aleatoria*. En este enfoque, cada iteración t consiste en elegir un punto θ_{t+1} de manera uniforme al azar dentro del espacio de búsqueda Θ , evaluar la función objetivo $f(\theta_{t+1})$ y mantener el mejor valor encontrado hasta el momento. Es decir,

$$\theta_t^* = \arg \min_{\theta \in \{\theta_1, \dots, \theta_t\}} f(\theta).$$

A pesar de su aparente simplicidad, esta técnica siempre debería probarse como línea base antes de implementar métodos más sofisticados, ya que en muchos casos proporciona soluciones competitivas con un coste computacional mínimo.

Esta estrategia ha sido aplicada con éxito en la optimización de hiperparámetros para modelos de aprendizaje automático, donde el objetivo es maximizar el rendimiento en un conjunto de validación. En estos problemas, el espacio de búsqueda suele ser continuo y de la forma

$$\Theta = [0, 1]^D,$$

lo que hace muy sencillo muestrear de manera aleatoria. La alternativa estándar consiste en cuantizar el espacio en un conjunto fijo de valores y evaluar todas las combinaciones posibles; esto se conoce como *búsqueda en cuadrícula* o *grid search*. Por supuesto, este último enfoque solo es factible cuando el número de dimensiones D es pequeño, ya que el número de evaluaciones crece exponencialmente con D .

En diversos estudios empíricos se ha encontrado que la búsqueda aleatoria supera a la búsqueda en cuadrícula. La razón intuitiva es que muchos hiperparámetros no tienen un efecto significativo sobre la función objetivo, y por lo tanto, colocar una cuadrícula fina a lo largo de dimensiones poco importantes resulta una pérdida de tiempo y recursos computacionales. En cambio, el muestreo aleatorio permite explorar cada dimensión con una resolución efectiva mucho mayor, concentrando los recursos en las direcciones que realmente importan.

Ejemplo 7.5 (Búsqueda aleatoria vs búsqueda en cuadrícula). *Supongamos que tenemos una función objetivo $f : [0, 1]^2 \rightarrow \mathbb{R}$ que depende de manera significativa solo de la primera coordenada, mientras que la segunda coordenada tiene una influencia despreciable. Por ejemplo,*

$$f(x_1, x_2) = (x_1 - 0.5)^2 + 0.01(x_2 - 0.5)^2.$$

El mínimo global está en $(0.5, 0.5)$, y el valor de x_1 es crítico para alcanzar un buen rendimiento, mientras que x_2 apenas afecta al resultado.

Consideremos dos estrategias con un presupuesto de $N = 25$ evaluaciones.

Búsqueda en cuadrícula (5×5): Se dividen ambas dimensiones en 5 valores equiespaciados: $\{0, 0.25, 0.5, 0.75, 1\}$. La cuadrícula contiene 25 puntos. En la dimensión importante x_1 , solo se prueban 5 valores fijos. Si el óptimo 0.5 está en la cuadrícula, se encuentra; si no, el error en x_1 será al menos de 0.25 (la mitad del espaciado).

Búsqueda aleatoria (25 muestras): Se generan 25 puntos (x_1, x_2) con cada coordenada uniforme en $[0, 1]$. En la dimensión importante x_1 , la muestra aleatoria equivale a 25 valores independientes. La resolución efectiva en x_1 es mucho mayor que la cuadrícula, y la probabilidad de obtener un valor cercano a 0.5 es alta. Además, los puntos se distribuyen de manera irregular, lo que permite una mejor cobertura de la región relevante.

Este sencillo ejemplo ilustra por qué la búsqueda aleatoria tiende a superar a la búsqueda en cuadrícula cuando la función objetivo tiene una dimensión efectiva baja, es decir, cuando solo unas pocas variables son realmente importantes. En la práctica, se recomienda utilizar búsqueda aleatoria como primer paso, y luego refinar la solución con métodos más específicos si es necesario.

7.4. Recocido Simulado

El recocido simulado es un algoritmo estocástico de búsqueda local que intenta encontrar el mínimo global de una función de caja negra $E(x)$, conocida como *función de energía*. El método convierte la energía en una distribución de probabilidad no normalizada sobre los estados, definida como

$$p(x) = \exp(-E(x)),$$

y utiliza una variante del algoritmo de Metropolis-Hastings para muestrear de un conjunto de distribuciones de probabilidad. Al final, el método tiende a muestrear de los modos de la distribución, es decir, de los estados más probables o de menor energía. Este enfoque puede aplicarse tanto a optimización discreta como continua.

La idea se inspira en el proceso físico de recocido: calentar un sólido y enfriarlo lentamente hasta alcanzar un estado de mínima energía. Para trasladar este concepto a la optimización, se define la distribución de Boltzmann a temperatura T :

$$p_T(x) = \exp\left(-\frac{E(x)}{T}\right),$$

donde $T > 0$ es la *temperatura*, que se reduce gradualmente a lo largo de las iteraciones. A medida que T disminuye, los picos más grandes se acentúan y los más pequeños desaparecen, permitiendo seguir el máximo dominante y encontrar el óptimo global.

Algoritmo. En cada paso, se propone un nuevo estado

$$x' \sim q(\cdot \mid x_t),$$

que para parámetros reales suele ser un paseo aleatorio:

$$x' = x_t + \varepsilon_{t+1}, \quad \varepsilon_{t+1} \sim \mathcal{N}(0, \Sigma).$$

La probabilidad de aceptación se calcula como

$$\alpha_{t+1} = \exp\left(-\frac{E(x') - E(x_t)}{T_t}\right),$$

y se acepta el nuevo estado con probabilidad $\min(1, \alpha_{t+1})$. Si el nuevo estado tiene menor energía ($E(x') < E(x_t)$), entonces $\alpha_{t+1} > 1$ y se acepta siempre. Si tiene mayor energía, puede aceptarse con una probabilidad que depende de la temperatura: a alta temperatura, es más probable aceptar estados con mayor energía, lo que permite escapar de mínimos locales; a baja temperatura, el algoritmo se comporta de manera más determinista.

Programa de enfriamiento. La velocidad con la que disminuye la temperatura se denomina *programa de enfriamiento*. Se ha demostrado que un enfriamiento logarítmico,

$$T_t \propto \frac{1}{\log(t+1)},$$

garantiza encontrar el óptimo global bajo ciertas condiciones, aunque en la práctica es demasiado lento. Por ello, se suele usar un enfriamiento exponencial

$$T_{t+1} = \gamma T_t, \quad \gamma \in (0, 1],$$

donde enfriar demasiado rápido puede llevar a quedar atrapado en un óptimo local, mientras que enfriar demasiado lento desperdicia tiempo. Determinar el mejor programa de enfriamiento es uno de los principales desafíos del recocido simulado.

El algoritmo completo es:

1. Definir un estado inicial x_0 y temperatura inicial T_0 .

2. Para $t = 1, 2, \dots, T$:

a) Proponer un nuevo estado $x' \sim q(\cdot \mid x_{t-1})$.

b) Calcular la probabilidad de aceptación:

$$\alpha = \exp\left(-\frac{E(x') - E(x_{t-1})}{T_{t-1}}\right).$$

c) Aceptar $x_t = x'$ con probabilidad $\min(1, \alpha)$; en otro caso, $x_t = x_{t-1}$.

d) Actualizar la temperatura: $T_t = \gamma T_{t-1}$, con $\gamma \in (0, 1]$.

7.5. Algoritmos Evolutivos

La búsqueda local estocástica (SLS) mantiene una única mejor estimación en cada paso, x_t . Si se ejecuta durante T pasos y se reinicia K veces, el costo total es TK . Una alternativa natural es mantener un conjunto o *población* de K candidatos, S_t , que se intenta mejorar en cada paso. Esto se denomina *algoritmo evolutivo* (EA). Si se ejecuta durante T pasos, también toma TK tiempo; sin embargo, puede obtener mejores resultados que SLS con múltiples reinicios, ya que el procedimiento explora más del espacio en paralelo y comparte información entre los miembros de la población.

Los algoritmos evolutivos se inspiran en la evolución biológica y adoptan su terminología. La *aptitud* de un miembro de la población es el valor de la función objetivo que se desea optimizar (por ejemplo, minimizar el error o maximizar el rendimiento). Los descendientes en el paso $t + 1$ pueden crearse mediante:

- **Mutación aleatoria** de un padre (reproducción asexual): se aplica una perturbación aleatoria a un individuo para generar un nuevo candidato.
- **Recombinación o cruce** de dos padres, seguido de mutación: se combinan partes de dos individuos para producir descendientes que heredan características de ambos.

Función de selección. El procedimiento por el cual se eligen los padres se denomina *función de selección*. Algunas variantes comunes son:

- **Selección por truncamiento:** los padres se eligen de los K individuos más aptos (conjunto élite), ignorando al resto de la población.
- **Selección por torneo:** cada padre es el más apto de un subconjunto aleatorio de K individuos. Se repite el torneo varias veces para seleccionar múltiples padres.
- **Selección proporcional a la aptitud** (ruleta): cada padre se elige con probabilidad proporcional a su aptitud relativa dentro de la población. Esto da más oportunidades de reproducción a los individuos con mejor rendimiento.
- **Evolución regularizada:** se eliminan los individuos más antiguos de la población y se seleccionan padres en función de su aptitud, manteniendo un equilibrio entre exploración y explotación.

Variantes de algoritmos evolutivos. Además de la regla de selección, se deben especificar las reglas de recombinación y mutación. Algunas variantes destacadas son:

- **Algoritmos genéticos (GA):** utilizan mutación y recombinación basada en cruce de cadenas binarias o vectores de enteros. Son los más clásicos y ampliamente utilizados.
- **Programación genética:** los individuos se representan como árboles (por ejemplo, expresiones matemáticas o programas), y los operadores de cruce y mutación se definen sobre estas estructuras, asegurando que los descendientes sean sintácticamente válidos.

- **EA asistidos por sustituto:** se emplea una función aproximada $\hat{f}(s)$ en lugar de la función objetivo real $f(s)$ para acelerar la evaluación, especialmente cuando f es costosa de calcular.
- **Algoritmos meméticos:** combinan mutación y recombinación con búsqueda local estándar (por ejemplo, descenso de gradiente) para refinar los individuos antes de insertarlos en la población.

Los algoritmos evolutivos se han aplicado en numerosos campos, incluyendo el entrenamiento de redes neuronales, donde esta combinación se conoce como *neuroevolución*, y en problemas de optimización combinatoria donde los métodos basados en gradiente no son aplicables.

El flujo general de un algoritmo genético básico es el siguiente:

1. Inicializar una población S_0 de K individuos (por ejemplo, generando valores aleatorios en el espacio de búsqueda).
2. Para $t = 1, \dots, T$:
 - a) Evaluar la aptitud de cada individuo $x \in S_{t-1}$ mediante la función objetivo $f(x)$.
 - b) Seleccionar padres de S_{t-1} según una regla de selección (por ejemplo, proporcional a la aptitud o por torneo).
 - c) Aplicar cruce: para cada par de padres seleccionados, elegir un punto de cruce aleatorio e intercambiar segmentos de los cromosomas para generar descendientes.
 - d) Aplicar mutación: con probabilidad p_{mut} , alterar aleatoriamente un gen de cada descendiente.
 - e) Formar la nueva población S_t con los descendientes, y opcionalmente preservar algunos de los mejores individuos de la generación anterior (élite).
3. Devolver el mejor individuo encontrado a lo largo de todas las generaciones.

8. Inferencia Variacional

La inferencia variacional es una técnica de aproximación utilizada en modelos probabilísticos complejos, donde la distribución posterior $p(z \mid x)$ no puede calcularse de forma cerrada. En lugar de muestrear de la posterior mediante MCMC (que puede ser computacionalmente costoso), la inferencia variacional propone aproximar la posterior mediante una familia paramétrica de distribuciones $q_\theta(z)$, y optimizar los parámetros θ para que q_θ sea lo más cercana posible a la posterior en términos de la divergencia de Kullback-Leibler.

Antes de abordar el problema variacional, es necesario introducir dos conceptos fundamentales: la entropía y la divergencia de Kullback-Leibler, que son las herramientas matemáticas que permiten medir la incertidumbre y la discrepancia entre distribuciones.

8.1. Divergencia de Kullback-Leibler y entropía

Entropía. La entropía de una distribución de probabilidad $q(x)$ sobre un espacio continuo o discreto mide la incertidumbre promedio asociada a la variable aleatoria $X \sim q$. Se define como

$$H(q) = -\mathbb{E}_q[\log q(X)] = - \int q(x) \log q(x) dx$$

en el caso continuo, y como

$$H(q) = - \sum_x q(x) \log q(x)$$

en el caso discreto. La entropía es no negativa y alcanza su valor máximo cuando la distribución es uniforme sobre su soporte (máxima incertidumbre), y su valor mínimo (0) cuando la distribución es degenerada (un punto fijo con probabilidad 1). En el contexto de la inferencia variacional, la entropía actúa como un término de regularización que fomenta que la distribución variacional mantenga cierta diversidad.

Divergencia de Kullback-Leibler (KL). La divergencia de Kullback-Leibler es una medida de la disimilitud entre dos distribuciones de probabilidad q y p . Se define como

$$D_{KL}(q \parallel p) = \mathbb{E}_q \left[\log \frac{q(X)}{p(X)} \right] = \int q(x) \log \frac{q(x)}{p(x)} dx.$$

Aunque no es una distancia en sentido estricto (no es simétrica y no cumple la desigualdad triangular), la KL-divergencia tiene propiedades fundamentales:

- **No negatividad:** $D_{KL}(q \parallel p) \geq 0$, con igualdad si y solo si $q = p$ casi seguramente.
- **Asimetría:** en general, $D_{KL}(q \parallel p) \neq D_{KL}(p \parallel q)$. Esto es importante porque en inferencia variacional minimizamos $D_{KL}(q \parallel p)$, lo que favorece que q cubra los modos de p (en lugar de $D_{KL}(p \parallel q)$, que favorecería que q se concentrara en un solo modo).

Ejemplo 8.1 (Entropía de distribuciones comunes). ▪ **Bernoulli**(p): $H = -p \log p - (1 - p) \log(1 - p)$. Es máxima en $p = 0.5$ (máxima incertidumbre) y mínima (0) en $p = 0$ o $p = 1$.

- **Normal**(μ, σ^2): $H = \frac{1}{2} \log(2\pi e \sigma^2)$. Depende únicamente de la varianza; a mayor varianza, mayor entropía.
- **Poisson**(λ): $H = \lambda - \lambda \log \lambda + \mathbb{E}[\log(X!)]$, que no tiene forma cerrada simple, pero crece con λ .

Ejemplo 8.2 (Cálculo de la KL-divergencia entre dos normales). Sean $p = \mathcal{N}(\mu_1, \sigma_1^2)$ y $q = \mathcal{N}(\mu_2, \sigma_2^2)$. La divergencia KL de q a p es

$$D_{KL}(q \parallel p) = \log \frac{\sigma_2}{\sigma_1} + \frac{\sigma_1^2 + (\mu_1 - \mu_2)^2}{2\sigma_2^2} - \frac{1}{2}.$$

Esta expresión será de gran utilidad en inferencia variacional cuando la familia variacional sea normal y la prior también lo sea, ya que permite calcular el término de regularización KL de forma cerrada.

8.2. Inferencia Variacional como optimización

Consideremos un modelo con variable latente z y variable observada x . Supongamos que la prior es $p(z)$ y la verosimilitud es $p(x | z)$, de tal forma que la densidad conjunta es

$$p(x, z) = p(x | z) p(z),$$

y la posterior es

$$p(z | x) = \frac{p(x, z)}{p(x)}.$$

Además, supongamos que la constante de normalización $p(x) = \int p(x, z) dz$ es incalculable (o muy costosa de evaluar), y por lo tanto la posterior también lo es.

El objetivo de la inferencia variacional es encontrar una densidad $q(z)$ que aproxime la posterior, tal que minimice la siguiente función de pérdida:

$$q = \arg \min_{q \in \mathcal{Q}} D_{KL}(q(z) \| p(z | x)),$$

donde $\mathcal{Q} = \{q_\theta(z) : \theta \in \Theta\}$ es una familia paramétrica de funciones de densidad, y θ se conocen como los *parámetros variacionales*. En la práctica, el problema se reescribe como

$$\theta^* = \arg \min_{\theta} D_{KL}(q_\theta(z) \| p(z | x)).$$

Desarrollando la divergencia KL:

$$\begin{aligned} \theta^* &= \arg \min_{\theta} \mathbb{E}_{q_\theta(z)} \left[\log \frac{q_\theta(z)}{p(z | x)} \right] \\ &= \arg \min_{\theta} \mathbb{E}_{q_\theta(z)} [\log q_\theta(z) - \log p(z | x)] \\ &= \arg \min_{\theta} \mathbb{E}_{q_\theta(z)} \left[\log q_\theta(z) - \log \left(\frac{p(x | z)p(z)}{p(x)} \right) \right] \\ &= \arg \min_{\theta} \mathbb{E}_{q_\theta(z)} [\log q_\theta(z) - \log p(x | z) - \log p(z) + \log p(x)] \\ &= \arg \min_{\theta} \{ \mathbb{E}_{q_\theta(z)} [\log q_\theta(z) - \log p(x | z) - \log p(z)] + \log p(x) \}. \end{aligned}$$

Dado que $\log p(x)$ no depende de θ , el problema se reduce a minimizar

$$\mathcal{L}(\theta | x) = \mathbb{E}_{q_\theta(z)} [-\log p(x, z) + \log q_\theta(z)],$$

donde $\mathcal{L}(\theta | x)$ se denomina la *energía libre variacional* (VFE).

Si definimos la energía como

$$E_\theta(z) = -\log p(x, z),$$

entonces la función de pérdida se puede reescribir como

$$\mathcal{L}(\theta | x) = \mathbb{E}_{q_\theta(z)} [E_\theta(z)] - H(q_\theta),$$

donde $H(q_\theta)$ es la entropía de la distribución variacional. Es decir, la pérdida se interpreta como:

energía esperada – entropía.

Además, se cumple la siguiente relación:

$$D_{KL}(q_\theta(z) \parallel p(z \mid x)) = \mathcal{L}(\theta \mid x) + \log p(x) \geq 0.$$

Por lo tanto,

$$\mathcal{L}(\theta \mid x) \geq -\log p(x).$$

Así, la inferencia variacional es equivalente a minimizar la energía libre variacional. En el caso ideal, cuando se alcanza el mínimo $-\log p(x)$, la divergencia KL es cero, lo que implica que la aproximación $q_\theta(z)$ coincide exactamente con la posterior verdadera.

Evidence Lower Bound (ELBO). El negativo de la energía libre variacional (VFE) se conoce como la *evidence lower bound* (ELBO):

$$\mathcal{E}(\theta \mid x) = \mathbb{E}_{q_\theta(z)} [\log p(x, z) - \log q_\theta(z)].$$

El nombre proviene de que satisface la siguiente cota:

$$\mathcal{E}(\theta \mid x) \leq \log p(x),$$

donde $\log p(x)$ se conoce como la *evidencia*. Por lo tanto, maximizar la ELBO es equivalente a minimizar la divergencia KL, ya que $\log p(x)$ es constante respecto a θ .

La ELBO también se puede escribir como:

$$\mathcal{E}(\theta \mid x) = \mathbb{E}_{q_\theta(z)} [\log p(x \mid z) + \log p(z) - \log q_\theta(z)],$$

que equivale a

$$\mathcal{E}(\theta \mid x) = \mathbb{E}_{q_\theta(z)} [\log p(x \mid z)] - D_{KL}(q_\theta(z) \parallel p(z)).$$

Esto se interpreta como:

$$\text{ELBO} = \text{log-verosimilitud esperada} - \text{regularización KL}.$$

El término KL actúa como un regularizador que evita que la distribución variacional se aleje demasiado de la prior, manteniendo la aproximación dentro de regiones de alta probabilidad a priori.

Ejemplo 8.3 (ELBO estocástica para aproximaciones Gaussianas Mean-Field). *Consideremos una familia variacional con estructura de factorización (mean-field) dada por*

$$\mathcal{Q} = \left\{ q(z) = \prod_{i=1}^d \mathcal{N}(z_i; \mu_i, \sigma_i^2) : \mu_i \in \mathbb{R}, \sigma_i > 0 \right\},$$

donde $z \in \mathbb{R}^d$ es el vector de variables latentes. Supongamos que la prior es

$$p(z) = \mathcal{N}(z; 0, \tau^2 I_d),$$

es decir, un producto de d normales independientes con media 0 y varianza τ^2 .

En este caso, la divergencia KL entre la aproximación variacional y la prior se puede calcular de forma cerrada:

$$D_{KL}(q(z) \parallel p(z)) = \mathbb{E}_{q(z)} \left[\log \frac{q(z)}{p(z)} \right].$$

Sustituyendo las expresiones factorizadas,

$$D_{KL}(q(z) \parallel p(z)) = \mathbb{E}_{q(z)} \left[\log \frac{\prod_{i=1}^d \mathcal{N}(z_i; \mu_i, \sigma_i^2)}{\prod_{i=1}^d \mathcal{N}(z_i; 0, \tau^2)} \right].$$

Usando la propiedad del logaritmo de un producto,

$$D_{KL}(q(z) \parallel p(z)) = \sum_{i=1}^d \mathbb{E}_{q(z)} [\log \mathcal{N}(z_i; \mu_i, \sigma_i^2) - \log \mathcal{N}(z_i; 0, \tau^2)].$$

Dado que cada z_i es independiente bajo $q(z)$, la esperanza se factoriza y el cálculo se reduce a

$$D_{KL}(q(z) \parallel p(z)) = \sum_{i=1}^d \mathbb{E}_{q(z_i)} \left[\log \frac{\tau}{\sigma_i} - \frac{(z_i - \mu_i)^2}{2\sigma_i^2} + \frac{z_i^2}{2\tau^2} \right].$$

Utilizando que bajo $q(z_i) = \mathcal{N}(\mu_i, \sigma_i^2)$ se cumple $\mathbb{E}[(z_i - \mu_i)^2] = \sigma_i^2$ y $\mathbb{E}[z_i^2] = \mu_i^2 + \sigma_i^2$, se obtiene

$$D_{KL}(q(z) \parallel p(z)) = \sum_{i=1}^d \left[\log \frac{\tau}{\sigma_i} - \frac{1}{2} + \frac{\mu_i^2 + \sigma_i^2}{2\tau^2} \right].$$

Ahora, consideremos un conjunto de datos $\mathcal{D} = \{(x_n, y_n)\}_{n=1}^N$. Supongamos que la verosimilitud factoriza sobre las observaciones:

$$p(\mathcal{D} \mid z) = \prod_{n=1}^N p(y_n \mid x_n, z).$$

Entonces,

$$\log p(\mathcal{D} \mid z) = \sum_{n=1}^N \log p(y_n \mid x_n, z).$$

La esperanza bajo $q(z)$ de esta cantidad es

$$\mathbb{E}_{q(z)} [\log p(\mathcal{D} \mid z)] = \sum_{n=1}^N \mathbb{E}_{q(z)} [\log p(y_n \mid x_n, z)].$$

En general, esta esperanza no tiene una forma cerrada. Sin embargo, se puede aproximar mediante Monte Carlo utilizando el truco de reparametrización. Dado que $z \sim q(z) = \mathcal{N}(\mu, \Sigma)$ con $\Sigma = \text{diag}(\sigma_1^2, \dots, \sigma_d^2)$, podemos escribir

$$z = \mu + \sigma \odot \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, I_d),$$

donde $\odot$ denota el producto elemento a elemento. Entonces,

$$\mathbb{E}_{q(z)} [\log p(\mathcal{D} \mid z)] \approx \frac{1}{S} \sum_{s=1}^S \sum_{n=1}^N \log p(y_n \mid x_n, z^{(s)}),$$

donde

$$z^{(s)} = \mu + \sigma \odot \varepsilon^{(s)}, \quad \varepsilon^{(s)} \sim \mathcal{N}(0, I_d).$$

Por lo tanto, la ELBO completa es

$$\mathcal{E}(\theta \mid \mathcal{D}) \approx \frac{1}{S} \sum_{s=1}^S \sum_{n=1}^N \log p(y_n \mid x_n, z^{(s)}) - D_{KL}(q(z) \parallel p(z)),$$

con

$$D_{KL}(q(z) \parallel p(z)) = \sum_{i=1}^d \left[\log \frac{\tau}{\sigma_i} - \frac{1}{2} + \frac{\mu_i^2 + \sigma_i^2}{2\tau^2} \right].$$

Este es el enfoque estándar en modelos como los autoencoders variacionales (VAEs), donde la ELBO se maximiza mediante optimización estocástica utilizando el truco de reparametrización para estimar el gradiente de la esperanza.